

大语言模型驱动的网络问政文本细粒度情感分析：一种多阶段优化方法

滕 婕^{1,2}, 贺荒兰^{1,2}, 胡广伟^{1,2}

(1. 南京大学信息管理学院, 南京 210023; 2. 南京大学政务数据资源研究所, 南京 210023)

摘 要 网络问政文本蕴含丰富的民意情感信息, 其细粒度情感分析对提升政府治理能力具有重要价值。然而, 传统方法难以准确捕捉文本中的复杂情感特征。本研究提出了一种基于大语言模型的网络问政文本细粒度情感分析多阶段优化框架。首先, 基于情绪唤醒度-效价理论, 构建适合网络问政场景的 8 个情绪区间和 56 个情绪标签的情感分类体系, 并采用 GPT-4 (generative pre-trained transformer 4) 配合 BROKE (background, role, objectives, key result, evolve) 框架设计的提示策略进行初始情感标注, 有效地解决了复杂语境理解挑战; 其次, 创新性地提出“大语言模型标注-专家评估-研判模型训练-多阶段优化”的数据质量控制机制, 通过 Claude 3.5 Sonnet 模型校正和研判模型筛选, 解决大语言模型在领域应用中的“幻觉”问题; 最后, 基于 Claude 3.5 Sonnet 的数据生成能力实现情感类别均衡, 将不平衡基尼系数从 0.866 降至 0.181, 显著提升模型泛化能力。实验结果表明, 该框架在情绪细粒度分析任务中准确率达 89.70%, F1 值较现有方法平均提高 21.65%, 为政民互动效能提升提供了新的技术范式。

关键词 网络问政; 细粒度情感; 大语言模型; 数据质量评估; 数据均衡

Fine-Grained Sentiment Analysis of Online Government-Public Interaction Texts Using Large Language Models: Multistage Optimization Approach

Teng Jie^{1,2}, He Huanglan^{1,2} and Hu Guangwei^{1,2}

(1. School of Information Management, Nanjing University, Nanjing 210023;
2. Government Data Resources Institution of Nanjing University, Nanjing 210023)

Abstract: Online government-public interaction texts contain a rich emotional information that reflects public opinion, making the fine-grained sentiment analysis valuable for enhanced government governance capabilities. However, traditional methods struggle to accurately capture complex emotional features in these texts. In this study, we propose a multistage optimization framework for a fine-grained sentiment analysis of online government-public interaction texts based on large language models. First, we establish a sentiment classification system with eight emotional zones and 56 emotional labels based on the arousal-valence theory of emotion, and employ GPT-4 with BROKE framework-designed prompting strategies for an initial sentiment annotation, effectively addressing complex contextual understanding challenges. Second, we innovatively propose a “large model annotation-expert evaluation-judgment model training-multistage optimization” data quality control mechanism, using the Claude 3.5 Sonnet model for correction and judgment model for filtering, solving the

收稿日期: 2024-11-28; 修回日期: 2025-03-07

基金项目: 国家社会科学基金重大项目“大数据驱动的城乡社区服务体系精准化构建研究”(20&ZD154)。

作者简介: 滕婕, 1993 年生, 博士研究生, 主要研究方向为自然语言处理、大模型应用实践; 贺荒兰, 2001 年生, 硕士研究生, 主要研究方向为网络问政; 胡广伟, 通信作者, 1975 年生, 博士, 教授, 博士生导师, 主要研究方向为政务大数据、数据智能与数据治理、价值共创等, E-mail: hugw@nju.edu.cn。

“hallucination” problem of large models in domain applications. Finally, we achieve emotional category balancing through Claude 3.5 Sonnet’s data generation capabilities, reducing the imbalance Gini coefficient from 0.866 to 0.181, significantly enhancing the model generalization ability. Experimental results show that this framework achieves an accuracy of 89.70% in fine-grained emotional analysis tasks, with an F1 score improvement of 21.65% on average compared to existing methods, providing a new technical paradigm for an enhanced government–public interaction effectiveness.

Keywords: e-governance; fine-grained sentiment; large language models; label quality assessment; data balancing

0 引言

随着互联网技术的快速发展和政府网络问政平台的广泛建设，在线问政平台已成为公众表达诉求和参与政策制定的重要渠道。这种前所未有的公众需求数据积累为政务智能化与精细化治理提供了数据基础，同时也对传统文本分析技术提出了新挑战。

网络问政文本具有明显的叙事特点，公众倾向于用详尽的语言描述其遭遇和感受，呈现信息点琐碎、长度不一、情感表达隐晦等特征^[1]。与普通社交媒体文本不同，网络问政语境下的公众表达往往包含更复杂的情感层次，既有对具体事件的客观陈述，也有对政府服务的主观评价，同时还融合了个人情绪体验。这类文本虽然主要表达负面情绪，但其内部情感差异极为丰富——从“忧虑”到“恐慌”、从“失望”到“愤怒”——这些细微差异对理解公众需求与预测社会风险至关重要^[2]。传统的二元或三元情感极性分类（正面/负面/中性）在政务语境下价值有限，而精准识别这些细粒度情感对提升政府治理效能具有重大意义^[3-4]。细粒度情感分析是指超越传统的“正面-负面-中性”三分类框架，能够识别和区分更为具体、微妙的情感状态的分析方法。与粗粒度情感分析仅能判断文本的整体情感倾向不同，细粒度情感分析致力于捕捉情感的强度差异（如从“不满”到“愤怒”的强度递进）、情感的复合性（如“既期待又担忧”的复杂心理状态）以及情感的动态变化（如从“困惑”转向“理解”的情感演进）。在网络问政语境下，细粒度情感分析能够区分“焦虑-忧虑-恐慌”等负面情感的不同层次，以及“期待-满意-兴奋”等正面情感的微妙差异，为政府部门提供更加精准的民意理解和响应策略制定依据。

网络问政文本的细粒度情感分析面临三大科学挑战。首先，叙事型长文本的复杂语境理解问题。当公众描述“我感谢新的回收计划，但我对缺乏清晰沟通感到沮丧”时，传统基于关键词匹

配或浅层特征提取的方法难以理解这种复杂的情感混合与转折，导致对公众意见的过度简化解读^[5]。其次，情感标注的高成本与一致性问题。网络问政文本的多样性与专业性（包含政策术语、行政程序和专业领域知识）使得高质量标注数据的获取极为困难，阻碍了深度学习模型的有效训练。最后，情感类别极度不平衡问题。政务语境下，公众诉求中某些情感（如“焦虑”和“愤怒”）出现频率远高于其他情感（如“满足”和“期待”），这种特殊的不平衡分布严重影响模型的泛化能力与识别精度^[6]。

大语言模型（large language models, LLM）的出现为解决上述挑战提供了新的技术路径。LLM凭借其强大的上下文理解能力和知识储备，能够整体把握网络问政文本的语义结构与情感表达^[7]。但将LLM应用于政务领域时，仍面临“幻觉”现象（即生成与事实不符的内容）和领域适应性问题^[8]，尤其是在处理包含大量专业术语和政策内容的问政文本时，这些挑战更为突出，需要有针对性地解决。

针对上述挑战，本研究提出了一种基于大语言模型的网络问政文本细粒度情感分析多阶段优化方法。首先，该方法基于情绪唤醒度-效价理论^[9]构建适合网络问政场景的多维情感体系，设计包含8个情绪区间和56个具体标签的细粒度分类框架；其次，创新性地将GPT-4（generative pre-trained transformer 4）与Claude 3.5 Sonnet相结合，构建标注质量评估与优化机制，有效解决了大语言模型在特定领域应用中的“幻觉”问题；最后，开发了基于大语言模型的数据均衡策略，针对政务文本中特定情感类别过度集中的问题，实现了更为平衡的类别分布。实验结果表明，该方法在网络问政数据集上取得了显著成效，F1值平均提高了21.65%。

本研究的创新贡献主要体现在3个方面。①理论创新：首次将情绪唤醒度-效价理论与大语言模型能力相结合，构建了适用于网络问政场景的细粒度情感分析框架，为精细化治理提供了理论基础；

②方法创新：提出了“大语言模型标注-专家评估-研判模型训练-多阶段优化”的标注框架，有效解决了大语言模型在领域应用中的“幻觉”问题，提高了标注质量与效率；③技术创新：设计了利用大语言模型生成能力解决类别不平衡问题的数据平衡框架，提高了情感识别模型的泛化能力。这些创新不仅推动了自然语言处理技术在政务领域的应用深化，也为基于大语言模型的高质量数据标注与优化提供了新范式。

1 相关工作概述

1.1 文本细粒度情感分析研究

文本细粒度情感分析的理论基础可追溯至 Russell^[9]于1980年提出的情绪唤醒度-效价理论（arousal-valence theory of emotion）。该理论通过唤醒度（情绪强度）和效价（情绪正负性）两个维度构建了系统的情感空间，为情感的精确刻画提供了科学框架。Bradley等^[10]开发的国际情感图片系统（international affective picture system, IAPS）和Barrett等^[11]提出的“核心影响”概念进一步验证了理论的有效性。在社交媒体领域，Preoticiu-Pietro等^[12]将该理论应用于Twitter数据分析，Mohammad等^[13]构建了基于唤醒度-效价维度的大规模情绪词典，展示了理论在文本分析中的实践价值。这些基础性研究为深度学习模型的设计和 optimization 指明了方向。

随着深度学习技术的发展，研究者在情绪维度理论指导下开发了一系列创新模型。陶林娟等^[14]提出的融合BERT（bidirectional encoder representations from transformers）词语表征模型通过引入情绪维度特征，在Restaurant和Laptop领域分别达到85.54%和80.35%的准确率。Li等^[15]开发的GloVe-CNN-BiLSTM（global vectors for word representation - convolutional neural network - bidirectional long short-term memory）架构创新性地结合静态词向量与动态特征提取，实现了对不同强度和效价情感的精确识别，准确率超过95%。在长文本处理方面，Zhang等^[16]提出的语义图双向编码表示方法（semantic graph bidirectional encoder representations from transformers, SG-BERT）通过构建包含情绪维度的语义图谱，提升了对复杂情感表达的理解能力。高玮军等^[17]开发的多视角情感分析网络则通过深度融合注意力机制和情绪维度特征，增强了模型对上下文依赖关系的捕捉能力。这些技术创新不仅提高了分析

精度，也为处理不同场景下的情感表达提供了可靠工具。

在模型创新的基础上，领域知识构建和多模态融合成为提升细粒度情感分析效果的关键途径。Buechel等^[18]提出的基于唤醒度-效价的多模态情感分类方法实现了文本、音频和视频特征的有效融合，为跨模态情感分析提供了新思路。蒋昊达等^[19]在此基础上提出改进的领域情感词典构建方法，通过整合多维度特征，在特定领域取得显著成果。李大宇等^[20]探索的表情符号远监督标注策略不仅降低了人工标注成本，更为构建高质量情感数据集提供了新范式。在低资源语言方面，公确多杰等^[21]的藏语情感词典构建工作拓展了知识构建的范围，为解决数据稀缺问题提供了有效方案。这些研究在丰富领域情感知识体系的同时，也推动了情感分析技术在不同应用场景中的落地。

细粒度情感分析研究虽取得显著进展，但仍面临3个关键挑战：首先，现有研究多关注情感的单一维度或简单分类，未能充分结合具体语境的复杂性构建多维情感体系；其次，政务文本标注资源稀缺且质量参差不齐，亟须构建高效、可靠的标注方法；最后，网络问政文本中情感分布的极度不平衡（如负面情感占比过高）严重影响模型性能。针对这些挑战，本研究探索利用大语言模型的潜力，提出政务文本情感分析的多阶段优化方法。

1.2 大语言模型文本生成研究

近年来，大语言模型在文本生成领域取得了显著进展，为网络问政文本细粒度情感分析提供了新的技术路径。通过对已有研究的系统梳理发现，大语言模型在文本生成方面的能力主要体现在3个与本研究关联紧密的方向：情感标注数据生成、质量评估与“幻觉”控制，以及特定领域文本生成与增强。

在情感标注数据生成方面，研究者致力于利用大语言模型的生成能力解决标注资源稀缺问题。Wu等^[22]提出的基于门控专家混合微调（gated mixture-of-experts fine-tuning, GMoEF）的方法，通过引导大语言模型生成带情感标签的文本，显著提升了标注数据的质量和多样性，该技术为解决网络问政文本标注资源有限的挑战提供了思路。Qu等^[23]将混合文本边界检测任务转化为生成式任务，使大语言模型能识别并标注文本中的情感转折点，这对于处理网络问政中公众表达复杂情感变化的长文本

尤为适用。Kyriakou 等^[24]通过组合多种预训练模型的生成结果，构建了更准确的情感标注系统，这种方法为政务文本中微妙情感差异的标注提供了可靠途径。这些研究为利用大语言模型进行政务文本情感标注奠定了基础，但尚未专门针对网络问政文本的特殊性进行优化。

在质量评估与“幻觉”控制方面，研究者探索了多种技术路径以确保大语言模型生成内容的可靠性。刘华玲等^[25]通过提示工程、检索增强生成和智能体技术的组合应用，显著降低了大语言模型在情感标注中的幻觉现象，这对处理包含专业政务术语的网络问政文本尤为重要。袁毓林^[26]深入研究了 ChatGPT 等大语言模型的知识获取机制，揭示了其通过训练语料学习世界知识的过程，为理解大语言模型在政务领域可能出现的知识盲点提供了理论基础。Callan 等^[27]研究发现，尽管基于 Transformer 的语言模型显著提升了生成文本的质量，但人类评价与自动评分之间仍存在差异，表明在政务文本情感标注中引入人类专家评估的必要性。这些研究揭示了仅依靠单一大语言模型进行政务文本情感标注面临的质量挑战，为本研究提出多阶段优化框架提供了理论支持。

在特定领域文本生成与增强方面，大语言模型展现出强大的领域适应能力，但也凸显了政务文本处理的独特挑战。马灿等^[28]提出的基于多输入中文拼写纠错方法，通过 LoRA (low-rank adaptation) 微调技术显著提升了处理非标准表达的能力，这对理解网络问政中公众多样化表达方式至关重要。李居昊等^[29]针对社交媒体文本立场检测问题，提出了包含明确任务指令的检测模板，这种方法可直接用于指导大语言模型识别网络问政文本中的情感立场。关威等^[30]开发的业务流程语义异常检测方法 (LLM-based business process semantic anomaly detection framework, SemAD) 在泛化能力方面表现优异，为检测网络问政文本中的异常情感表达提供了技术支持。此外，Wei^[31]、Shin 等^[32]及林佳瑞等^[33]在特定领域文本生成研究中的成果表明，大语言模型需要特殊的领域适应训练才能处理好特定领域的文本生成任务，这对于网络问政这类包含大量政策术语和行政程序内容的文本尤为重要。

系统梳理上述研究可见，大语言模型的文本生成能力在解决网络问政文本细粒度情感分析的三大挑战方面具有巨大潜力：首先，其强大的上下文理解能力可用于把握政务文本中复杂的情感表达；其

次，通过精心设计的提示工程和多模型协作，可以提高情感标注的质量和效率；最后，其文本生成能力可用于增强少数类样本，缓解政务文本中情感类别严重不平衡的问题。然而，大语言模型在网络问政文本中仍面临特殊挑战，尤其是处理政策术语、理解行政程序和捕捉隐晦情感表达时容易产生“幻觉”，导致标注不准确。此外，如何设计高效的提示策略引导大语言模型精准理解政务语境中的情感表达，如何建立多阶段质量控制机制以确保生成内容的可靠性，是应用大语言模型进行网络问政文本情感分析亟须解决的问题。因此，本研究提出结合多种大语言模型优势的多阶段优化方法，既能发挥大语言模型的文本生成能力用于高质量情感标注和数据均衡，又通过创新的质量控制机制解决了政务领域特有的“幻觉”问题。

2 研究方法与设计

本研究提出一种基于大语言模型的网络问政文本细粒度情感分析框架，该框架由 3 个相互关联的核心模块构成。

首先，为了获取初步的情感标注结果，开发基于 GPT-4 的自动标注模块 (2.1 节)。该模块对原始未标注数据进行处理，并将标注数据按 4:6 划分为验证集和训练集，为后续模型训练奠定基础。

其次，为了确保标注数据的质量和可靠性，设计高质量数据集构建与优化模块 (2.2 节)。该模块利用 Claude 3.5 Sonnet 模型对验证集进行标注校正，并引入专家团队进行人工审核。基于专家团队的二元判定结果，训练一个标注质量评估模型。随后，将这一流程应用于训练集：先由 Claude 3.5 Sonnet 进行校正，再由质量评估模型筛选可靠标注。为了解决数据类别不平衡问题，创新性地采用 Claude 3.5 Sonnet 进行数据增强，通过生成式方法补充稀缺类别样本，最终构建一个均衡的高质量数据集。

最后，为了选择最适合网络问政文本情感分析任务的模型架构，开发模型构建与评估模块 (2.3 节)。该模块实现了多种深度学习模型，包括 RoBERTa (robustly optimized BERT pretraining approach)、BiLSTM (bidirectional long short-term memory)、RoBERTa-BiLSTM 融合模型以及 CNN (convolutional neural network)，并在构建的均衡数据集上进行全面的性能评估。这 3 个模块有机结合，构成了一个完整的分析框架，如图 1 所示。




图1 研究思路框架

2.1 基于大语言模型的细粒度情感标注方法

随着自然语言处理技术的快速发展,文本情感分析在社交媒体分析、用户意见挖掘等领域发挥着越来越重要的作用。然而,传统的情感分析方法往往局限于粗粒度的分类(如正面、负面、中性),难以捕捉文本中丰富的情感细节。为此,本研究提出一种基于大语言模型的文本情感细粒度标注方法论框架(图2)。

为了实现准确的情感识别,首先,构建一个完整的细粒度情感标签体系(2.1.1节),该体系系统地定义了文本中可能出现的各类情感类型及其

层次关系。基于这一标签体系,进一步设计针对大语言模型的专门化提示策略(2.1.2节),以确保模型能够准确理解和应用这些细粒度情感标签。

2.1.1 基于情绪唤醒度-效价理论的多维情感标签体系构建

本研究基于Russell的情绪环形模型,构建了适用于网络问政文本的多维情感标签体系。针对网络问政场景的特殊性,考虑从以下3个维度建立情感分类体系。

首先,基于Scherer^[34]的评估理论,将情感维度细分为8个区间,用于准确捕捉网络问政文本中的




图2 基于大语言模型的文本细粒度情感标注框架

多层次情感表达与治理效能评价。其次，借鉴 Bradley 等^[35]的情感评价研究，在唤醒度维度采用四级层次划分，有效区分如“愤怒”与“失望”等问政语境中的差异化情感强度。最后，考虑到网络问政文本中情感极性的复杂性，在效价维度采用精细化正负划分。具体如表 1 所示。

表 1 多维情感标签体系

情感区间	唤醒度	效价	情绪标签示例	文献来源
高唤醒度正性	高	高正	兴奋、激动、欢欣、狂喜、着迷、惊喜、热血	[36-37]
中高唤醒度正性	中高	中高正	愉悦、开心、快乐、满意、自豪、乐观、欢快	[38-39]
中性唤醒度正性	中	低正	和煦、放松、满足、舒适、自信、期待、惬意	[40-41]
低唤醒度正性	低	微正	安心、悠闲、淡定、平静、知足、温馨、恬静	[42]
高唤醒度负性	高	高负	焦虑、恐慌、愤怒、绝望、崩溃、震惊、鄙夷	[43]
中高唤醒度负性	中高	中高负	厌恶、沮丧、悲伤、懊恼、烦躁、悲观、恐惧	[44-45]
中性唤醒度负性	中	低负	低落、失望、郁闷、忧虑、紧张、困惑、无奈	[46-47]
低唤醒度负性	低	微负	疲倦、孤独、倦怠、冷漠、麻木、消沉、乏味	[48]

本研究构建的细粒度情感标签体系具有 3 个层次的精细化特征。①维度细分：基于唤醒度和效价 2 个维度的交叉组合，将传统的“正负性”二元划分扩展为 8 个情绪区间，实现了情感强度和方向的双重细化；②标签精细：在每个情绪区间内进一步细分为 7 个具体情绪标签，总计 56 个标签，相比于传统方法的 3~5 个标签，精细度显著提升；③语境适应：针对网络问政文本的特殊性，选择能够准确反映政民互动中公众心理状态的情绪标签，如“困惑”“期待”“无奈”等，解决了通用情感词典在政务语境下的适用性不足问题。

2.1.2 基于 BROKE 框架的大语言模型提示工程

为确保 2.1.1 节中大语言模型标注的情感数据集的质量，提高标签的准确性和一致性，本研究基于 BROKE 框架设计了情感标注路径。在 BROKE 框架的指导下，利用 GPT-4 在常识推理和知识补全方面的优势进行初步数据标注。BROKE 提示工程框架包含背景（background，B）、角色（role，R）、目标（objectives，O）、关键结果（key result，K）和演化（evolve，E）要素。表 2 详细展示了在分类任务中，基于 BROKE 框架的大语言模型标注阶段的 prompt 设计和应用情况。

表 2 标签标注路径在不同任务中的设计与应用

任务环节	prompt 设计核心模块
大语言模型情感标注：使用 GPT-4 对原始数据集划分情感空间和情绪标签标注	(1)任务背景：从“人民网_网上的人民日报”互动模块的领导留言板模块(或中国深圳市人民政府网站的政民互动模块的领导信箱模块)下载一个公开的公众进行网络问政的数据集，该数据集是公众表达的诉求，希望自己的诉求能够得到解决。 (2)角色设定：假设你现在是发表这个诉求文本的人，请回忆你发表该动态时的情感和情绪。 (3)目标要求：对于每一条诉求文本，输出格式如下： - 原始诉求：“该部分为原始诉求内容”； - 该文本包含情绪：[情绪 1(情绪区间 1)，情绪 2(情绪区间 2)，……]； - 核心情绪：情绪 1(情绪区间 1)； - 该文本的情绪区间是否均来自给定的参考区间：是/否； - 给出的情绪标签是否均来自上述具体的情绪标签的示例：是/否。 (4)规则与示例：对于每一文本，请根据以下 8 个情感区间和每个区间的情绪标签，将每条诉求划分到合适的情感区间：{emotion_rules}。 (5)问题输入：原始诉求文本：“{emotion_text}”。

2.2 情感标注数据的多阶段获取与优化方法

本节提出一种创新的多阶段方法,用于进一步优化和提高大语言模型标注的数据质量。该方法融合了大语言模型的智能处理能力和人类专家的专业判断,通过系统化的流程提高情感标注的准确性和可靠性。

2.2.1 多阶段研判模型构建与高质量数据筛选

为构建能够准确评估情感标注质量的研判模型,本研究设计以下多阶段流程。

步骤 1. 从 2.1.2 节经大语言模型标注的数据集中随机抽取 40% 作为初始样本。该抽样策略确保了样本的代表性和多样性。

步骤 2. 基于标注结果的规则矫正。考虑到大语言模型可能产生的“幻觉”,本研究基于 BROKE 框架的基准测试思想,对已建立的情感标签体系进行系统化评估,并据此对初步标注结果进行规则矫正,确保最终标签符合预定义的情感区间和情绪标签。表 3 为基于 BROKE 框架实现审核与纠偏任务的 prompt 要素。

表 3 大语言模型进行审核与纠偏的 prompt 要素

任务环节	prompt 设计核心模块
基于标注结果的规则矫正: Claude 3.5 Sonnet 对大语言模型标注结果的审查、矫正	(1)任务背景:现在针对网络问政数据集进行情感标签的审核与修正。该数据集已具有情感标签,你需要依据以下规则对原始情感标签进行审查、修正和纠偏,给出最符合该诉求文本的情感标注。 (2)角色设定:你现在是心理学和情感分析专家,请对以下数据的情感进行精准的标注。 (3)目标要求:对于每一条诉求文本,输出格式如下: - 原始诉求:“该部分为原始诉求内容”; - 经审查后的情绪:[情绪 1(情绪区间 1),情绪 2(情绪区间 2),……]; - 经审查后的核心情绪:情绪 1(情绪区间 1); - 原始的情感标注是否合理:是/否; - 您是否进行了纠正:是/否。 (4)规则与示例: - 对于每一条文本,请根据以下 8 个情感区间和每个区间的情绪标签将每条诉求划分到合适的情感区间:{emotion_rules}; - 每一条诉求文本现在均有情感标注,情感标注包括情感区间和情绪标签,请对诉求文本现有的情感区间和情绪标签进行重新审查,不合理就进行纠正,合理就重新复述一遍原始诉求和原始情感标注结果; - 输出格式包括原始诉求文本、经审查后的情绪、经审查后的核心情绪、该文本的原始情感标注是否合理、您是否进行了纠正; - 不需要展示每条动态的情绪分析的过程,直接按照输出格式要求输出即可; - 情绪标签并不是提取诉求文本中的词汇短语,而是对文本情绪表达的理解。 (5)问题输入:原始诉求文本:“{emotion_text}”;原始诉求标注:{total_emotion}。

步骤 3. 专家团队评估。由跨学科的专家团队对大语言模型审核后的结果开展进一步评估,专家团队由以下成员组成:2 位南京大学信息资源管理领域博士生导师、1 位南洋理工大学信息科学博士生导师、2 位南京大学情报领域博士研究生、1 位南京大学情报领域硕士研究生。这种多元化的专家团队构成基于 Surowiecki 的“群体智慧”理论^[49],旨在结合不同的专业视角,提高评估的全面性和准确性。

步骤 4. 专家团队针对规则矫正的结果进行审查。专家团队针对大语言模型审核、纠偏后的标注是否正确,赋予数据记录二分类标签,即人工为每条数据赋予二分类标签:标签 0 表示大语言模型标

注正确,标签 1 表示大语言模型标注错误。

采用二分类标签的原因是基于 Occam’s Razor 原则^[50],即在保证效果的前提下选择最简单的方法。这不仅简化了评估过程,也为后续研判模型提供了明确的学习目标。

步骤 3 和步骤 4 是专家团队的第一次参与,作用是判断大语言模型审核的准确性,为研判模型提供训练数据。

步骤 5. 研判模型的训练。使用步骤 4 中经人工标注的二分类数据集训练研判模型。因 RoBERTa 在文本分类任务表现出色,本研究采用基于 RoBERTa 的二分类模型^[51-52]。数据集按 8:2 划分为训练集和测试集,以确保模型的泛化能力。

通过步骤 5 构建的研判模型对剩余 60% 的数据集进行质量评估，以获取高质量标注数据集。具体实现步骤如下。①应用研判模型：对每条数据进行分类，识别出大语言模型标注正确的数据记录；②高质量标注数据集的筛选：将研判模型判定为正确的数据与步骤 4 中专家团队确认大语言模型标注正确的数据合并，最终形成高质量标注数据集。这种方法的创新性在于它结合了机器学习的效率和人类专家判断的准确性，能够大规模地识别和筛选高质量的情感标注数据。步骤 5 是专家团队的第二次参与，在研判过程中，中等置信度的数据需要人工审核，以保证数据标注的准确性。

2.2.2 大语言模型驱动的数据增强工程

尽管本研究通过多阶段方法构建了高质量的标注数据集（2.2.1 节），但数据集中各情感类别的样

本分布呈现显著不平衡现象，这种不平衡可能会降低情绪识别模型的性能表现。

为此，本研究提出基于大语言模型的数据均衡策略。该策略的优势是能够在保持数据真实性和多样性的同时，提升模型在各情感类别上的识别能力，具体实现过程如下。①基于现有情感类别的统计分析：对高质量标注数据集进行类别分布分析，识别样本数量不足的类别。②基于小样本情感类别的数据生成：使用 Claude 3.5 Sonnet 为样本不足的类别生成新的诉求文本。本研究设计了特定的 prompt，如表 4 所示，以确保生成的文本符合目标情感类别和语境。③质量筛选与控制：使用研判模型对生成的数据进行筛选，只保留模型判定为“正确”的样本。④迭代优化：重复②和③，直到各类别样本数量达到平衡。

表 4 数据均衡中 prompt 设计的核心模块

任务环节	prompt 设计核心模块
数据均衡工程：使用 Claude 3.5 Sonnet 生成小样本情感类别的诉求文本	(1)任务背景：现在的任务是对已具有情感标签类别的数据进行数据扩展。 (2)角色设定：假设你在人民政府网站给市长写信，希望能够得到政府领导或者相关机构帮助自己解决问题。 (3)目标要求：给出具有和原始诉求情绪标签相同的诉求文本。 (4)规则与示例： - 每一条原始诉求文本，会被划分至以下的 8 个情感区间和 56 个情绪标签； - 请以公众的视角，基于原始诉求的情绪标签：{emotion_label} 给出 6 个诉求文本； - 生成的诉求文本具有和原始诉求同样的情绪标签； - 对于每一条诉求文本，输出结果中需要有 2 个部分内容：原始诉求的情绪标签和诉求文本。 (5)问题输入： - 原始诉求的情绪标签：{emotion_label}

本研究选择 Claude 3.5 Sonnet 进行数据生成的技术原理如下：首先，Claude 3.5 Sonnet 在文本生成任务中表现出更好的可控性和一致性，能够根据指定的情感标签生成符合要求的政务文本；其次，该模型具有更强的领域适应能力，通过精心设计的 BROKE 框架提示，能够生成既符合网络问政文本特征又具有目标情感特征的高质量样本；最后，Claude 3.5 Sonnet 在生成文本的多样性和真实性方面平衡较好，避免了简单重复或脱离现实的生成内容。

2.3 网络问政文本细粒度情感识别模型

高质量数据集的标注过程（2.1 节和 2.2 节）涉及复杂的标注流程和验证机制，需要投入大量人力物力资源。特别是在大语言模型接口调用方面，标

注过程产生了显著的资源支出。为提升网络问政文本情感分析的效率和可扩展性，亟须开发一个自动化的细粒度情感识别模型。该模型以公众诉求文本为输入，直接输出细粒度情感标注结果，可有效降低人工标注成本。

本节基于已构建的高质量数据集，重点完成两项核心任务：一是经典分类模型的选型，筛选和确定适用于网络问政场景的情感分类模型；二是实验方法与评估体系的构建，建立科学完备的模型评估框架。

2.3.1 深度学习模型架构设计

为构建高效准确的情感识别模型，本研究实现了 5 种具有代表性的深度学习模型架构。这些模型采用模块化设计，包含特征提取、信息融合和分类预测等关键环节。表 5 详细对比了各模型的特点。

表 5 5 种情绪识别模型的选择依据与特点对比

模型名称	模型特点与优势	文献来源
RoBERTa	优秀的语义区分能力,适合处理细粒度的情感类别划分;强大的上下文理解能力,能够准确捕捉问政文本中的细微情感差异;通过预训练获得的丰富语义知识,有助于理解较为正式的问政用语。	[52-53]
CNN	擅长提取局部文本特征,可识别问政文本中的情感词组和关键词语;并行计算效率高,适合处理大规模问政数据;通过多通道卷积核设计,可同时捕获多个粒度的类别特征。	[54-55]
BiLSTM	双向信息处理有助于理解问政文本中的语境依赖关系;长期记忆机制适合捕捉长文本中的情感变化和转折;序列建模能力强,适合处理结构化的政务诉求文本。	[56-57]
RoBERTa-CNN	结合 RoBERTa 的语义理解和 CNN 的特征提取优势;适合处理问政文本中的多层次情感特征;模型结构灵活,可针对几十种类别进行特征优化。	[58-59]
RoBERTa-BiLSTM	整合 RoBERTa 的语义表示和 BiLSTM 的序列建模能力;特别适合处理长篇幅的问政文本;层次化特征提取有助于区分相近情感类别。	[60-61]

2.3.2 模型评估框架

本研究设计了系统的实验评估框架,包括数据集构建、评估指标选择和超参数优化策略 3 个维度。具体实验设计如表 6 所示。

实验框架的要素如下。

(1) 数据集构建:训练集包含 29413 条公众诉求数据,其中,来源于深圳市人民政府-领导信箱模块(简称 SZLM) 16196 条,来源于人民网留言板-深圳市模块(简称 SZPD) 13217 条,时间跨度为 13 个月。测试集包含 5882 条数据,分别从 SZLM 和 SZPD 等比爬取 3239 条和 2643 条诉求数据。

(2) 评估体系:模型性能评估采用精确度、准

确度和 F1 值 3 个互补指标,以全面评估模型性能。其中,精确度反映预测准确性,准确度体现整体表现,F1 值适用于类别不平衡场景。

(3) 参数优化:通过网格搜索方法优化学习率、批次大小、训练轮次和 dropout 率等关键参数。对于基于 RoBERTa 的模型,固定预训练参数以平衡计算效率和性能。最终根据验证集 F1 值选择最优参数组合。

(4) 人工标注过程共有 2 名标注成员参与,分别为南京大学信息资源管理领域的 1 名博士研究生和 1 名硕士研究生,要求一致性检验的 Cohen's kappa 系数达 0.81 以上。

表 6 情感识别模型的实验设计

设计因素	设置说明
数据集划分	- 训练集数据来源:时间跨度为[2022-12-31, 2024-01-01],数据量为 29413 条; - 测试集数据来源:时间自 2024-01-01 起始,数据量为 5882 条。
评估指标	- 精确度(precision):预测为正类的样本中,真正为正类的比例; - 准确度(accuracy):预测正确的样本占总样本的比例; - F1 值(F1-score):精确度和召回率的调和平均数; - Cohen's kappa 系数:人工审核标注一致性测量的 Cohen's kappa 系数大于等于 0.81。
超参数搜索	- 学习率: {2e-2, 2e-3, 2e-4, 2e-5}; - 批次大小(batch size): {16, 32, 64}; - 训练轮次(epoch数): {10, 20, 30, 50}; - dropout 率: {0.1, 0.2, 0.3}; - RoBERTa 相关模型:固定 RoBERTa 参数,只搜索上层 BiLSTM 或 CNN 的超参数; - 选择标准:在验证集上 F1 值最高的超参数组合。

3 实验与结果分析

本节通过系统化实验证明本研究方法的有效性。实验设计遵循“数据获取-质量优化-模型构建-性能评估”的研究框架,包含 4 个递进关系的实验

环节。先对深圳市两个主要网络问政平台的数据进行采集和预处理,并进行细粒度情感标注(3.1 节);为了解决大语言模型“幻觉”带来的错误标注,基于大语言模型初次标注数据,通过研判模型过滤得到高质量大语言模型标注数据(3.2 节);通

过对比单独使用大语言模型和多阶段优化方法两种路径的标注效果来验证多阶段标注方法的有效性（3.3 节）；通过对高质量标注数据进行数据增强得到数据均衡过的高质量大语言模型标注数据（3.4 节）；基于数据均衡过的高质量大语言模型标注数据，经过情绪识别模型训练出最优的情绪分类模型（3.5 节）。

3.1 数据集来源和预处理

本研究选取 SZLM 和 SZPD 两个具有代表性的网络问政平台作为数据来源。两个平台分别代表政府官方和主流媒体渠道，数据来源权威可靠，能真

实反映政民互动情况。数据集基本信息如表 7 所示。
从表 7 可以看出，SZLM 数据集源自政府官方网站，代表较为正式和权威的政民互动渠道，数据量达到 16196 条；而 SZPD 数据集来自主流媒体平台，涵盖了更广泛的公众诉求，数据量为 13217 条。这两个数据集的时间跨度一致，均为 2022 年 12 月 31 日至 2024 年 1 月 1 日。在情感标签的划分粒度上，两个数据集均划分为 8 个区间，对应 56 个情绪标签。在相同的情感粒度下，不同来源的数据集可以更加公平地比较本研究提出方法的性能表现，排除由情感标签差异导致的影响。

表 7 深圳市网络问政数据集基本信息

数据集名称	数据集内容	数据量/ 条	情感划分区间量/ 情绪标签量
深圳市人民政府- 领导信箱模块 (SZLM)	来自深圳市人民政府网站的互动交流模块的公众诉求数据,时间跨度为[2022-12-31, 2024-01-01];数据来源链接: https://www.sz.gov.cn/	16196	8/56
人民网留言板-深 圳市模块(SZPD)	人民日报为中央部委和地方各级党委、政府搭建的公众诉求平台,包括 10 个区级领 导、市长和市委书记,时间跨度为[2022-12-31, 2024-01-01];数据来源链接: https://liuy-an.people.com.cn/	13217	

3.2 研判模型性能评估

为确保获取高质量的情感标注数据，对研判模型性能进行严格评估至关重要。本研究采用多维度分析方法对不同模型进行全面评估。表 8 展示了 5 种模型在测试集上的详细性能指标对比。实验结果表明，在所有评估模型中，RoBERTa 模型表现最为出色，在准确度、精确度和 F1 值 3 个关键指标上分别达到 0.8354、0.8638 和 0.7915。相比之下，基础的 CNN 和 BiLSTM 模型性能相对较弱，而 RoBERTa 与 CNN、BiLSTM 的组合模型虽有所提升，但仍未超越单一 RoBERTa 模型的性能。基于这一综合性能评估，选择 RoBERTa 作为最终的研判模型。

表 8 各模型性能评估

模型	准确度	精确度	F1 值
CNN	0.7123	0.7356	0.6892
BiLSTM	0.7468	0.7651	0.7245
RoBERTa	0.8354	0.8638	0.7915
RoBERTa+CNN	0.8012	0.8234	0.7634
RoBERTa+BiLSTM	0.8145	0.8356	0.7723

注：粗体表示最优值；研判模型为二分类模型，所研判数据的情感细粒度类别数为 34 种。

研判模型的作用是快速评估大语言模型标注的正确性，提高专家人工审核的效率。尽管研判模型的各项性能指标并未超过 90%，但在研判的过程中结合置信度分析，可以在加速数据审核工作的同时极大地保障数据质量。基于研判模型的性能，本研究对 2.1 节单独使用大语言模型标注且未参与大语言模型审核与纠偏的剩余 60% 数据（17648 条）进行质量评估。采用分层策略分析模型的置信度分布，如图 3 所示。

对于置信度高于 0.9 的 14201 条数据，直接将其纳入高质量数据集；对于置信度在 0.7~0.9 的 2961 条数据，对其进行人工抽样审核，其中近 90% 通过了质量检验；而置信度低于 0.7 的 486 条数据被直接剔除。对 2.1 节单独使用大语言模型标注且参与模型纠偏和人工审核的 40% 数据进行整体统计，最终得到高质量情感标注数据集的构成，如表 9 所示。

多阶段的数据质量控制方法结合了人工专家判断和深度学习模型的优势，不仅显著提高了情感标注的质量，还大大提升了数据处理的效率。最终，数据集保留了原始数据的约 97%，既确保了数据质量，又很好地维持了数据的代表性和多样性。被剔




图3 分层策略下的部分高质量数据集来源

表9 高质量情感标注数据集的构成

数据来源	数据量/条	占总数据集(29413条)的比例/%
专家团队确认数据	11765	40.00
研判模型高置信度数据	14201	48.28
研判模型中等置信度通过审核数据	2541	8.64
总计	28507	96.92

除的约3%数据可能包含一些特殊或难以处理的案例，这可能导致最终模型在处理非常复杂或罕见的情感表达时表现不佳。

3.3 多阶段优化的细粒度情感标注实验

本节通过对比单独使用大语言模型（实验1）和多阶段优化方法（实验2）两种路径，验证多阶段标注方法的有效性。单独使用大语言模型指的是仅通过GPT-4对数据进行标注（2.1节）。多阶段优化方法指的是在2.1节基础上继续进行2.2.1节的操作，即通过分类模型过滤掉具有“幻觉”标注的数据，从而避免GPT-4“幻觉”直接进行数据标注带来的错误情况。结果表明，多阶段方法在精确度、准确度和F1值等指标上均优于单独使用大语言模型。

在深圳市人民政府-领导信箱模块（SZLM）和人民网留言板-深圳市模块（SZPD）两个数据集构成的整体数据集上进行两条标注实验路径的对比，实验结果如表10所示。为了开展本项实验，需要对3.2节获得的高质量数据集进行人工标注，标注准确性通过人工评估方式进行判断。评估工作由南京大学信息资源管理专业的2名研究生完成，包括1名博士研究生和1名硕士研究生。两位评估者之间的评分一致性系数达到0.87，表明人工评估具有较高的一致性。此处为第三次人工参与，为了验证本研究提出方法的有效性，需要对高质量数据集中专家团队未标注的数据进行标注，才能对实验1和实验2进行评估。

表10 情感标注实验路径效果对比

数据集	情感区间/个	情绪标签/个	评估指标	实验1	实验2
SZLM+SZPD	8	34	精确度	0.8511	0.9745
			准确度	0.7346	0.9692
			F1值	0.7773	0.9713

如表10所示，多阶段优化方法在模型性能上表现突出，精确度、准确度和F1值均优于单独使用大语言模型的组合，优化后的3项指标均达到0.97左右，较实验1分别高出约0.12、0.23和0.19。这表明使用多阶段获取与数据优化的方法能够更准确地进行情感标签的细粒度划分。此外，组合模型在泛化能力上也优于单独使用大语言模型。综合以上因素，多阶段优化方法是更优的选择。在已经证明多阶段优化方法有效性后，在3.4节数据均衡工程中，人工参与仅出现在研判模型中等置信度的数据标注中，预计不超过数据的20%，极大地提高了数据标注工程的效率。多阶段优化方法高效高质，在之后相同领域的迁移中能够提供方法上的参考依据。

从实验结果来看，虽然大语言模型在常识推理、知识补全等方面具有优势，但仍然存在一些局限性，例如，大语言模型会产生与情感标签体系脱节的情感标签。这表明在实际的情感分析任务中，仍然需要结合专业的情感理论和人工规则进行矫正和优化。本研究提出的多阶段高质量数据筛选方法通过融合大语言模型和多阶段规则矫正，能够更精确地对网络问政文本进行细粒度情感标注，减少了不必要的标签冗余，提高标注的

一致性和准确性，这样的结果也有利于后续情感分析任务的执行。

3.4 数据均衡工程实验结果分析

在 3.2 节中，本研究获得了包含 28507 条高质量标注数据的数据集。然而，初步分析发现这些数据在不同情感类别间的分布存在显著差异，情感类别差异较大势必会影响后续情感识别模型的性能。为此，本研究采用基于大语言模型的数据均衡策略，首先对原始数据集中各情感类别的分布进行统计分析，结果如表 11 所示。

表 11 数据增强前数据情感类别分布

情感类别	计数	占比/%	情感类别	计数	占比/%
困惑	8912	31.2	恐惧	27	<0.1
愤怒	7174	25.1	淡定	3	<0.1
焦虑	5839	20.5	兴奋	4	<0.1
忧虑	1807	6.3	冷漠	4	<0.1
无奈	1094	3.8	乐观	5	<0.1
期待	2296	8.0	崩溃	8	<0.1
失望	459	1.6	激动	4	<0.1
烦躁	290	1.0	倦怠	1	<0.1
沮丧	199	0.7	放松	1	<0.1
震惊	30	0.1	厌恶	15	<0.1
满足	36	0.1	疲倦	3	<0.1
平静	6	<0.1	郁闷	8	<0.1
满意	29	0.1	低落	1	<0.1
自豪	7	<0.1	恐慌	20	<0.1
紧张	39	0.1	温馨	5	<0.1
绝望	98	0.3	和煦	1	<0.1
悲伤	19	<0.1			
懊恼	63	0.2	总计	28507	100

从表 11 可以看出，多阶段组合方法获取的高质量情感标注数据集中存在明显的类别不平衡问题。困惑、愤怒、焦虑的情绪样本数量较多，占比分别为 31.3%、25.1%、20.5%；而平静、兴奋、放松等情绪样本数量极其少，这与网络问政文本的特点有关，因为网络问政文本通常是公众的投诉与不满。这种不平衡将导致情绪识别模型在训练过程中偏向于样本数量较多的类别，进而影响对少数类的识别能力。

为了解决这一问题，本研究采用基于 Claude 3.5 Sonnet 大语言模型的数据生成策略，具体步骤如下。首先，对于样本数量低于平均水平（839）的类别，使用大语言模型生成额外样本。生成过程中，本研究基于大语言模型调用的 BROKE 框架设计

了特定的 prompt，经过示例数据多次调试确定最终数据生成使用的 prompt，以此确保生成的文本符合目标情感类别和语境。其次，对于大语言模型新生成的文本数据，使用研判模型对生成的数据进行筛选，只保留被判定为“正确”的样本。重复上述操作，直至各类别样本数量接近平均水平。经过数据均衡处理后的网络问政数据集分布如表 12 所示。

表 12 均衡后数据集情感类别分布

情感类别	计数	占比/%	情感类别	计数	占比/%
困惑	2936	5.4	恐惧	1389	2.6
愤怒	2710	5.0	淡定	1359	2.5
焦虑	2339	4.3	兴奋	1324	2.4
忧虑	3331	6.1	冷漠	1318	2.4
无奈	2594	4.8	乐观	1229	2.3
期待	2296	4.2	崩溃	1190	2.2
失望	1971	3.6	激动	1186	2.2
烦躁	1784	3.3	倦怠	1183	2.2
沮丧	1603	3.0	放松	1177	2.2
震惊	1572	2.9	厌恶	1161	2.1
满足	1560	2.9	疲倦	1149	2.1
平静	1554	2.9	郁闷	1148	2.1
满意	1553	2.9	低落	1141	2.1
自豪	1537	2.8	恐慌	1046	1.9
紧张	1515	2.8	温馨	1019	1.9
绝望	1514	2.8	和煦	997	1.8
悲伤	1453	2.7			
懊恼	1413	2.6	总计	54251	100

通过数据均衡处理，成功地将各情感类别的样本数量调整到相近水平。值得注意的是，为了保持数据质量，本研究对原本样本数量较多的类别（如困惑、愤怒、焦虑）进行了适度删减，而不是单纯地增加少数类样本。这种策略既保证了数据集的平衡性，又避免了过度生成可能带来的质量风险。为了评估数据均衡的效果，分别从以下 4 个方面进行整体评估。①类别分布均衡度：使用基尼系数（Gini coefficient）来衡量类别分布的均衡程度。均衡前的基尼系数为 0.866，均衡后降低到 0.181，表明类别分布显著趋于平衡。②生成样本质量：对新生成的样本使用研判模型进行评估。结果显示，95.4% 的生成样本被认为符合目标情感类别且表达自然。这证明大语言模型在生成高质量、符合特定情感的文本方面具有出色能力。③语义多样性：使用余弦相似度来评估生成样本与原始样本之间的语义差异。结果显示，生成样本与原始样本的

平均余弦相似度为0.871,表明生成的内容既保持了与原始数据的相关性,又引入了新的表达方式,增加了数据集的多样性。④对模型性能的影响:本研究使用均衡前后的数据集分别训练了一个基础的RoBERTa分类模型,在相同的测试集上进行评估。结果如表13所示。

表13 数据均衡前后模型性能比较

均衡前后	准确度	精确度	F1值
数据均衡前	0.5800	0.5513	0.5480
数据均衡后	0.7424	0.7930	0.7567

表14 不同模型在测试集上的整体性能比较

分类数	评估指标	RoBERTa	CNN	BiLSTM	RoBERTa+CNN	RoBERTa+BiLSTM	最优模型
34	准确度	0.7985	0.7011	0.7120	0.6412	0.6492	RoBERTa
	精确度	0.8046	0.7496	0.7666	0.7178	0.6792	
	F1值	0.7995	0.7118	0.7278	0.6571	0.6547	

从表14可以看出,在准确度方面,RoBERTa模型展现了卓越的性能,其准确度达到了0.7985,明显高于CNN(0.7011)和BiLSTM(0.7120),表明RoBERTa在捕捉网络问政文本的复杂语义信息时表现更为优越。这主要得益于RoBERTa模型的深层上下文理解能力,能够更好地处理复杂情感之间的微妙差异。相比之下,CNN和BiLSTM虽然在捕捉文本局部特征和序列信息方面具有一定优势,但它们在处理长距离依赖和多层语义互动时不如Transformer架构的RoBERTa。在精确度方面,RoBERTa的得分为0.8046,远高于CNN(0.7496)和BiLSTM(0.7666),凸显了其强大的特征提取能力。在F1值方面,RoBERTa依然表现最佳(0.7995)。相比之下,CNN(0.7118)和BiLSTM(0.7278)的F1值较低,表明这两种模型虽然在某些情感类别上可能表现较好,但在全局平衡上未能达到RoBERTa的效果。

组合模型RoBERTa+CNN和RoBERTa+BiLSTM的表现低于预期,两者的准确度、精确度和F1值均未超过单独的RoBERTa,甚至在所有评估指标上均呈现劣势,尤其是准确度分别为0.6412和0.6492。这一结果可能反映了多模型融合在情感分类任务中面临的挑战。组合模型的理论基础在于整合不同模型的优势,但在实际应用中,RoBERTa的强大语义理解能力已经足够捕捉情感类别间的复杂关系,加入其他模型可能引入了噪声或增加了不必要的复杂性,反而影响了整体性能。

3.5 细粒度情感识别模型性能评估

本节采用多个模型对均衡数据进行训练,以此选取最佳细粒度情感识别模型。选择5种经典的深度学习模型参与实验:RoBERTa、CNN、BiLSTM、RoBERTa+CNN和RoBERTa+BiLSTM。为确保公平比较,所有模型都使用相同的预处理步骤和训练参数。数据集被随机分为训练集(80%)和测试集(20%)。研究使用Adam优化器,学习率为 $2e-5$,批次大小为32,训练轮数为50。表14展示了5种模型在测试集上的整体性能。

本研究选取表现最佳的RoBERTa,探索其在每个情感类别上的表现,如表15所示。观察34个情感类别,可以看到在准确度、精确度和F1值的表现上,各类别之间存在一定的差异,如“绝望”“震惊”等情感类别表现较好,“焦虑”“无奈”等类别的表现相对较弱。同时,本研究按照8个情感区间和正负2类情感极性这2种情绪聚类方式进行分层分析,如表16和表17所示。将34种情感分为8个情感区间,可以看到,在不同唤醒度内,负性和正性情感的表现有所不同,并且随着唤醒度的增加,负性情感的表现逐渐减弱。在中性唤醒度情绪区中,负性情感的表现较好,而在其他区间中,正性情感可能表现更突出。但是,当将情感分为正性和负性两大类时,负性情感整体上表现更好,这可能是由于负性情感更容易被明确地定义和识别。分层分析的结果为理解情绪的内在结构提供了依据,同时,通过动态调整分类粒度,既可以减少混淆并增强跨领域的适应性,也证明了模型可以更灵活地适应不同下游任务。

综上所述,RoBERTa在网络问政文本情感分类任务中的优异表现,展示了其在处理复杂、多层次语义信息时的显著优势。尽管组合模型理论上能增强分类能力,但在此任务中,单独使用RoBERTa已经能提供最佳结果,模型组合反而可能因特征融合不足或复杂度增加而降低了性能。

表 15 模型在情感类别上的分类效果

类别	准确度	精确度	F1 值	类别	准确度	精确度	F1 值
困惑	0.6827	0.6028	0.6402	悲伤	0.9324	0.9740	0.9527
愤怒	0.5858	0.7907	0.6730	厌恶	0.8724	0.7833	0.8254
焦虑	0.2330	0.1352	0.1711	崩溃	0.7581	0.7692	0.7636
期待	0.5817	0.6482	0.6132	郁闷	0.9176	0.8298	0.8715
忧虑	0.6040	0.5557	0.5789	自豪	0.9650	0.9612	0.9631
无奈	0.4908	0.5661	0.5258	平静	0.9660	0.9419	0.9538
失望	0.8148	0.7230	0.7662	乐观	0.8023	0.8903	0.8440
烦躁	0.7306	0.6867	0.7079	温馨	0.7991	0.9015	0.8472
沮丧	0.7676	0.8257	0.7956	激动	0.8512	0.8243	0.8375
绝望	0.9851	0.9940	0.9895	冷漠	0.8552	0.8791	0.8670
懊恼	0.7918	0.7365	0.7632	兴奋	0.9045	0.9660	0.9343
紧张	0.7632	0.7273	0.7448	淡定	0.8992	0.9345	0.9165
满足	0.7340	0.8651	0.7942	疲倦	0.8828	0.8178	0.8491
震惊	0.9968	0.9813	0.9890	低落	0.8745	0.8938	0.8840
满意	0.8797	0.8323	0.8554	放松	0.7767	0.9027	0.8350
恐惧	0.8362	0.8451	0.8406	和煦	0.9034	0.9167	0.9100
恐慌	0.9091	0.9365	0.9226	倦怠	0.8011	0.7178	0.7572

表 16 模型在 8 个情感区间上的分类结果

类别	准确度	精确度	F1 值
高唤醒度负性情绪区	0.8080	0.8326	0.8201
高唤醒度正性情绪区	0.8782	0.8925	0.8853
中高唤醒度负性情绪区	0.8259	0.8083	0.8170
中高唤醒度正性情绪区	0.8828	0.8902	0.8865
中性唤醒度负性情绪区	0.8332	0.7857	0.8088
中性唤醒度正性情绪区	0.6984	0.7810	0.7374
低唤醒度负性情绪区	0.8752	0.8311	0.8526
低唤醒度正性情绪区	0.8889	0.9272	0.9076
总体数据	0.8363	0.8436	0.8394

表 17 模型在正负极性情绪区间上的分类结果

类别	准确度	精确度	F1 值
负性情感	0.9507	0.9283	0.9394
正性情感	0.8308	0.8799	0.8547
总体数据	0.8908	0.9041	0.8970

4 研究结论与研究价值

4.1 研究结论

本研究融合大语言模型与传统机器学习方法，构建了网络问政文本细粒度情感分析的多阶段优化框架，系统解决了复杂语境理解、高质量标注获取与类别不平衡三大科学挑战，为政府部门精准把握民意提供了有效工具。基于实验结果和系统分析，

本研究得出以下 3 个主要结论。

（1）多维度情感标注体系显著提升了网络问政文本分析的精度和深度。基于情绪唤醒度-效价理论构建 8 个情绪区间和 56 个情绪标签体系，成功突破了传统二元或三元情感分类的局限性。这一细粒度情感框架能够准确捕捉网络问政文本中“焦虑”与“愤怒”、“期待”与“失望”等细微情感差异，实现了对情感强度和极性的精确刻画。研究结果表明，本研究提出的情感分析方法在 F1 值上较现有方法平均提高了 21.65%，在情感分析任务中达到 89.70% 的平均准确度，充分证明了多维度情感标注体系在处理复杂叙事型政务文本时的优越性。

（2）大语言模型辅助标注结合多阶段优化策略解决了高质量数据获取难题。本研究设计的“大语言模型标注-专家评估-研判模型训练-多阶段优化”框架，在保证标注质量的同时提高了效率。通过科学的提示工程设计，GPT-4 在初始标注阶段展现出卓越性能。为解决大语言模型可能产生的“幻觉”问题，研究创新性地引入 Claude 3.5 Sonnet 进行审核纠偏，并结合 RoBERTa 研判模型构建质量评估机制，将标注数据的质量显著提升。研究结果表明，本研究方法比基准模型在标注质量评估中提高了 27.96%，这种差异化大语言模型组合与多阶段优化策略不仅提高了标注质量与效率，也为大语言模型在专业领域应用中的“幻觉”问题提供了系统性解决方案。

（3）基于大语言模型的数据均衡策略有效解决了情感类别不平衡问题，显著提升了模型的泛化能力。本研究分析发现，初始数据集中“困惑”“愤怒”“焦虑”3 类情感样本占比分别为 31.3%、25.1% 和 20.5%，而很多情感类别样本量不足 1%，严重影响模型性能。对此，本研究创新性地采用 Claude 3.5 Sonnet 生成补充样本，并利用研判模型进行质量筛选，成功实现了情感类别的均衡分布。数据均衡后，模型的表现获得了显著提升，在准确度、精确度和 F1 值 3 项指标上均有明显改善。如表 13 所示，均衡后的模型准确度从 0.5800 提升至 0.7424，精确度从 0.5513 提升至 0.7930，F1 值从 0.5480 提升至 0.7567，为实现网络问政文本的精准情感分析奠定了坚实基础。

这 3 项研究结论证明了大语言模型在网络问政文本细粒度情感分析中的巨大潜力，为解决自然语言处理领域的的数据质量控制与类别不平衡问题提供了新思路。研究成果为政府部门理解公众情感需

求、优化政务响应策略、提升治理精细化水平提供了理论指导和技术支持。

4.2 研究价值

本研究构建的基于大语言模型的网络问政文本细粒度情感分析框架,不仅丰富了情感计算理论与技术方法,也为提升政府治理能力提供了实用工具。本研究的理论价值在于丰富和拓展了大语言模型驱动的情感分析理论体系,为政务文本的精细化理解与情感演变分析提供了新的研究视角和方法论框架,具体内容如下:

第一,丰富了情绪理论在政务文本分析中的应用范式。本研究基于情绪唤醒度-效价理论构建的细粒度情感分析框架,突破了传统二元或三元情感分类的局限,建立了包含8个情绪区间和56个标签的多维度情感分类体系。该体系不仅能够精确刻画网络问政文本中的复杂情感表达,也为其他领域的细粒度情感分析提供了理论支撑。研究证明,与简单情感极性分类相比,多维度情感体系能够更准确地反映公众心理状态,为深入理解政民互动过程中的情感动态提供了新视角。

第二,探索了大语言模型与传统机器学习方法融合的新路径。本研究提出的“大语言模型标注-专家评估-研判模型训练-多阶段优化”框架,不仅解决了大语言模型在专业领域应用中的“幻觉”问题,也为处理标注质量与模型训练效率之间的平衡提供了创新方案。这种结合人机协作的标注优化方法,为自然语言处理领域的的数据质量控制提供了新思路,对促进大语言模型在各专业领域的应用具有重要启示。

第三,拓展了情感演变动态分析的理论视野。本研究通过细粒度情感识别实现了对公众情感变化轨迹的精确刻画,为理解社会情绪的形成与演变机制提供了实证支持。这种动态视角下的情感分析方法,不仅丰富了情感计算的理论框架,也为社会心理学、公共管理学等领域研究公众情绪与社会治理关系提供了新工具。

本研究的应用价值在于为政府部门提供了基于细粒度情感分析的民意精准感知、风险预警和差异化服务决策支持,有助于实现政务服务的精细化管理和资源优化配置。主要体现在3个方面。

第一,为政府部门精准把握民意提供了技术支持。网络问政文本的细粒度情感分析能够区分“焦虑”与“愤怒”、“失望”与“无奈”等不同情感状

态,使政府部门能够更精准地理解公众诉求背后的心理需求,从而制定更有针对性的回应策略。这种情感分析能力的提升,有助于政府部门跳出传统的“问题-解决”简单思维模式,更加关注公众的情感体验和主观感受,从而提高治理的精细化水平。

第二,为社会风险预警提供了早期信号识别机制。本研究的细粒度情感分析方法能够捕捉公众情感从“忧虑”到“恐慌”、从“不满”到“愤怒”的演变过程,这一能力对预测潜在社会风险具有重要价值。政府部门可以通过监测特定议题上的情感强度变化,及时发现社会情绪波动异常,做到问题早发现、早干预,防止舆情风险的扩大化和失控。

第三,为政务服务优化提供了基于情感的决策支持。不同情感类型的诉求往往需要不同的处理策略和服务方式。通过细粒度情感分析,政府部门可以根据公众表达的情感类型,采取差异化的回应措施:对于表达“困惑”的诉求,可加强政策解释和信息透明;对于表达“愤怒”的诉求,则需要及时干预和问责跟进;对于表达“期待”的诉求,可提供进展报告和参与渠道。这种基于情感的差异化服务策略,有助于提升政民互动效能和公众满意度。

本研究提出的方法与思路,不仅适用于网络问政领域,也可推广至其他政务文本分析场景,如舆情监测、政策解读反馈分析、公共服务评价等。随着社会治理精细化、智能化要求的不断提高,细粒度情感分析将在数字政府建设中发挥越来越重要的作用,为实现“用数据说话、用数据决策、用数据管理、用数据创新”的智慧治理提供有力支撑。

4.3 不足与展望

尽管本研究取得了显著成果,但仍存在一些局限性。首先,当前研究主要基于中文网络问政文本,对其他语言和领域的适用性有待进一步验证。其次,所提出的方法对大语言模型资源的需求较高,可能限制了其在小型机构或资源受限环境中的应用。未来研究可以从以下2个方面展开:①结合知识图谱等外部知识,提高模型对特定领域情感表达的理解能力;②优化整个系统流程或选取性价比更高的大语言模型以降低资源需求,使其更适合在各种规模的机构中应用。

参 考 文 献

- [1] Akhtar M S, Gupta D, Ekbal A, et al. Feature selection and ensemble construction: a two-step method for aspect based senti-

- ment analysis[J]. Knowledge-Based Systems, 2017, 125: 116-135.
- [2] Li S S, Wang Z Q, Zhou G D, et al. Semi-supervised learning for imbalanced sentiment classification[C]// Proceedings of the Twenty-Second International Joint Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2011: 1826-1831.
- [3] Zhao J Q, Gui X L, Zhang X J. Deep convolution neural networks for Twitter sentiment analysis[J]. IEEE Access, 2018, 6: 23253-23260.
- [4] Sun S L, Luo C, Chen J Y. A review of natural language processing techniques for opinion mining systems[J]. Information Fusion, 2017, 36: 10-25.
- [5] Mao R, Ge M S, Han S, et al. A survey on pragmatic processing techniques[J]. Information Fusion, 2025, 114: 102712.
- [6] 颜学明, 黄翰, 金耀初, 等. 面向不平衡短文本情感多分类的三阶语义图数据推广方法[J]. 计算机学报, 2024, 47(12): 2742-2759.
- [7] 李诗晨, 王中卿, 周国栋. 大语言模型驱动的跨领域属性级情感分析[J]. 软件学报, 2025, 36(2): 644-659.
- [8] Mao R, Chen G Y, Zhang X L, et al. GPTEval: a survey on assessments of ChatGPT and GPT-4[C]// Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation. Stroudsburg: Association for Computational Linguistics, 2024: 7844-7866.
- [9] Russell J A. A circumplex model of affect[J]. Journal of Personality and Social Psychology, 1980, 39(6): 1161-1178.
- [10] Bradley M M, Lang P J. Measuring emotion: the self-assessment manikin and the semantic differential[J]. Journal of Behavior Therapy and Experimental Psychiatry, 1994, 25(1): 49-59.
- [11] Barrett L F, Russell J A. The structure of current affect: controversies and emerging consensus[J]. Current Directions in Psychological Science, 1999, 8(1): 10-14.
- [12] Preotiu-Pietro D, Schwartz H A, Park G, et al. Modelling valence and arousal in Facebook posts[C]// Proceedings of the 7th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis. Stroudsburg: Association for Computational Linguistics, 2016: 9-15.
- [13] Mohammad S M, Salameh M, Kiritchenko S. How translation alters sentiment[J]. Journal of Artificial Intelligence Research, 2016, 55: 95-130.
- [14] 陶林娟, 华庚兴, 李波. 基于位置增强词向量和GRU-CNN的方面级情感分析模型研究[J]. 计算机工程与应用, 2024, 60(9): 212-218.
- [15] Li X Y, Raga R C, Shi X M. GloVe-CNN-BiLSTM model for sentiment analysis on text reviews[J]. Journal of Sensors, 2022, 2022: 7212366.
- [16] Zhang L K, Lei Y X, Wang Z Y. Long-text sentiment analysis based on semantic graph[C]// Proceedings of the 2020 IEEE International Conference on Embedded Software and Systems. Piscataway: IEEE, 2020: 1-6.
- [17] 高玮军, 孙子博, 刘书君. 基于多视角的图像文本情感分析[J]. 计算机科学, 2024, 51(S2): 138-145.
- [18] Buechel S, Hahn U. Emobank: studying the impact of annotation perspective and representation format on dimensional emotion analysis[C]// Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2017: 578-585.
- [19] 蒋吴达, 赵春蕾, 陈瀚, 等. 基于改进TF-IDF与BERT的领域情感词典构建方法[J]. 计算机科学, 2024, 51(S1): 162-170.
- [20] 李大宇, 李咏, 王素格. 大规模中文金融情感分析数据集自动构建[J]. 山西大学学报(自然科学版), 2024, 47(4): 776-785.
- [21] 公确多杰, 索南才让. 基于卷积神经网络的藏语情感词典自动构建方法[J]. 高原科学研究, 2024, 8(3): 117-124.
- [22] Wu Y L, Wang K C, Ma K, et al. Werkzeug at SemEval-2024 task 8: LLM-generated text detection via gated mixture-of-experts fine-tuning[C]// Proceedings of the 18th International Workshop on Semantic Evaluation. Stroudsburg: Association for Computational Linguistics, 2024: 547-552.
- [23] Qu X Y, Meng X F. TM-TREK at SemEval-2024 task 8: towards LLM-based automatic boundary detection for human-machine mixed text[C]// Proceedings of the 18th International Workshop on Semantic Evaluation. Stroudsburg: Association for Computational Linguistics, 2024: 710-715.
- [24] Kyriakou T, Maslaris I, Arampatzis A. DUTh at SemEval 2024 task 8: comparing classic machine learning algorithms and LLM based methods for multigenerator, multidomain and multilingual machine-generated text detection[C]// Proceedings of the 18th International Workshop on Semantic Evaluation. Stroudsburg: Association for Computational Linguistics, 2024: 1080-1086.
- [25] 刘华玲, 张子龙, 彭宏帅. 面向闭源大语言模型的增强研究综述[J]. 计算机科学与探索, 2025, 19(5): 1141-1156.
- [26] 袁毓林. ChatGPT等语言大模型到底做对了什么?——语言大模型的世界模型和感觉知识的来源探秘[J]. 当代修辞学, 2025 (1): 22-39.
- [27] Callan D, Foster J. How interesting and coherent are the stories generated by a large-scale neural language model? Comparing human and automatic evaluations of machine-generated text[J]. Expert Systems, 2023, 40(6): e13292.
- [28] 马灿, 黄瑞章, 任丽娜, 等. 基于大语言模型的多输入中文拼写纠错方法[J]. 计算机应用, 2025, 45(3): 849-855.
- [29] 李居昊, 石磊, 丁锰, 等. 基于大语言模型的社交媒体文本立场检测[J]. 计算机科学与探索, 2025, 19(5): 1302-1312.
- [30] 关威, 曹健, 赵海燕, 等. 基于大语言模型的业务流程语义异常检测方法[J/OL]. 计算机集成制造系统, (2025-01-14). <https://link.cnki.net/doi/10.13196/j.cims.2025.BPM03>.
- [31] Wei X. The use of large language models for translating Buddhist texts from classical Chinese to modern English: an analysis and evaluation with ChatGPT 4, ERNIE bot 4, and gemini advanced

- [J]. Religions, 2024, 15(12): 1559.
- [32] Shin D, Kim H, Lee S, et al. Using large language models to detect depression from user-generated diary text data as a novel approach in digital mental health screening: instrument validation study[J]. Journal of Medical Internet Research, 2024, 26: e54617.
- [33] 林佳瑞, 陈柯吟, 郑哲, 等. 建筑工程标准规范智能解译关键技术及应用[J]. 工程力学, 2025, 42(2): 1-14.
- [34] Scherer K R. What are emotions? And how can they be measured?[J]. Social Science Information, 2005, 44(4): 695-729.
- [35] Bradley M M, Lang P J. International affective picture system [M]// Encyclopedia of Personality and Individual Differences. Cham: Springer, 2017. DOI: 10.1007/978-3-319-28099-8_42-1.
- [36] Ekman P. An argument for basic emotions[J]. Cognition and Emotion, 1992, 6(3/4): 169-200.
- [37] Plutchik R. A general psychoevolutionary theory of emotion[M]// Theories of Emotion. New York: Academic Press, 1980: 3-33.
- [38] Watson D, Clark L A, Tellegen A. Development and validation of brief measures of positive and negative affect: the PANAS scales [J]. Journal of Personality and Social Psychology, 1988, 54(6): 1063-1070.
- [39] Tracy J L, Robins R W. The psychological structure of pride: a tale of two facets[J]. Journal of Personality and Social Psychology, 2007, 92(3): 506-525.
- [40] Fredrickson B L. What good are positive emotions?[J]. Review of General Psychology, 1998, 2(3): 300-319.
- [41] Bandura A. Self-efficacy: the exercise of control[M]. New York: Freeman, 1997.
- [42] McCullough M E, Emmons R A, Tsang J A. The grateful disposition: a conceptual and empirical topography[J]. Journal of Personality and Social Psychology, 2002, 82(1): 112-127.
- [43] Spielberger C D. Anxiety: current trends in theory and research [M]. New York: Academic Press, 1972.
- [44] Beck A T. Depression: clinical, experimental, and theoretical aspects[M]. Pennsylvania: University of Pennsylvania Press, 1967: 103-113.
- [45] Buss A H, Durkee A. An inventory for assessing different kinds of hostility[J]. Journal of Consulting Psychology, 1957, 21(4): 343-349.
- [46] Zeelenberg M, van Dijk W W, Manstead A S R, et al. On bad decisions and disconfirmed expectancies: the psychology of regret and disappointment[J]. Cognition and Emotion, 2000, 14(4): 521-541.
- [47] Borkovec T D, Robinson E, Pruzinsky T, et al. Preliminary exploration of worry: some characteristics and processes[J]. Behaviour Research and Therapy, 1983, 21(1): 9-16.
- [48] Peplau L A, Perlman D. Loneliness: a sourcebook of current theory, research and therapy[M]. New York: Wiley, 1982.
- [49] Surowiecki J. The wisdom of crowds[M]. New York: Anchor, 2005.
- [50] Blumer A, Ehrenfeucht A, Haussler D, et al. Occam's razor[J]. Information Processing Letters, 1987, 24(6): 377-380.
- [51] Devlin J, Chang M W, Lee K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[C]// Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics, 2019: 4171-4186.
- [52] Liu Y H, Ott M, Goyal N, et al. RoBERTa: a robustly optimized BERT pretraining approach[OL]. (2019-07-26). <https://arxiv.org/pdf/1907.11692>.
- [53] Liao W X, Zeng B, Yin X W, et al. An improved aspect-category sentiment analysis model for text sentiment analysis based on RoBERTa[J]. Applied Intelligence, 2021, 51(6): 3522-3533.
- [54] Kim Y. Convolutional neural networks for sentence classification [C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2014: 1746-1751.
- [55] Liu X Z, Zhang L F, Li T, et al. Dual attention guided multi-scale CNN for fine-grained image classification[J]. Information Sciences, 2021, 573: 37-45.
- [56] Liu G, Guo J B. Bidirectional LSTM with attention mechanism and convolutional layer for text classification[J]. Neurocomputing, 2019, 337: 325-338.
- [57] Cheng Y Y, Chen Y M, Yeh W C, et al. Valence and arousal-infused bi-directional LSTM for sentiment analysis of government social media management[J]. Applied Sciences, 2021, 11(2): 880.
- [58] Lin E, Sun J, Chen H, et al. Data quality matters: suicide intention detection on social media posts using a RoBERTa-CNN[C]// Proceedings of the 2024 46th Annual International Conference of the IEEE Engineering in Medicine and Biology Society. Piscataway: IEEE: 2024: 1-5.
- [59] Cai Y Y, Zhao Y C, Luo H B, et al. Evaluation model of learner's cognitive level based on RoBERTa fused with CNN[C]// Proceedings of the 2023 3rd International Conference on Neural Networks, Information and Communication Engineering. Piscataway: IEEE, 2023: 66-69.
- [60] Rahman M M, Shiplu A I, Watanobe Y, et al. RoBERTa-BiLSTM: a context-aware hybrid model for sentiment analysis[J/OL]. IEEE Transactions on Emerging Topics in Computational Intelligence, (2025-06-02). <http://doi.org/10.1109/TETCI.2025.3572150>.
- [61] Jahin M A, Shovon M S H, Mridha M F, et al. RoBERTa and attention-based BiLSTM for interpretable sentiment analysis of tweets[OL]. (2024-09-09). <https://arxiv.org/pdf/2404.00297v3>.

(责任编辑 魏瑞斌)