

基于语义相似性的引用贡献归属： 揭示直接引用中的隐性被引来源

杨思洛^{1,2}, 吴丽娟^{1,2}, 吴碧瑶^{1,2}

(1. 武汉大学信息管理学院, 武汉 430072; 2. 武汉大学中国科学评价研究中心, 武汉 430072)

摘 要 为精准识别直接引用中未被标注的隐性贡献与隐性被引文献, 本文构建基于引用标记与语义相似性的引用贡献归属方法, 探讨将隐性贡献纳入学术评价的必要性, 为科研贡献归因提供新视角。以 CL-SciSumm 2017 数据集作为实证对象, 先采用两类引用贡献归属方法测算焦点文献的显性贡献, 再将剩余贡献界定为其参考文献的隐性贡献, 并按平等原则与语义相似性分配权重; 以传统直接引用评价、引文级联评价作为对照, 比较隐性被引文献的贡献得分差异。结果显示, 焦点文献的参考文献对其引证文献存在隐性贡献; 基于语义相似性的归属方法对隐性被引来源识别更全面, 但识别精度仍需提升; 本文方法与传统方法所得贡献得分差异显著, 隐性贡献应被纳入文献学术贡献评价体系。

关键词 引用贡献; 间接引用; 语义相似性; 全文本引文分析; 学术评价

Citation Contribution Attribution Based on Semantic Similarity: Revealing Implicitly Cited Sources in Direct Citations

Yang Siluo^{1,2}, Wu Lijuan^{1,2} and Wu Biyao^{1,2}

(1. School of Information Management, Wuhan University, Wuhan 430072;

2. Research Center for Chinese Science Evaluation, Wuhan University, Wuhan 430072)

Abstract: To accurately identify the hidden contributions and unlabeled implicitly cited sources in direct citations, in this paper, citation contribution attribution (CCA) methods are constructed based on citation markers and semantic similarity, and the necessity of integrating hidden contributions into academic evaluation is discussed to provide a new perspective for research contribution attribution. Using the CL-SciSumm 2017 dataset as an empirical object, two types of CCA methods are used to calculate the explicit contributions of focal papers. The remaining contributions are defined as hidden contributions of their references and allocated according to the equal allocation principle and semantic similarity. Two traditional methods, direct citation evaluation and citation cascade evaluation, are employed as benchmarks to compare the differences in contribution scores of implicitly cited papers. The references of focal papers provide hidden contributions to their citing papers. Semantic similarity-based CCA methods identify implicitly cited sources more comprehensively but need further improvement in identification precision. The contribution scores obtained by the proposed and traditional methods differ significantly, suggesting that the hidden contributions should be incorporated into the academic contribution evaluation system of scientific literature.

Keywords: citation contribution; indirect citation; semantic similarity; full-text citation analysis; academic evaluation

收稿日期: 2025-03-08; 修回日期: 2025-11-11

基金项目: 国家社会科学基金重大项目“科研成果社会影响的评价体系与提升策略研究”(23&ZD226)。

作者简介: 杨思洛, 1979 年生, 博士, 教授, 博士生导师, 主要研究方向为文献计量与科学评价、数据分析与知识服务; 吴丽娟, 通信作者, 1997 年生, 博士研究生, 主要研究方向为文献计量与科学评价, E-mail: lijuanw1929@whu.edu.cn; 吴碧瑶, 1999 年生, 博士研究生, 主要研究方向为文献计量与科学评价。

0 引言

学术论文既是科研成果的核心载体,也是评价学者、机构、期刊与学科发展的重要依据。构建科学合理的论文评价机制与奖励政策,对推动科研高质量发展、规范学术行为、激发创新活力具有重要意义^[1]。国家相继出台系列政策文件予以引导,例如,《关于深化项目评审、人才评价、机构评估改革的意见》提出注重标志性成果的质量、贡献与影响,《国务院办公厅关于完善科技成果评价机制的指导意见》强调坚持科技创新质量、绩效、贡献为核心的评价导向。当前,论文评价研究逐渐走向内容化和精细化,对贡献识别与归因的关注度持续提升。科技评价需求增长、开放获取普及与数智技术发展,共同为精细化学术评价创造了有利条件。

一篇论文发表后获得的直接引用可被视为第一代引用,后续引用不断延伸形成多代引用链,构成引文级联(citation cascade)。每一篇被引论文,对于引证者来说,是有了一篇参考文献;而对于被引证者来说,则是有了一篇引证论文。引证关系体现了科学知识的累积性、连续性与继承性,也被视为同行对研究成果的认可,能在一定程度上反映被引论文的学术贡献。基于引文分析的评价方法随之出现,影响因子、h指数等指标被广泛应用,但这类指标仅表征文献在直接引用中的影响,忽略了间接引用与高阶引用中的价值传递^[2]。为实现更全面的评价,全代引证研究受到关注,这类研究主张累加论文在各代引用中的影响,并假设影响随引用代次增加而递减^[3]。PageRank类算法、f-value、fp^k-index等指标主要基于该假设构建,且高度依赖大规模引证网络。

引用贡献(citation contribution)是近年提出的核心概念,指引证论文引用被引论文所带来的价值^[4]。引用贡献归属(citation contribution attribution, CCA)则是将引用贡献分配至真实被引来源的过程,回答“贡献归谁、各占多少”。受引用链影响,当一篇论文被直接引用时,真实被引来源不仅包括被引论文本身,还可能包括其参考文献。一方面,被引论文及其参考文献被同一篇论文共引的现象早已被发现,但受“用而不注”“引而不标”等不规范引用行为的影响^[5-6],真实贡献者难以获得应有的认可;另一方面,全代引证研究虽覆盖了间接引用,但其假设并非完全成立,高阶

引用的知识来源可能并非原始文献,而是中间引证文献。现有研究普遍忽视真实贡献者的识别,导致参考文献的贡献被低估,而焦点文献的贡献被高估。

此类贡献归因偏差若长期存在,会引发系统性评价失真。在知识发现层面,隐性贡献被遮蔽易使研究者将中介文献视为知识源头,窄化研究视野,阻碍学术谱系的准确追溯。在科研评价层面,这会低估原创性奠基成果的价值,加剧马太效应,导致学术资源分配不公与原创贡献边缘化。因此,引用贡献归属方法亟须优化完善,以构建更贴合真实知识流动的科学计量范式。基于引用内容的贡献归属能够超越表层引用计数,深入揭示学术共同体的知识互动机制,在理论认知、评价实践与创新引导上具有重要价值。

为清晰阐释引证关系与贡献归属逻辑,本文以图1为例,论文 P_0 为焦点文献, $\{C_1, C_2, C_3\}$ 为其引证文献, $\{R_1, R_2, R_3, R_4\}$ 为其参考文献。 C_3 引用了 P_0 中涉及 R_3, R_4 的内容,但仅标注 P_0 ,未标注 R_3 和 R_4 。此时, P_0 为显性被引来源, R_3, R_4 为隐性被引来源。①传统评价仅依据引用标记将贡献全部归于 P_0 ,导致 R_3, R_4 贡献被低估。②全代引证方法则按代次加权, P_0 为 R_3, R_4 的第一代引用, C_3 为第二代引用, R_3, R_4 会同时获得来自 P_0 及 C_1, C_2, C_3 等全部第二代引证文献的引用贡献,易被高估。③本文所提基于语义相似性的归属方法,将 $\{P_0, R_1, R_2, R_3, R_4\}$ 均纳入候选来源,依据被引片段与语义相似性筛选真实贡献者 $\{P_0, R_3, R_4\}$,再借鉴合著信用分配方法完成贡献分配。其中, P_0 所得为显性贡献, R_3, R_4 所得为隐性贡献。

开放科学的推进与全文本引文分析的发展,为细粒度识别引用贡献、追溯真实知识来源提供了数据与方法支撑。在此背景下,本文旨在揭示直接引用中的隐性被引来源,基于引文上下文与被引片段的语义相似性识别真实贡献者,验证语义相似性引用贡献归属方法的可行性与必要性。本文围绕以下3个核心问题展开:

问题一. 焦点文献的参考文献是否对焦点文献的引证文献存在隐性贡献?

问题二. 隐性贡献源于焦点文献的哪些参考文献,各自贡献权重如何?

问题三. 评价焦点文献的参考文献时,是否有必要纳入直接引用中的隐性贡献?




图1 文献引证与贡献归属示例

1 相关研究

1.1 引证关系中的隐性贡献

引用标记 (citation markers, CM) 是引文分析的基础, 常见形式包括作者(年份)、(作者, 年份)、[文献序号]等。传统引文分析侧重直接引用, 较少关注间接与高阶引用^[7]。越来越多的证据表明, 文献的学术影响具有间接性与持续性, 科学贡献并非仅通过直接引用体现^[8]。直接引用 (direct citations, DC) 表征一阶影响与显性贡献^[9], 间接引用 (indirect citations, IC) 反映高阶影响与隐性贡献^[10], 文献的多代引证关系被称为引文级联。早期研究发现, 引用影响可覆盖三代引证文献, 近期研究则认为影响范围更广^[3]。部分学者提出应在评价中纳入间接引用^[2,11], 但受数据累积、数据库限制与计算能力的约束, 相关研究仍较为有限。

同时, 引用不规范加剧了隐性贡献的遗漏。匿引、转引等行为隐蔽性强^[12], 缺乏高效识别工具, 导致贡献难以准确归因。引文级联研究虽覆盖间接引用, 但仍基于相邻代次的直接引用, 无法解决各代次内部的不规范引用问题。“被引不足但影响力突出”的文献现象表明, 将间接引用与隐性引用纳入评价体系具有现实必要性^[8,13]。

1.2 引证关系的贡献者识别

知识贡献的准确归因日益受到学界重视。当前研究主要聚焦合著论文的作者贡献评价, 通常依据署名顺序、分工差异与学术影响力开展评估; 部分研究将引文上下文与作者贡献要素相结合, 进一步提升了评价准确性^[14]。但此类研究通常停留在作者层面, 对文献层面的隐性贡献者关注不足。

在文献层面, 引文级联研究认为原始文献对历代引证文献均存在贡献^[3], 并引入知识衰减机制^[15]。然而, 知识衰减系数尚存争议^[16], 固定取值会忽略代次间与同代内的差异性, 按固定公式赋值则未考虑高阶引用内容并非源自原始文献的情况。有研究依据相邻代次引文上下文的最大语义相似性设定知识衰减系数^[17], 为文献级贡献识别提供了新思路, 但未考虑多贡献者并存的场景。主路径分析虽能从复杂引证网络中提取核心路径以简化评价^[15], 但会损失评价的全面性。虚假引文识别主要采用文本相似度、机器学习、知识图谱等方法^[12], 侧重检验引文有效性, 较少深入挖掘隐性贡献的真实来源。

1.3 基于引证关系的贡献评价

文献是科技评价的重点关注对象, 其学术贡献是衡量成果质量和价值的关键指标^[18]。在评价需求推动下, 引文分析不断完善, 形成了被引频次、h指数等系列指标^[2]。尽管部分指标结合了网络结构与知识图谱等方法^[19], 却仍以直接引用为主^[20], 仅少量研究纳入间接引用^[21]。有研究针对专利开展全代引证分析, 发现累积指数优于直接被引频次, 在识别隐性高贡献成果上更具优势^[22]。

传统引文分析侧重数量统计, 忽略引文上下文的定性信息。引文上下文 (citation content, CC) 是指引证文献中引用标记前后的句段集合, 承载引用意图、动机与评价信息等^[23], 是全文本引文分析的核心对象^[24]。被引片段 (reference span, RS) 是指被引文献中与引文上下文对应的文本片段^[25], 是识别贡献句与创新点的重要依据^[18]。将引文上下文与被引片段融入贡献评价的研究仍较少, 主要受限于文本数据处理难度与效果验证挑战。

2 研究设计

2.1 研究思路

本文以引用贡献归属为切入点,分离焦点文献的显性贡献与参考文献的隐性贡献,整体分为3个阶段(图2):①厘清贡献归属模式、方法与权重设置,以CL-SciSumm 2017为数据来源,人工抽取并校验数据,识别焦点文献的显性贡献,将剩余部分界定为参考文献的隐性贡献,回答问题一;②对存在隐性贡献的引证实例,确定隐性被引来源并量化贡献权重,回答问题二;③设置实验组(本文CCA方法)与对照组(传统直接引用、全代引证方法),

对比参考文献的贡献得分差异,判断是否纳入隐性贡献,回答问题三。

2.2 引用贡献归属框架

2.2.1 归属模式分析

在直接引用中,真实贡献来源包括焦点文献及其参考文献。以图1中 C_3 对 P_0 ,以及 P_0 对 R_3 的引证为例,依据引文上下文的知识来源,可将引用贡献归属划分为3种模式(图3)。

(1) 模式I:引文上下文完全源自焦点文献,贡献全部归于焦点文献,即引证文献 C_3 对焦点文献 P_0 的引文是由 P_0 自主创造的, P_0 独享全部引用贡献。




图2 研究框架

(2) 模式II:引文上下文同时源自焦点文献与参考文献,贡献由二者共享,即与引证文献 C_3 的引文相对应的被引片段中含有 P_0 对其参考文献 R_3 的引文, P_0 、 R_3 共享引用贡献。

(3) 模式III:引文上下文完全源自参考文献,贡献全部归于参考文献,即引证文献 C_3 对焦点文献

P_0 的引文完全由 P_0 的参考文献 R_3 提供, R_3 独享全部引用贡献。

2.2.2 归属方法设计

直接问询引证者以确定贡献归属与分配权重,不仅成本较高,还易引入主观偏差,因此未采用该




图3 引用贡献归属模式

方案。本文基于全文本引文分析构建3类CCA方法，如图4所示。

(1) 基于引用标记的方法 (CCA_CM_{RS})

该方法以引证文献对焦点文献的引文上下文 ($CC_{[C_3, P_0]}$) 为线索，定位焦点文献中对应的被引片段 ($RS_{[C_3, P_0]}$)，并判断其中是否包含指向参考文献的引用标记 ($CM_{[P_0, R_i]}$)。若包含且被引片段与焦点

文献对参考文献的引文上下文 ($CC_{[P_0, R_i]}$) 完全重合，则贡献由该参考文献独享；若部分重合，则由焦点文献与参考文献共享；若未检测到引用标记，则贡献由焦点文献独享。该方法遵循传统引用规范，强调通过引用标记承认在先研究的贡献。受期刊版面限制，作者通常会选取重要参考文献在正文中标引与呈现。因此，若焦点文献的被引片段中




图4 引用贡献归属方法

出现参考文献的引用标记,则可判定该参考文献对焦点文献的引证文献存在隐性贡献。

(2) 基于语义相似性的方法 (CCA_SS_{CC})

该方法的核心假设为,文本语义相似性可有效反映知识关联强度,并作为引用贡献归属的判别依据。这一假设植根于分布式语义理论,即语义向量空间中的邻近关系能够有效表征文本间的内容相关性。该方法需预先设定相似性阈值 X_0 与 X_1 ,依次计算引证文献引文上下文与焦点文献对各参考文献引文上下文的相似度,若设焦点文献有 n 篇参考文献,则形成相似度集合 $\{\text{Sim}_{[C_3,R_1]}, \text{Sim}_{[C_3,R_2]}, \text{Sim}_{[C_3,R_3]}, \dots, \text{Sim}_{[C_3,R_n]}\}$,并以最大值($\text{Max}_{[\text{Sim}]}$)进行归属判断。①若 $0 \leq \text{Max}_{[\text{Sim}]} < X_0$ (不相似),则贡献由焦点文献独享;②若 $X_0 \leq \text{Max}_{[\text{Sim}]} < X_1$ (有点相似),则贡献由焦点文献与对应参考文献均分;③若 $X_1 \leq \text{Max}_{[\text{Sim}]} \leq 1$ (相似),则贡献由对应参考文献独享。该方法可有效识别“用而不注”等隐性引用行为,但仅能识别单篇隐性被引文献,无法处理多贡献者并存的场景。

(3) 改进语义相似性的方法 (CCA_SS_{RS})

在CCA_SS_{CC}计算所得语义相似度集合($\{\text{Sim}_{[C_3,R_1]}, \text{Sim}_{[C_3,R_2]}, \text{Sim}_{[C_3,R_3]}, \dots, \text{Sim}_{[C_3,R_n]}\}$)的基础上,本文方法进一步以引证文献对焦点文献的引文上下文($\text{CC}_{[C_3,P_0]}$)与焦点文献对应被引片段($\text{RS}_{[C_3,P_0]}$)的相似度($\text{Sim}_{[C_3,P_0]}$)作为贡献归属最低

门槛,筛选出相似度高于该门槛的参考文献,形成贡献来源列表(Sub_List),其中,焦点文献位于列表末尾。若引证文献对焦点文献的引文上下文($\text{CC}_{[C_3,P_0]}$)与焦点文献对其第 i 篇参考文献的引文上下文($\text{CC}_{[P_0,R_i]}$)的相似度($\text{Sim}_{[C_3,R_i]}$)高于该门槛,则相应参考文献参与贡献分配,且相似度越高,权重越大;若所有参考文献的最大相似度($\text{Max}_{[\text{Sim}]}$)仍低于最低门槛($\text{Sim}_{[C_3,P_0]}$),则贡献由焦点文献独享。该方法无须预设阈值,可同时识别多篇隐性被引文献,并保证焦点文献始终获得基础贡献权重。本文认为,即便焦点文献仅承担知识传递的中介角色,也应赋予其适度的引用贡献。

2.2.3 贡献权重设置

贡献由单一文献独享时,其权重为1;若由多方共享,则采用平等分配与按语义相似性分配两种策略。结合贡献归属模式与方法,焦点文献 P_0 的贡献权重设置如表1所示。其中, $\text{cc}_w(P_0)$ 表示 P_0 的显性贡献权重,剩余权重为其参考文献的隐性贡献。CCA_CM_{RS}与CCA_SS_{CC}在共享模式下均采用平等分配,该策略适用于多篇参考文献被共同提及或语义高度相似的场景。在缺乏明确贡献区分依据时,平等分配是保守且稳健的基准方法,既能保障对各潜在贡献者的基础认可,也具备良好的可解释性与复现性。

表1 引用贡献权重分配

归属方法	具体情况	归属模式	焦点文献 P_0 的引用贡献权重
CCA_CM _{RS}	不含引用标记	模式 I	$\text{cc}_w(P_0)=1$
	含引用标记,部分重合,设引用标记中的文献数量为 n ,平等分配	模式 II	$\text{cc}_w(P_0)=1/(n+1)$
	含引用标记,完全重合	模式 III	$\text{cc}_w(P_0)=0$
CCA_SS _{CC}	不相似, $0 \leq \text{Max}_{[\text{Sim}]} < X_0$	模式 I	$\text{cc}_w(P_0)=1$
	有点相似, $X_0 \leq \text{Max}_{[\text{Sim}]} < X_1$,平等分配	模式 II	$\text{cc}_w(P_0)=1/2$
	相似, $X_1 \leq \text{Max}_{[\text{Sim}]} \leq 1$	模式 III	$\text{cc}_w(P_0)=0$
CCA_SS _{RS}	按语义相似性降序排列得到Sub_List,即享有引用贡献的文献列表,设 i 为焦点文献在Sub_List中的顺序, n 为Sub_List含有的文献数量	分数分配法(CCA_SS _{RS,FC})	$\text{cc}_w(P_0)=1/n$
		直接分配法(CCA_SS _{RS,SC})	$\text{cc}_w(P_0)=1, i=1$ $\text{cc}_w(P_0)=0, i \neq 1$
		算数分配法(CCA_SS _{RS,AC})	$\text{cc}_w(P_0)=2(n-i+1)/[n(n+1)]$
		几何分配法(CCA_SS _{RS,GC})	$\text{cc}_w(P_0)=(2n-i)/(2n-1)$
		调和级数分配法(CCA_SS _{RS,HC})	$\text{cc}_w(P_0)=(1/i)/(1+1/2+\dots+1/n)$

为更精细地刻画知识关联强度对贡献分配的影响,CCA_SS_{RS}借鉴合著信用分配方法^[14],设置分数分配、直接分配、算数分配、几何分配与调和级

数分配5种赋权方式,分别记为CCA_SS_{RS,FC}、CCA_SS_{RS,SC}、CCA_SS_{RS,AC}、CCA_SS_{RS,GC}和CCA_SS_{RS,HC}。该方法将贡献来源列表(Sub_List)类比为作者署

名序列, 实现基于语义相似性的差异化赋权。上述分配策略具备理论支撑, 能有效提升贡献归属的区分度, 但仍存在不足, 如未充分考虑学科差异、引用动机多样性等。为此, 本文同时采用平等分配与语义相似性加权两种思路, 通过对比不同假设下的归属结果, 为后续构建更贴合学术实践的贡献分配模型提供理论与方法参考。

2.3 数据来源与处理

2.3.1 数据来源

本文实证数据采用 CL-SciSumm 2017 数据集^①, 包含计算语言学领域 40 篇焦点文献 (共含 810 篇参考文献) 及其 480 篇引证文献, 共 753 个引证与被引文本对, 提供经人工校验的引证文献对焦点文献的引文上下文与焦点文献对应的被引片段, 数据可靠性较高。

2.3.2 数据处理

对原始数据进行清洗, 修正重复记录、标注错误与文本缺失, 最终保留 753 个有效文本对。为便于追踪, 本文为每对文本对设置唯一编号, 格式为“(焦点文献: 引证文献)|序号”。例如, (C00-2123: C02-1050)|01 表示焦点文献 C00-2123 在引证文献 C02-1050 中被第一次提及。

为保证数据质量, 采用人工方式提取参考文献、引用标记及引文上下文, 并使用交并比 (intersection of union, IoU) 与 ROUGE (recall-oriented understudy for gisting evaluation) 指标检验标注一致性。结果显示, IoU 最小值为 0.85, 94.4% 的样本 $\text{IoU} \geq 0.90$; ROUGE 的 F1 值、精确率、召回率最小值分别为 0.92、0.86、0.85, 标注一致性良好。

借助 NLTK (natural language toolkit) 库完成分词、去停用词、词形还原等文本预处理操作。采用 Sentence Transformers 框架的 all-MiniLM-L6-v2 模型 (batch_size=16, normalize_embeddings=True) 生成语义向量, 并以余弦相似度衡量文本间的语义关联强度。综合 3 种方法确定阈值: ①由百分位数法 (25% 和 75% 分位数) 得到 0.35 和 0.55; ②由拐点法得到上升拐点 0.33 和下降拐点 0.57; ③由 k -means 聚类 ($k=3$) 得到 0.38 和 0.56。最后, 取中间值确定分类阈值: $X_0=0.35$, $X_1=0.56$; 与已有研究的专家判定结果基本一致^[17] (不相似和有点相似的最高相似度分别为 0.35 和 0.45)。为避免低估焦点文献

的显性贡献, 本文在阈值划分上采用较为宽松的策略, 更贴合实际引用规范。

3 结果与讨论

经统计, 数据集包含焦点文献的参考文献 810 篇, 其中 10 篇未在焦点文献正文中出现, 予以剔除。焦点文献对参考文献总计提及 1259 次, 单篇最高被提及频次为 16 次, 共提取有效引用标记 987 个。

为聚焦隐性贡献识别, 本文先排除焦点文献与参考文献被同时显性标注的样本。依据引用标记筛选, 此类样本共 106 例, 其中, 含 1、2、3、4、7 篇参考文献的占比分别为 68.87%、16.98%、8.49%、4.72%、0.94%。此类样本构成显性共被引关系, 参考文献的贡献可直接计量, 因此, 本文最终以 647 个有效文本对开展实证分析。对这些文本对的被引片段进一步核查发现, 有 114 个片段包含指向参考文献的引用标记。其中, 含 1 篇参考文献的占比最高, 为 65.79%; 含 2、4 篇参考文献的占比分别为 17.54%、10.53%, 含 3、5、6 篇参考文献的占比均低于 3%, 如图 5 所示。整体上, 被引片段与焦点文献对其参考文献的引文上下文并非完全重合, 仅 4 个被引片段被标注为完全一致。

3.1 参考文献隐性贡献的整体情况

假设焦点文献与参考文献的贡献权重之和为 1, 焦点文献权重为显性贡献, 剩余部分为参考文献的隐性贡献。在 647 个文本对中, $\text{CCA_CM}_{\text{RS}}$ 、 $\text{CCA_SS}_{\text{CC}}$ 、 $\text{CCA_SS}_{\text{RS}}$ 识别出参考文献享有贡献的案例数分别为 114、615、446, 描述性统计结果如表 2 所示。两种语义相似性归属方法所得隐性贡献均值均高于 0.5, 显著高于 $\text{CCA_CM}_{\text{RS}}$ 的均值 0.1。

贡献归属结果表明, 直接引用中普遍存在隐性贡献。 $\text{CCA_CM}_{\text{RS}}$ 显示, 17.62% 的被引片段包含参考文献引用标记, 但引证文献仅标注焦点文献, 进而造成贡献归因偏差。典型隐性引用示例如图 6 所示。文本对 (H89-2014: C92-1060)|01 与 (H89-2014: H91-1046)|02 均隐性引用了焦点文献 H89-2014 的参考文献 “Kupiec, 1989b”。若忽略隐性贡献, 全部贡献将会归于 H89-2014, 即 “Kupiec, 1989a”; 若按传统间接引用处理, “Kupiec, 1989b” 与其他参考文献将获得同等权重; 若采用 $\text{CCA_CM}_{\text{RS}}$ 或 $\text{CCA_SS}_{\text{CC}}$, 因被引片段与引文上下文完全重合且

① <https://github.com/WING-NUS/scisumm-corpus>




图5 数据集文本对引用特征与标记情况

表2 隐性贡献权重描述统计

归属方法	<i>N</i>	最小值	最大值	均值	标准偏差	方差
CCA_CM _{RS}	647	0.00	1.00	0.1046	0.23389	0.055
CCA_SS _{CC}	647	0.00	1.00	0.6391	0.27395	0.075
CCA_SS _{RS,FC}	647	0.00	0.98	0.5349	0.38224	0.146
CCA_SS _{RS,SC}	647	0.00	1.00	0.6909	0.46249	0.214
CCA_SS _{RS,AC}	647	0.00	1.00	0.6151	0.42409	0.180
CCA_SS _{RS,GC}	647	0.00	1.00	0.6268	0.43297	0.187
CCA_SS _{RS,HC}	647	0.00	1.00	0.5957	0.41527	0.172

相似度高于 0.56, 贡献由“Kupiec, 1989b”独享; 若采用 CCA_SS_{RS}, 贡献由焦点文献 H89-2014 与“Kupiec, 1989b”共享, 其中焦点文献作为中介文献分配较低权重。

图 6 中文本对 (P05-1053: D07-1076) 呈现类似规律, 引证文献 D07-1076 隐性引用了焦点文献 P05-1053 的两篇参考文献。当忽略隐性贡献时, 引用贡献由 P05-1053 即“Zhou et al., 2005”独享; 传统间接引用则会将贡献平均分配给所有参考文献; CCA_CM_{RS} 因被引片段无引用标记, 贡献仍归 P05-1053; CCA_SS_{CC} 仅识别出“Kambhatla, 2004”为隐性被引文献, 且因相似度高于 0.56, P05-1053 不获得贡献; CCA_SS_{RS} 则依据相似度递减顺序, 将贡

献分配给“Kambhatla, 2004”和 P05-1053, 前者因语义关联更强获得更高权重。

综上, 仅依靠显性引用与引用标记难以客观评价文献贡献。CCA_CM_{RS} 与 CCA_SS_{CC} 易遗漏部分隐性被引文献, 而融合被引片段与语义相似性能更全面地识别真实贡献来源。余弦相似度能够有效反映文本内容、结构与语义的相近程度, 在隐性贡献识别中具有明显优势。实证结果显示, CCA_SS_{CC} 与 CCA_SS_{RS} 的隐性贡献均值均高于 CCA_CM_{RS}, 表明语义深度挖掘可识别更多隐性贡献。基于引用标记的方法中, 焦点文献占据明显优势, 显性贡献显著偏高; 而改进语义相似性的方法以内容关联为依据, 显性与隐性贡献分配更为均衡, 能更真实地反映知识传递与贡献分担关系。

3.2 参考文献隐性贡献的归属情况

明确参考文献隐性贡献整体特征后, 进一步分析其内部归属结构。3 种方法识别的隐性被引文献分布 (图 7): CCA_CM_{RS}、CCA_SS_{CC}、CCA_SS_{RS} 分别检出 196、615、653 篇隐性被引文献, 对应文本对数量为 114、615、446。CCA_CM_{RS} 与 CCA_SS_{RS} 可同时识别多篇隐性被引文献, CCA_SS_{CC} 最多识





图6 焦点文献的引证实例

图7 3种归属方法识别出的隐性被引文献分布
(彩图请见 <https://qbx.istic.ac.cn>)

别1篇；其中CCA_CM_RS最多识别6篇，CCA_SS_RS可识别6篇及以上。

以CCA_CM_RS针对114个文本对识别出的隐性被引文献为参照，CCA_SS_RS对隐性被引来源的识别比CCA_SS_CC准确。在66个文本对中，CCA_SS_RS与CCA_CM_RS识别结果一致性较高，而且能识别更多隐性被引文献，部分实例如表3所示。以文本对(P98-2143: J02-1001)01为例，CCA_SS_CC仅识别1篇，与CCA_CM_RS识别的10篇完全不同；而CCA_SS_RS可覆盖全部11篇，并额外检出2篇。CCA_SS_CC仅选取相似度最高的单篇文献参与分配，无法处理多篇文献同时具备高相似度的情形，仅适用于引证内容与焦点文献引文上下文高度重合的场景。CCA_SS_RS识别出的隐性被引文献，与被引片段的相似度显著高于非隐性被引文献，且生成引证

引文上下文的概率更高。但该方法仍存在识别结果过于分散的问题，后续可在最低门槛基础上引入动态截断策略或学科适配截断点，以筛选核心贡献文献，平衡识别全面性与准确性。

表3 3种归属方法识别出的隐性被引文献实例

序号	文本对	CCA_CM_RS	CCA_SS_CC	CCA_SS_RS
1	(P05-1004: CS2-1011)02	■	■	■
2	(W03-0410: D09-1138)02	■	■	■▲
3	(P05-1004: P12-2050)01	■	▲	■▲
4	(P05-1053: N07-1015)01	■	▲	■▲+2
5	(N09-1025: D11-1081)02	■▲	■	■▲
6	(N09-1025: P13-1110)02	■▲	■	■▲+3
7	(N09-1025: W10-1757)01	■▲	●	■▲●
8	(N09-1025: W10-1761)02	■▲	●	■▲●+2
9	(P98-2143: J02-1001)01	10■	▲	10■+▲+2
10	(N09-1025: P13-1110)01	■▲●+1	▲	■▲●+1

注：■、▲、●表示不同隐性被引文献，数字为文献集合，“+”表示合并文献形成整体识别结果。

完成隐性被引文献识别后开展贡献分配，图8展示了传统不考虑隐性贡献（记为NCCA_DC）与CCA_CM_RS、CCA_SS_CC、CCA_SS_RS.HC的归属结果。CCA_SS_RS因5种加权方式分布相近，故采用认可度较高的调和级数法呈现。在图8中，方形代表焦点文献，面积越大，表示焦点文献的引证文献越多；圆形代表焦点文献的引证文献，相同被引数量的引证文献构成集群，数字表示被引文献总数（含显性




图8 引用贡献归属分布

与隐性); 三角形代表参考文献集合, 面积越大, 表示被识别为隐性被引文献的频次越高; 连线表示贡献归属关系, 线条越粗, 权重越大。

其中, NCCA_DC 共有 2 个集群, 较小集群由焦点文献共被引形成。CCA_CM_RS 与 CCA_SS_CC 各形成 7 个集群; 尽管对于每个文本对, CCA_SS_CC 仅能识别出一篇隐性被引文献, 但若焦点文献被多次提及, 则可能产生不同的文献, 由此形成含多篇文献的集群。CCA_SS_RS_HC 共形成 38 个集群, 数量较图 7 中 CCA_SS_RS 识别出的 39 种隐性被引文献分类少 1 个。这一差异源于文本对(J96-3004: W12-1011)|01: 该文本对识别出 42 篇隐性被引文献, 对应的 43 号集群已包含焦点文献及其 42 篇参考文献; 而在同一文献对的(J96-3004: W12-1011)|02 中被判定为隐性被引的 35 篇参考文献, 均已被包含在上述 43 号集群内, 因此, 未形成新的独立集群。

传统评价方法 NCCA_DC 不考虑隐性贡献, 引用贡献完全由焦点文献独享, 因此, 图中未出现三角形。CCA_CM_RS 可识别隐性被引文献, 但贡献分配仍以焦点文献为主, 表现为方形与圆形之间的连线更为密集; CCA_SS_CC 中参考文献获得的贡献占比有所提升, 圆形与三角形之间的连线明显多于 CCA_CM_RS; CCA_SS_RS 识别出的隐性被引文献数量显著增加, 贡

献分配更分散, 方形与圆形之间的连线随之变细、变少。整体结果表明, 直接引用中同时存在显性贡献与隐性贡献, 改进语义相似性的归属方法可有效区分两类贡献, 精准定位真实贡献者并量化贡献差异。

3.3 直接引用中参考文献的贡献评价

为检验隐性贡献纳入评价的必要性, 本文整合 3 种方法识别的隐性被引文献, 去重后得到 664 篇, 按文本对累加权重得到总贡献得分。设置两组传统对照方法: ①NCCA_DC, 仅依据引用标记, 不考虑隐性贡献, 参考文献的贡献权重为 0; ②NCCA_IC, 基于引文级联, 按公式 $(1/2)^{n-1}$ 对第 n 代引用加权^[26-27], 其中, 焦点文献为第一代, 其引证文献为第二代。不同方法所得贡献得分的描述统计与分布如表 4 和图 9 所示。结果显示, NCCA_IC 的平均得分最高 (9.181), 值域为 [1, 25.5], 明显夸大了参考文献的贡献; NCCA_DC 平均得分接近 0, 完全忽略隐性贡献; 依托语义相似性的两类方法得分平均值介于 0.521~0.670, 分布更集中、稳定性更强。NCCA_IC 因假设所有参考文献均跨代贡献而导致高估; CCA_CM_RS 仅依赖引用标记则易受不规范引用影响而低估; CCA_SS_RS 兼顾每次提及的独特性, 采用动态赋权, 结果更稳健。

表 4 参考文献的贡献得分描述统计

方法	个案数	平均值	标准偏差	标准错误	平均值的 95% 置信区间		最小值	最大值
					下限	上限		
NCCA_DC	664	0.000	0.000	0.000	0.000	0.000	0.00	0.00
NCCA_IC	664	9.181	6.302	0.245	8.701	9.662	1.00	25.50
CCA_CM _{RS}	664	0.101	0.352	0.014	0.074	0.128	0.00	5.00
CCA_SS _{CC}	664	0.623	1.376	0.053	0.518	0.728	0.00	10.50
CCA_SS _{RS.FC}	664	0.521	0.606	0.024	0.475	0.567	0.00	4.46
CCA_SS _{RS.SC}	664	0.670	1.486	0.058	0.557	0.783	0.00	14.00
CCA_SS _{RS.AC}	664	0.596	0.778	0.030	0.537	0.655	0.00	6.54
CCA_SS _{RS.GC}	664	0.607	0.977	0.038	0.532	0.681	0.00	8.96
CCA_SS _{RS.HC}	664	0.587	0.840	0.033	0.523	0.651	0.00	7.63




图 9 参考文献的贡献得分分布

进一步地，采用 Kruskal-Wallis 检验比较 9 种评价方法所得参考文献的贡献得分差异。结果显示， $H=3298.841$ ， $P<0.001$ ，差异具有统计学意义（ $\alpha=0.05$ ）。Bonferroni 校正的两两比较结果表明，NCCA_DC、NCCA_IC、CCA_CM_{RS} 与语义相似性方法得分均存在显著差异（表 5），证实纳入隐性贡献的必要性，也说明依托语义的归属方法与传统方法存在本质区别。两类归属方法的差异主要源于：①引用不规范导致 CCA_CM_{RS} 难以全面识别隐性被引文献；②作者常对参考文献内容进行改写，降低了文本相似度。在语义相似性方法内部，CCA_SS_{CC} 与 CCA_SS_{RS.SC}、CCA_SS_{RS.FC} 与 CCA_SS_{RS.AC/HC} 均无显著差异，这是因为二者均以最大相似度判定贡献归属。尽管多数赋权方式差异不显著，但 CCA_SS_{RS.GC} 结果表明，加权方式仍会对最终贡献分配产生一定影响。

表 5 参考文献贡献得分两两比较的显著性(P值)

方法	NCCA_DC	NCCA_IC	CCA_CM _{RS}	CCA_SS _{CC}	CCA_SS _{RS.FC}	CCA_SS _{RS.SC}	CCA_SS _{RS.AC}	CCA_SS _{RS.GC}	CCA_SS _{RS.HC}
NCCA_DC	—	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001
NCCA_IC	<0.001	—	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001
CCA_CM _{RS}	<0.001	<0.001	—	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001
CCA_SS _{CC}	<0.001	<0.001	<0.001	—	<0.001	1.000	<0.001	<0.001	<0.001
CCA_SS _{RS.FC}	<0.001	<0.001	<0.001	<0.001	—	<0.001	1.000	0.002	1.000
CCA_SS _{RS.SC}	<0.001	<0.001	<0.001	1.000	<0.001	—	<0.001	<0.001	<0.001
CCA_SS _{RS.AC}	<0.001	<0.001	<0.001	<0.001	1.000	<0.001	—	0.001	1.000
CCA_SS _{RS.GC}	<0.001	<0.001	<0.001	<0.001	0.002	<0.001	0.001	—	0.012
CCA_SS _{RS.HC}	<0.001	<0.001	<0.001	<0.001	1.000	<0.001	1.000	0.012	—

4 结论与启示

本文以焦点文献与其引证文献的直接引用关系为对象，构建两类语义相似性引用贡献归属方法（CCA_SS_{CC}、CCA_SS_{RS}），分离焦点文献的显性贡

献与参考文献的隐性贡献。基于 CL-SciSumm 2017 数据集，将语义相似性方法与引用标记方法（CCA_CM_{RS}）进行对比，系统揭示隐性贡献的分布、来源与权重，并比较不同评价框架下的贡献得分差异。

研究结果表明, 焦点文献的参考文献对其引证文献存在隐性贡献。改进语义相似性的方法可有效识别未被标注的隐性被引文献, 并按相似度实现差异化赋权。其中, CCA_SS_{RS} 的识别全面性优于 CCA_CM_{RS} 、 CCA_SS_{CC} , 但存在贡献分配偏分散的问题。与传统直接引用评价、引文级联评价相比, 纳入隐性贡献的评价结果存在显著统计差异, 说明直接引用中的隐性贡献应当纳入文献评价体系。参考文献通过语义方法与引用标记方法所得贡献得分差异显著, 参考文献在语义框架下通常获高贡献权重; 两种语义方法所得贡献得分相近, 但赋权方式仍会对分配结果产生一定影响。

本文的研究结果兼具理论和实践价值。在理论上, 本文聚焦直接引用中的隐性贡献, 实现显性与隐性贡献的精准归因, 为虚假引文、重要引文识别等提供新路径; 在实践上, 本文方法能够修正传统评价与全代引证方法的偏差, 推动评价体系从“被引频次”向“加权被引频次”升级, 更公平地反映文献真实学术影响力。更完善的评价模式应依托完整引文网络, 同时兼顾显性被引与隐性被引角色, 综合衡量文献的学术净贡献。

本文仍存在一些局限: 一是采用人工抽取文本, 难以实现大规模数据处理; 二是基于计算语言学领域数据开展研究, 本文方法的跨学科适用性有待验证。引文规范、知识表达习惯在不同学科间差异明显, 会影响隐性贡献识别效果与应用效益。未来可引入自动化文本抽取工具, 提升方法可扩展性; 针对不同学科开展领域适配与模型微调, 增强跨学科稳健性; 融合引用标记、语义计算、链路预测与主题分析等^[17]多元手段, 进一步提升贡献归因精度。

参 考 文 献

- [1] Zhu X D, Turney P, Lemire D, et al. Measuring academic influence: not all citations are equal[J]. *Journal of the Association for Information Science and Technology*, 2015, 66(2): 408-427.
- [2] Cai L W, Tian J H, Liu J Y, et al. Scholarly impact assessment: a survey of citation weighting solutions[J]. *Scientometrics*, 2019, 118(2): 453-478.
- [3] Min C, Chen Q Y, Yan E J, et al. Citation cascade and the evolution of topic relevance[J]. *Journal of the Association for Information Science and Technology*, 2021, 72(1): 110-127.
- [4] Liu Y Y, Wu Q, Wu S J, et al. Weighted citation based on ranking-related contribution: a new index for evaluating article impact[J]. *Scientometrics*, 2021, 126(10): 8653-8672.
- [5] 刘运梅, 李冉, 盛小平. 隐形三角引用: 科学论文中的不规范引用行为[J]. *现代情报*, 2024, 44(4): 127-141.
- [6] Liu Y M, Yang L, Chen M. A new citation concept: triangular citation in the literature[J]. *Journal of Informetrics*, 2021, 15(2): 101141.
- [7] Lyu H H, Bu Y, Zhao Z Y, et al. Citation bias in measuring knowledge flow: evidence from the web of science at the discipline level[J]. *Journal of Informetrics*, 2022, 16(4): 101338.
- [8] Hu X J, Rousseau R. Scientific influence is not always visible: the phenomenon of under-cited influential publications[J]. *Journal of Informetrics*, 2016, 10(4): 1079-1091.
- [9] Ahlgren P, Chen Y W, Colliander C, et al. Enhancing direct citations: a comparison of relatedness measures for community detection in a large set of PubMed publications[J]. *Quantitative Science Studies*, 2020, 1(2): 714-729.
- [10] Fragkiadaki E, Evangelidis G. Three novel indirect indicators for the assessment of papers and authors based on generations of citations[J]. *Scientometrics*, 2016, 106(2): 657-694.
- [11] 吕海华, 李江. 1987—2016年跨学科知识流动的规律: 一个新的视角“学科势能”[J]. *图书情报知识*, 2021, 38(4): 125-135.
- [12] 鞠秀芳. 基于文本相似度分析的期刊引文有效性识别研究[J]. *现代情报*, 2018, 38(11): 14-17.
- [13] MacRoberts M H, MacRoberts B R. The mismeasure of science: citation analysis[J]. *Journal of the Association for Information Science and Technology*, 2018, 69(3): 474-482.
- [14] Yang S L, Xiao A X, Nie Y, et al. Measuring coauthors' credit in medicine field—based on author contribution statement and citation context analysis[J]. *Information Processing & Management*, 2022, 59(3): 102924.
- [15] Liu J S, Kuan C H. A new approach for main path analysis: decay in knowledge diffusion[J]. *Journal of the Association for Information Science and Technology*, 2016, 67(2): 465-476.
- [16] Hou J H, Yang X C, Zhang Y. The effect of social media knowledge cascade: an analysis of scientific papers diffusion[J]. *Scientometrics*, 2023, 128(9): 5169-5195.
- [17] Asubiaro T V, Ajiferuke I. Semantic similarity-based credit attribution on citation paths: a method for allocating residual citation to and investigating depth of influence of scientific communications[J]. *Scientometrics*, 2022, 127(11): 6257-6277.
- [18] 罗卓然, 蔡乐, 钱佳佳, 等. 学术论文创新贡献句识别研究[J]. *图书情报工作*, 2021, 65(12): 93-100.
- [19] Fiala D, Tutoky G. PageRank-based prediction of award-winning researchers and the impact of citations[J]. *Journal of Informetrics*, 2017, 11(4): 1044-1068.
- [20] Waltman L. A review of the literature on citation impact indicators[J]. *Journal of Informetrics*, 2016, 10(2): 365-391.
- [21] Feng S D, Li H J, Qi Y B. How to detect the sleeping beauty papers and princes in technology considering indirect citations?[J].

- Journal of Informetrics, 2023, 17(3): 101431.
- [22] 康旭东, 邓乐乐, 王宇开, 等. 基于全代引证的专利累积影响力评价——一个诺奖得主专利的案例研究[J]. 情报学报, 2021, 40(3): 267-277.
- [23] Tahamtan I, Bornmann L. What do citation counts measure? An updated review of studies on citations in scientific documents published between 2006 and 2018[J]. Scientometrics, 2019, 121(3): 1635-1684.
- [24] 卢超, 章成志, 王玉琢, 等. 语义特征分析的深化——学术文献的全文计量分析研究综述[J]. 中国图书馆学报, 2021, 47(2): 110-131.
- [25] 金贤日, 欧石燕. 无监督引用文本自动识别与分析[J]. 数据分析与知识发现, 2021, 5(1): 66-77.
- [26] Fragkiadaki E, Evangelidis G, Samaras N, et al. Cascading citations indexing framework algorithm implementation and testing [C]// Proceedings of the 13th Panhellenic Conference on Informatics. Piscataway: IEEE, 2009: 70-74.
- [27] Dervos D A, Kalkanis T. Cc-IFF: a cascading citations impact factor framework for the automatic ranking of research publications [C]// Proceedings of the 2005 IEEE Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications. Piscataway: IEEE, 2005: 668-673.

(责任编辑 冯家琪)