

基于异质图神经网络的学者研究主题推荐方法研究

霍朝光^{1,2}, 但婷婷¹, 逢增瑶¹

(1. 中国人民大学信息资源管理学院, 北京 100872; 2. 中国人民大学图书馆, 北京 100872)

摘要 研究主题的选择对于学者科研生涯发展至关重要, 但如何从海量学术资源中筛选出契合学者研究基础和研究兴趣的主题仍是一大难题。为此, 本文构建了一个面向学者的个性化主题推荐模型, 旨在帮助学者快速筛选契合其研究基础和研究兴趣的主题。针对现有推荐方法在学习网络中节点类型与关系类型异质性方面的不足, 本文提出一种基于异质图神经网络的学者研究主题推荐模型, 构建基于 HAN (heterogeneous graph attention network)、HGT (heterogeneous graph transformer)、HGCL (heterogeneous graph contrastive learning) 的三种学者和主题特征聚合模式, 强调利用消息传递与聚合机制等学习学者与主题间的复杂交互模式, 刻画主题扩散与学者选题的规律, 在特征聚合基础上, 通过逻辑回归、随机森林和多层感知机等分类器进行推荐判别。以 Scopus 数据库中 6521 名中国人民大学学者及其涉猎的 3 万多个研究主题数据为例进行实证检验, 研究发现, 基于 HGCL 整合多层感知机的推荐模型精确率最高, 达到 88.25%, 相对于基线模型 SVD 提升了 9.29 个百分点; 基于 HAN 整合多层感知机的推荐模型在召回率和 F1 值上的表现最佳, 分别达到 96.41% 和 91.92%, 相对于基线模型 SVD 分别提升了 17.21 和 12.56 个百分点。本文首次构建学者研究主题推荐模型, 强调对学者与主题节点异质性和关系异质性的表征与学习, 为学者个性化选题以及主题层面的学术资源推荐提供了参考。

关键词 研究主题推荐; 学者选题推荐; 主题推荐; 异质图神经网络; 链路预测

Research Topic Recommendation for Scholars Based on Heterogeneous Graph Neural Networks

Huo Chaoguang^{1,2}, Dan Tingting¹ and Pang Zengyao¹

(1. School of Information Resource Management, Renmin University of China, Beijing 100872;

2. Renmin University of China Libraries, Beijing 100872)

Abstract: Research topic selection is critical for academic career development. However, identifying suitable candidates from a large number of options remains a significant challenge. To address this issue, this study developed a personalized topic recommendation method to assist scholars discover topics that are relevant to their research bases and interests. Given the limitations of existing recommendation methods in dealing with the heterogeneity of nodes and relationship types in scholarly networks, this study proposes a research topic recommendation model for scholars based on a heterogeneous graph neural network. Three feature aggregation modes for scholars and topics using heterogeneous graph attention net-

收稿日期: 2025-06-11; 修回日期: 2025-10-23

基金项目: 国家自然科学基金面上项目“基于图机器学习的学科交叉主题识别与预测研究”(72374202); 国家自然科学基金青年科学基金项目“基于广度学习的学科主题演化预测研究”(72004221)。

作者简介: 霍朝光, 1990 年生, 博士, 副教授, 主要研究方向为科学预测与系统推荐; 但婷婷, 通信作者, 2002 年生, 硕士研究生, 主要研究方向为科学计量与图机器学习, E-mail: dantingting_ruc@126.com; 逢增瑶, 1993 年生, 硕士, 主要研究方向为科技情报与图机器学习。

work (HAN), heterogeneous graph transformer (HGT), and heterogeneous graph contrastive learning (HGCL) were constructed, with a focus on message passing and aggregation mechanisms to learn the complex interaction patterns between scholars and topics, as well as to capture the patterns of topic diffusion and scholar topic selection. Based on feature aggregation, classifiers such as logistic regression, random forest, and multilayer perceptron have been used for recommendation discrimination. Empirical tests were conducted using data from 6,521 scholars at Renmin University of China and over 30,000 research topics covered by them from the Scopus database. The results showed that the recommendation model based on HGCL integrated with a multilayer perceptron had the highest precision (88.25%), representing a 9.29 percentage points improvement over the baseline model SVD. Meanwhile, the model based on HAN integrated with a multilayer perceptron outperformed the baseline model in terms of recall and F1-score, achieving 96.41% and 91.92%, respectively, representing 17.21 and 12.56 percentage points improvements. This is the first study to construct a research topic recommendation model for scholars, focusing on the representation and learning of heterogeneity in scholar and topic nodes, as well as their relationships. This study provides a reference method for personalized topic selection by scholars and topic-level academic resource recommendations.

Keywords: research topic recommendation; scholar topic recommendation; topic recommendation; heterogeneous graph neural networks; link prediction

0 引言

学者关于研究主题的选择对于学科发展和其职业生涯发展至关重要^[1]。有研究表明,学者研究兴趣的专注度与学术成果影响力之间存在正向关联^[2],研究选题更加广泛的学者往往拥有更长的职业生涯^[3]。随着不同研究领域的交叉融合,研究主题的丰富性、多样性与复杂性正在不断提升^[4],学者转换研究主题的现象也越来越普遍^[5]。但如何从海量主题中筛选出契合学者研究基础与研究兴趣的主题仍是亟待解决的一大难题。

个性化学术资源推荐是应对学术资源过载的有效手段之一,其基本思路是通过表征用户兴趣与资源特征向用户推荐与其需求相匹配的资源^[6]。学术资源推荐的对象主要包括论文^[7]、引文^[8]、学者^[9]、主题^[10]等,但现有研究主要聚焦于论文与引文推荐,关于主题推荐的研究相对比较匮乏。研究主题推荐是一种依托数据挖掘、自然语言处理、机器学习等技术,针对科研人员的个性化需求自动推送相关学术主题的信息服务,其核心目标是帮助学者快速定位有价值的研究方向。从推荐内容来看,现有研究更加关注热点主题分析和主题趋势预测^[11-12],虽然能为学者把握宏观研究趋势提供参考,但难以识别和满足其个性化需求。目前主流的推荐方法存在以下问题:基于内容的推荐方法过度依赖已有文本特征,难以有效捕捉学者的潜在研究兴趣^[13];基于协同过滤的推荐方法容易受到数据稀疏与冷启动问题的负面影响^[14];基于图的推荐方法主要采用随机游走或同质图神经网络技术框架,无法有效捕捉节点类型与关系类型的异质性^[15]。

针对上述问题,本文提出一种基于异质图神经网络的学者研究主题推荐模型,强调以关键词来表征研究主题,从而进行学者研究主题个性化推荐。该模型强调将主题推荐任务转化为链路预测任务,通过融合节点内容特征与结构特征刻画学者研究兴趣,并利用异质图神经网络的消息传递与聚合机制学习学者与主题间的复杂关联及异质信息,以期刻画主题扩散与学者选题的潜在规律,从而面向学者进行细粒度的个性化主题推荐。

1 相关工作

目前,学术资源推荐的方法主要有三种,分别是基于内容的推荐方法、基于协同过滤的推荐方法以及基于图的推荐方法^[6]。本节对三种推荐方法的思路进行了系统梳理,并对其在学者研究主题推荐任务中的适用性进行了分析。

1.1 基于内容的推荐方法

基于内容的推荐方法通过提取待推荐对象的内容特征向用户推荐与其研究兴趣相契合的项目。该方法早期主要基于TF-IDF (term frequency - inverse document frequency)^[16]、LDA (latent Dirichlet allocation)主题模型^[17]等简单的文本分析方法进行推荐。随着自然语言处理技术的发展,TextRank算法^[18]、深度学习^[19]、双向长短期记忆力网络^[20]等技术也被应用到学术资源推荐之中,提高了模型的内容挖掘能力。此外,部分研究通过捕捉上下文、语序、段落、篇章等文本结构特征,提高了模型对文本内容理解的精细程度^[21]。然而,由于忽略了学术实体间

的交互关系,该方法对学者潜在研究兴趣的识别能力通常较弱,难以实现个性化与新颖性推荐。

1.2 基于协同过滤的推荐方法

基于协同过滤的推荐方法是通过项目评分矩阵挖掘用户的潜在偏好^[22],从而为用户推荐符合其兴趣的项目。协同过滤法认为具有相似偏好的用户在行为上也会呈现一定的相似性^[23],因此,可以利用多个学者的已知偏好来为其他学者推荐感兴趣的资源。此外,融合引文关系^[24]、语义关系^[25]等特征,能够增强模型对学者特定偏好的识别能力,从而提升对特定类型学术资源的推荐性能。基于协同过滤的推荐方法需要大量的用户数据作为支撑,但在现实的学术网络中,大部分学者与主题之间不存在关联,这可能导致数据稀疏和冷启动问题^[16],使模型难以捕捉学者研究兴趣的全貌。

1.3 基于图的推荐方法

基于图的推荐方法则是通过图表示学习技术捕捉节点间的复杂交互关系以挖掘用户偏好并推荐相关内容^[26]。图表示学习技术能够通过学术网络的拓扑结构更加充分地挖掘学者的潜在研究兴趣,并缓解网络稀疏性导致的数据稀疏与冷启动问题。常用的图表示学习算法主要包括 DeepWalk^[27]、Node2Vec^[28]以及图神经网络^[29](graph neural network, GNN)等。DeepWalk 与 Node2Vec 是基于随机游走的技术框架,只能处理网络的拓扑结构,无法同时处理内容、行为、类别等辅助信息。图神经网络算法则能在处理网络拓扑结构的同时灵活处理多种辅助信息,并通过其消息传递与聚合机制捕捉节点间的依赖关系^[30]。然而,图卷积网络(graph convolutional network, GCN)、图注意力网络(graph attention networks, GAT)、GraphSAGE(graph sample and aggregated)等同质图神经网络算法没有考虑节点与边的异质性^[15],难以准确捕捉学者与主题节点在类型和关系上的差异。异质图神经网络算法将图神经网络拓展至异质图种,能够区分节点与边的类型差异^[31],比传统的同质图神经网络更加适用于主题推荐。

2 研究设计与模型构建

构建研究主题推荐模型,首先,需要明确如何表征研究主题的内涵。现有研究主题表征主要有专家定性概括的主题、定量词汇组合的主题、单一词汇表征的主题三种形式^[32]。专家定性概括的主题通

常由领域专家依据科学文献与专业知识提炼而成,虽具有较强的权威性和指导性,但也存在主观性强、抽象性高、实操成本高等弊端,不适用于大规模数据的处理。定量词汇组合的主题通常由基于聚类、社群探测或主题模型等技术自动生成的多词组合构成,其生成过程随机性较大,主题内的词汇往往存在含义分散、关联性弱、可解释性低等问题,不适用于对主题一致性及可解释性要求较高的任务场景。单一词汇表征的主题包括作者关键词、自动抽取词与系统分配词等形式,相较于其他主题类型具有表征粒度细、可操作性强等优点。其中,作者关键词由研究者本人标注,能够精准、直接地反映研究主题的内涵,被视为准确性最高操作性最强的表征方式^[33]。因此,本文强调以作者关键词来表征研究主题,即将每一个关键词都视作一个研究主题,为学者推荐研究选题。

其次,内容相似性与关系邻近性是主题推荐中需要着重考虑的两个因素。一方面,受知识结构与专业背景的限制,与学者过往研究相似度更高的主题更容易被选中。另一方面,通过与学者、论文、主题、学科等学术实体间的关联,学者也可以挖掘符合自身兴趣的主题,关系更邻近的主题则更容易被选中。例如,学者A的合作者B发表了一篇有关图机器学习的文章,通过B这一中介,A也可能研究与图机器学习相关的其他主题。因此,如何挖掘节点的文本内容特征与网络结构特征,捕捉并学习主题扩散与选题行为的潜在规律,是提升主题推荐准确率的关键。

鉴于此,本文设计了如图1所示的研究框架,包含数据收集和处理、异质信息网络构建、学者研究主题推荐模型构建三个模块。异质信息网络构建模块根据学者、文献、主题间的关系构建出“学者-文献-主题”异质信息网络。研究主题推荐模型有三个核心组件:首先是特征抽取与表示,本文强调先分别使用BigBird模型与DeepWalk算法生成节点的内容特征与结构特征,再采用Bi-LSTM(bi-directional long short-term memory)算法融合两类特征以生成节点初始嵌入;其次是基于异质图神经网络的特征聚合,分别基于HAN(heterogeneous graph attention network)、HGT(heterogeneous graph transformer)、HGCL(heterogeneous graph contrastive learning)聚合学者和主题邻域节点信息以及节点间的高阶关系,并生成节点最终嵌入;最后是机器学习分类器,将节点最终嵌入分别输入逻辑回归、随机森




图1 研究框架

林、多层感知机三种机器学习分类器，完成研究主题推荐。该模型强调利用异质图神经网络的消息传递与聚合机制来挖掘学者与主题间的内容相似性及关系邻近性，通过网络拓扑结构捕捉节点间的潜在复杂关联，以学习主题扩散与学者选题的潜在规律。

2.1 异质信息网络构建

同质信息网络（或同质图）由单一类型的节点和边构成，异质信息网络（或异质图）则包含两种及以上不同类型的节点和边。令一个图为 $G = (V, E)$ ，其中 V 是节点集合， E 是边集合，存在节点类型映射函数 $\phi: V \rightarrow A$ 和边类型映射函数 $\psi: E \rightarrow R$ ，其中 A 和 R 分别是节点类型集合与边类型的集合。若 $|A| + |R| > 2$ ，即节点类型数量与边类型数量大于2，则 G 为异质信息网络。图 2a 是一个学者合作网络，在该网络中，只存在学者节点和

合作关系连边，是一个典型的同质信息网络；图 2b 则包含学者和文献两种节点，以及引用和发表两种边，是一个典型的异质信息网络。

学者和主题之间的关系可以通过三部图进行建模。三部图是一种含有三种不同类型的节点且同类节点间不存在连边的异质图。如图 2c 所示，如果学者和文献之间存在发表关系，且文献含有若干主题，那么会在学者节点和文献节点之间创建边，同时在文献节点和主题节点之间创建边，由此即可得到“学者-文献-主题”异质信息网络。

2.2 特征抽取与表示

构建好异质信息网络后，需要抽取节点特征作为异质图神经网络的输入。根据前文论述，文本内容特征和网络结构特征能够表征节点内容属性与关系属性，从而反映学术实体的相关研究内容及其在




图2 学术实体关系网络示意图

学术网络中的位置关系,为后续的特征聚合与链路预测奠定基础。

首先,通过处理节点关联文献的标题与摘要生成节点内容特征。对于学者节点,选择学者发表文章的标题和摘要作为内容文本;对于主题节点,则选择研究过该主题文章的摘要作为内容文本。然后,使用BigBird^[34]模型生成节点内容特征。该模型在Transformer架构的基础上引入了稀疏注意力机制,在保证模型能够捕捉文本中的重要语义信息和长距离依赖关系的同时,提高了模型对长文本序列的处理能力与效率。

其次,本文使用DeepWalk算法生成网络结构特征。DeepWalk算法能够通过随机游走过程获取目标节点的多条节点序列,从而挖掘节点间的潜在联系。例如,“学者A—文献—学者B”路径表示学者A和学者B之间存在合作关系,那么与学者B相关联的主题有可能扩散到学者A。然后,将随机游走获取的节点序列输入Skip-Gram模型,以生成节点的网络结构特征。

对于每节点 i ,通过上述步骤可以获得其内容特征向量 $\mathbf{x}_{\text{content}}^i$ 和结构特征向量 $\mathbf{x}_{\text{structure}}^i$ 。使用Bi-LSTM算法融合两类特征以生成节点的初始嵌入,即

$$\mathbf{e}_i^0 = \text{Bi-LSTM}(\mathbf{x}_{\text{content}}^i, \mathbf{x}_{\text{structure}}^i) \quad (1)$$

其中, $\mathbf{e}_i^0$ 是节点 i 的初始嵌入。Bi-LSTM模型含有正向和反向两个LSTM^[35],能够从两个方向捕捉上下文信息。与简单的特征拼接或求和不同,Bi-LSTM模型能够捕捉内容特征与结构特征间的深层关系,在异质特征融合方面十分有效。

2.3 基于异质图神经网络的学者和主题特征聚合

获得节点初始嵌入后,本文利用图神经网络的消息传递与聚合机制聚合邻域节点特征,以自动捕

捉节点间的高阶连接关系。由于同质图神经网络无法捕捉节点类型与关系类型的异质性,本文分别基于异质图注意力网络^[31](HAN)、异质图Transformer模型^[36](HGT)、异质图对比学习模型^[37](HGCL)构建三种学者与主题特征聚合模式,以增强模型对节点异质性与关系异质性的表征与学习能力。

(1) 基于HAN的特征聚合

HAN是一种基于双层注意力机制的异质图神经网络,包含节点级注意力和语义级注意力两层结构,其模型架构如图3所示。在节点级注意力中,需要先人工定义元路径的约束下获取邻域节点,再使用注意力机制聚合邻域节点特征。元路径是网络中连接两个节点的特定路径,不同的元路径可以表征学术实体间的不同关系。本文共定义了四条元路径(表1),以“学者→文献→学者”为例,若两名学者与同一篇文章产生链接,则说明两名学者间存在合作关系。

对于异质图 $G=(V,E)$ 中的节点 $\mathbf{v}_1$,其元路径定义为 $P: \mathbf{v}_1 \xrightarrow{e_1} \mathbf{v}_2 \xrightarrow{e_2} \dots \xrightarrow{e_{n-1}} \mathbf{v}_n$,则节点 $\mathbf{v}_1$ 在该条元路径约束下的邻域节点集合记为 $N_1^P = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ 。同理,任意节点 i 基于元路径 P 的邻域节点集合可记为 N_i^P 。对于通过 P 连接的两个节点 i 和 j ,计算其节点注意力系数,并使用softmax函数进行归一化处理,计算方法为

$$\alpha_{ij}^P = \text{softmax}\left(\text{attention}_{\text{node}}(\mathbf{e}_i^0, \mathbf{e}_j^0; P)\right) \quad (2)$$

为提高训练过程的稳定性,HAN将节点级注意力重复执行了 K 次,然后拼接 K 个注意力头的结果,计算方法为

$$\mathbf{e}_i^P = \big\|_{k=1}^K \sigma\left(\sum_{j \in N_i^P} \alpha_{ij}^P \cdot \mathbf{h}_j\right) \quad (3)$$

其中, $\mathbf{e}_i^0$ 和 $\mathbf{e}_j^0$ 分别是节点 i 和节点 j 的初始嵌入; $\text{attention}_{\text{node}}$ 是执行节点级注意力的深度神经网络;




图3 基于异质图注意力网络(HAN)的学者和主题特征聚合

表1 元路径设计与含义

元路径设计	图示	元路径含义
学者→文献→学者		学者合作关系
学者→文献→主题		学者研究兴趣
学者→文献→主题→文献→学者		学者兴趣相关
主题→文献→主题		主题共现关系

e_i^P 是节点 i 基于元路径 P 的学习嵌入； σ 是激活函数 ReLU； $\parallel$ 是向量拼接操作。

根据上述方法，可以得到节点 i 基于 n 条元路径的 n 个学习嵌入，通过语义级注意力聚合不同元路径下的节点表示，计算方法为

$$(\beta_i^{P_1}, \beta_i^{P_2}, \dots, \beta_i^{P_n}) = \text{softmax}(\text{attention}_{\text{semantic}}(e_i^{P_1}, e_i^{P_2}, \dots, e_i^{P_n})) \quad (4)$$

$$e_i = \sum_{n=1}^N \beta_i^{P_n} \cdot e_i^{P_n} \quad (5)$$

其中， $\beta_i^{P_n}$ 是元路径 P_n 的学习权重； $\text{attention}_{\text{semantic}}$ 是执行语义级注意力的深度神经网络； e_i 是节点 i 的最终嵌入。通过双层注意力机制，HAN 能够在聚合邻域节点特征的同时，通过人工定义元路径学习不同关系类型的语义差异，进而捕捉学者与主题节点间交互方式的异质性。

(2) 基于 HGT 的特征聚合

与 HAN 不同，HGT 通过元关系语义信息自动捕捉节点与关系的异质性，更适用于处理大规模数据。元关系是含有节点类型与边类型信息的三元组，对于从源节点 j 指向目标节点 i 的边 e ，其元关系定义为 $\langle \phi(j), \psi(e), \phi(i) \rangle$ 。例如，对于一条从学者指向主题的连边，其元关系为 $\langle \text{学者}, \text{研究兴趣}, \text{主题} \rangle$ 。

HGT 由三个部分构成，分别是异质互注意力、异质消息传递以及消息聚合，模型构架如图 4 所示。异质互注意力模块利用多头自注意力机制，将




图4 基于异质图Transformer(HGT)的学者和主题特征聚合

目标节点嵌入转换为键向量 K_i ，将源节点嵌入转换为查询向量 Q_j 和值向量 V_j ，通过拼接多个注意力头的结果计算节点注意力系数，计算方法为

$$\text{attention}_{(j,e,i)} = \text{softmax}_{\forall j \in N_i} \left(\parallel_{m \in [1,n]} \text{attention-head}_m(j,e,i) \right) \quad (6)$$

其中， $\text{attention}_{(j,e,i)}$ 是节点对 (j,e,i) 的注意力系数； N_i 是目标节点 i 的邻居集合； attention-head_m 是第 m 个注意力头的结果。

在异质消息传递模块中，首先，基于元关系对源节点 i 的值向量进行参数化处理，以融入特定连边的节点类型与边类型信息。其次，拼接节点对 (j,e,i) 的 n 个消息头以生成最终的异质消息，计算方法为

$$\text{message}_{(j,e,i)} = \parallel_{m \in [1,n]} \text{message-head}_m(j,e,i) \quad (7)$$

在消息聚合模块中，先以注意力系数为权重聚合邻居节点的异质消息，再通过非线性激活操作将目标节点 i 的表示映射到对应节点类型的分布中，最后，堆叠上一层 HGT 的输出 e_i^{l-1} 以生成节点 i 在第 l 层的最终嵌入 e_i^l ，计算方法为

$$e_i^l = \sigma A_Linear_{\phi(i)} \cdot \bigoplus_{\forall j \in N_i} \left(\text{attention}_{(j,e,i)} \cdot \text{message}_{(j,e,i)} \right) + e_i^{l-1} \quad (8)$$

其中， σ 为激活函数 ReLU； $A_Linear_{\phi(i)}$ 是线性变换函数； $\bigoplus$ 是聚合函数。

(3) 基于 HGCL 的特征聚合

HGCL 从“学者-文献-主题”三部图中抽取“学者-学者”视图、“主题-主题”视图与“学者-主

题”视图（分别记为 G_{aa} 、 G_{tt} 和 G_{at} ），分别用于表示学者合作关系、主题共现关系以及学者研究兴趣三种核心的关系类型。HGCL 的策略是通过融合从异质视图中捕捉到的网络结构信息对学者与主题间的复杂交互模型进行建模。HGCL 含有异质图关系学习、跨视图元学习以及异质关系对比学习三个部分，模型架构如图 5 所示。

在异质图关系学习模块中，首先，使用 GCN 在“学者-主题”视图中聚合异质邻居的特征，计算方法为

$$e_a^{l+1} = \sum_{t \in N_a} \frac{e_t^l}{\sqrt{|N_a|} \sqrt{|N_t|}}, e_t^{l+1} = \sum_{a \in N_t} \frac{e_a^l}{\sqrt{|N_a|} \sqrt{|N_t|}} \quad (9)$$

其中， e_a^l 和 e_t^l 分别是作者节点和主题节点在第 l 层的节点嵌入； N_a 和 N_t 分别是学者节点 a 和主题节点 t 的邻居集合。所有学者节点的嵌入和所有主题节点的嵌入分别构成了节点属性嵌入矩阵 E_a^l 和 E_t^l 。为捕捉其他视图的结构特征，HGCL 通过一个自门控模块从节点嵌入矩阵中推导出节点在“学者-学者”视图和“主题-主题”视图中的关系感知嵌入矩阵，分别记为 E_{aa}^l 和 E_{tt}^l 。其次，通过逐元素均值池化聚合同类节点的节点属性嵌入矩阵与关系感知嵌入矩阵。最后，通过归一化残差连接整合每层 HGT 的输出以生成整体节点嵌入，计算方法为

$$E_a = E_a^0 + \sum_{l=1}^L \frac{E_a^l}{\|E_a^l\|}, E_t = E_t^0 + \sum_{l=1}^L \frac{E_t^l}{\|E_t^l\|} \quad (10)$$

其中， E_a^0 和 E_t^0 分别是学者与主题的整体节点嵌入矩阵，通过类似的方法可以生成学者与主题的整体关系嵌入矩阵 E_{aa} 和 E_{tt} 。




图5 基于异质图对比学习(HGCL)的学者和主题特征聚合

在主题推荐任务中,学者的选题偏好对相关学者、相关主题以及研究兴趣等信息的敏感性存在个体差异, HGCL的跨视图元学习模块则能够通过个性化知识传递挖掘和强化学者的个体偏好。先通过拼接同类节点的节点属性嵌入、关系感知嵌入以及异质邻居嵌入之和分别提取学者与主题节点的元知识;然后通过一个由两层MLP (multilayer perceptron) 构成的元知识学习器生成知识迁移矩阵;最后,使用知识迁移矩阵增强关系感知嵌入以生成节点的最终嵌入矩阵,计算方法分别为

$$M_{aa} = E_u \| E_{uu} \| \sum_{t \in N_a} e_t \quad (11)$$

$$E_{aa}^M = \sigma(f_{MLP}^1(M_{aa}) f_{MLP}^2(M_{aa}) E_{aa}) \quad (12)$$

$$E'_a = \lambda_a \cdot E_a + (1 - \lambda_a) \cdot (E_{aa} + E_{aa}^M) \quad (13)$$

其中, M_{aa} 是学者节点的元知识; E_{aa}^M 是学者节点的知识迁移矩阵; σ 是 PReLU 激活函数; λ_a 是一个超参数, 能够控制节点属性嵌入和关系感知嵌入的权重。这里以学者节点最终嵌入矩阵 E'_a 的计算过程为例, 同理可生成主题节点最终嵌入矩阵 E'_t 。

在异质关系对比学习模块中, 模型通过优化 InfoNCE (information noise contrastive estimation) 损失函数对齐不同视图的嵌入, 并更新节点的最终嵌入。InfoNCE 损失函数利用余弦相似度来衡量不同视图下节点特征的相似程度, 使相似的样本在特征空间距离更近、不同的样本距离更远, 从而提高模型对潜在链路的识别能力。

2.4 机器学习分类器

通过特征聚合生成节点最终嵌入后, 本文将嵌入向量分别输入逻辑回归、随机森林和多层感知机三种机器学习分类器, 并通过预测学者节点与主题节点间是否存在连边进行主题推荐。逻辑回归是一种基于概率的线性分类模型, 其核心目标是通过线性组合输入特征, 并利用 Sigmoid 函数将输出映射为概率值。逻辑回归分类器具有较高的计算效率, 但其本质上是线性模型, 对复杂网络结构的建模能力有限。随机森林是一种基于 Bagging 集成的非线性分类算法, 通过构建多棵决策树并聚合决策树结果以提升模型泛化性能。

在链路预测中, 随机森林能够自动捕捉节点间的非线性关系, 其优势在于无须复杂特征工程即可实现非线性建模。多层感知机是一种前馈神经网络, 利用多个非线性隐藏层对节点间的抽象特征进行建模, 具有优秀的非线性建模能力, 通过增加深度结构, 可以学习到更复杂的特征表达, 更适用于复杂模式识别任务。

对于一个学者节点 a 和主题节点 t 构成的节点对 (a, t) , 若该节点对之间存在链接, 则记为 $y_{at} = 1$; 否则, 记为 $y_{at} = 0$ 。然后, 将节点对的嵌入进行拼接, 分别输入三种机器学习分类器。若分类器输出的结果为 $\hat{y}_{at} = 1$, 则说明该节点对间存在预测边, 应当将主题 t 推送给学者 a ; 否则, 不予推荐。

3 实验与分析

3.1 数据收集与预处理

本文的研究数据来自 Scopus 数据库，通过检索式 AFFILCOUNTRY (China) AND LANGUAGE (English) 查询到 800 万余条文献记录，其中绝大多数文献发表于 2000 年后。受限于计算成本，本文对数据规模进行调整，将中国人民大学学者于 2000—2023 年参与发表的综述论文 (review) 与研究论文 (article) 作为最终的研究数据集。调整后的检索式为 AF-ID ("Renmin University of China" 60014402) AND LANGUAGE (English) AND PUBYEAR>1999 AND PUBYEAR<2024 AND (DOCTYPE (re) OR DOCTYPE (ar))，共检索得到 15212 条文献记录。

获得原始数据后，需要对数据进行处理并构建实验所需的异质图。Scopus 数据库的字段包含“作者”“作者 ID”“归属机构”“EID”“作者关键词”等。其中，“EID” (electronic identity) 是文献唯一标识符，“作者 ID” (author identifier) 是学者唯一标识符，通过唯一标识符可以有效区分不同的学术实体。首先，本文根据 EID 进行文献去重处理，最终抽取出 13802 篇文献。其次，根据“归属机构”与“作者 ID”字段，抽取出归属机构为人民大学的学者，删除重复值后，共抽取出 6521 名学者。再其次，参考 Huo 等^[33]的做法，将“作者关键词”作为主题词，对词形、大小写进行标准化处理，并删掉标点与多余空格，共抽取出 30380 个主题。最后，根据 2.1 节介绍的方法，在关联节点之间创建边，即可得到“学者-文献-主题”异质图，其构成如表 2 所示。

表 2 “学者-文献-主题”异质图构成

节点		边	
类型	数量	类型	数量
学者	6521	学者-文献	28968
文献	13802	文献-主题	56031
主题	30380	学者-学者	31838
—	—	主题-主题	106990
总计	50703	总计	223827

表 3 是学者、文献和主题三类节点相关内容的示例，同类节点按入度降序排列。可以发现，每个节点都标识了节点类型、节点 ID 以及节点标签等信息。主题节点由单一作者关键词构成，其中热点主题词包括“COVID19”“machine learning”“economic

growth”“climate change”等，由此可见，中国人民大学学者更加关注国内及热点问题，而且其研究方向并不局限于人文社会科学，与计算机科学与技术、环境科学等理工类学科存在较强的交叉性。

表 3 节点内容示例

节点类型	节点 ID	节点标签
主题	15800	COVID19
主题	1508	adolescent
主题	4149	social network
主题	3086	machine learning
主题	935	economic growth
主题	1273	climate change
学者	351	Chen, Zili
学者	22	Zhang, Bo
学者	2033	Zhedanov, Alexei
学者	844	Liu, Liguang
学者	605	He, Qing
学者	367	Li, Huanrong
学者	273	Gao, Jinwu
文献	10663	Activated sludge process enabling highly efficient removal of heavy metal in wastewater
文献	461	Educational publishing in China: status quo, problems and counter measures
文献	162	Database research: achievements and challenges
文献	10577	Preparation and application of ZrO ₂ -SiO ₂ complex oxide for efficient biocrude generation by hydrothermal liquefaction of Spirulina
文献	2565	Highly N ₂ -selective coupling of 1, 2, 3-triazoles with indole and pyrrole
文献	2775	Career adaptability, calling and the professional competence of social work students in China: a career construction perspective

3.2 基线模型

为了验证异质图神经网络算法在主题推荐任务中的有效性，本文将基于异质图神经网络的特征聚合与机器学习分类器两个模块替换为三个基线模型，分别是 co-clustering 算法、SVD (stable video diffusion) 算法以及 Slope One 算法。与异质图神经网络不同，这三种算法忽略了学术实体关系的异质性，很难充分捕捉学者与主题间的复杂关联。

(1) co-clustering 算法^[38]：一种无监督学习算法，能够对矩阵的行和列同时进行聚类，从而揭示数据间的潜在关联。在主题推荐任务中，co-clustering

能够同时对学者与主题进行聚类，并挖掘类之间的相似性，从而预测节点间产生链接的概率。

(2) SVD算法^[39]：一种矩阵分解技术，能够将用户-项目评分分解为低维矩阵，并通过低维表示捕捉用户和物品之间的关联。在主题推荐任务中，SVD算法能够挖掘学者节点与主题节点间的潜在关联以实现主题推荐。

(3) Slope One算法^[40]：一种基于用户相似性的协同过滤算法，该算法先基于用户项目评分衡量用户间的偏好相似性，再根据相似用户的偏好为目标用户提供推荐项目。在主题推荐任务中，Slope One能够挖掘学者研究偏好，并根据相关学者的研究兴趣为目标学者推荐潜在研究主题。

3.3 实验设置与评价指标

本文模型在Pytorch深度学习框架上进行训练，数据集由“学者-主题”节点对构成，在真实网络中存在连边的节点对即为正样本。学术网络具有稀疏性，大部分节点间不存在连边，因此，需要通过负采样来保证正负样本的平衡性。本文采取的负采样策略是，在所有节点之间随机生成边，排除掉真实存在的边后，剩余的边所对应的节点对即为负样本；当负样本与正样本数量达到1:1时，停止采样。之后，按照8:2将数据集划分为训练集与测试集两个部分，并采用随机均匀抽样保证训练集与测试集数据分布的一致性。

训练过程中，对特征抽取与表示、基于异质图神经网络的特征聚合、机器学习分类器三个模块分别进行优化。首先，通过特征抽取与表示模块分别生成学者、文献、主题三类节点的内容特征与结构特征。本文使用bigbird-pegasus-large预训练模型生成768维的内容特征向量，使用DeepWalk生成128维的结构特征向量，并采用Bi-LSTM模型融合两类特征并生成128维的节点初始嵌入。其次，将节点初始嵌入分别输入HAN、HGT和HGCL三种异质图神经网络，以生成聚合邻域节点特征后的节点最终嵌入。其中，HAN与HGT中注意力头的数量设置为8，HGCL中异质关系对比学习板块采用的正负样本比例为1:1。最后，将“学者-主题”节点对的最终嵌入进行拼接，分别输入逻辑回归、随机森林、多层感知机三种分类器。若节点对的输出标签为1，表明相应的学者与主题间存在预测边，应当将该主题节点对应的学者关键词推荐给这名学者；否则，不予推荐。

最后，通过测试集上的连边预测结果与真实网络结构的差异衡量推荐模型效果。本文选用精确率(precision)、召回率(recall)和F1值三项指标评价模型性能。精确率是被模型预测为正例的实例中真正例的比例，用于衡量预测结果的可靠性和准确性。召回率是模型预测出的真正例占有真正例的比例，召回率高的模型能够识别出更多的正样本，反映了模型的样本识别与覆盖能力。F1值是精确率和召回率的调和平均值，常被用于评估模型的整体性能。

3.4 实验结果与分析

本文共进行了12组对比实验，以探究不同类型的异质图神经网络和机器学习分类器对主题推荐模型性能的影响，并与三种基线模型的结果进行对比，实验结果如表4所示。三个基线模型中，SVD的表现最佳，其精确率、召回率和F1值分别达到78.96%、79.20%和79.36%。HGCL搭配多层感知机的模型在精确率上表现最佳，达到88.25%，相对于基线模型SVD提升了9.29个百分点；HAN搭配多层感知机的模型在召回率和F1值上表现最佳，分别达到96.41%和91.92%，相对于基线模型SVD分别提升了17.21和12.56个百分点。这说明异质图神经网络的综合表现优于最佳基线模型，验证了该模型在主题推荐任务中的有效性。

表4 研究主题推荐对比实验结果

	模型	精确率/%	召回率/%	F1值/%
基线模型	co-clustering	76.49	75.76	75.52
	SVD	<u>78.96</u>	<u>79.20</u>	<u>79.36</u>
	Slope One	77.60	77.52	77.57
HAN	逻辑回归	70.12	75.25	72.30
	随机森林	83.93	82.02	82.96
	多层感知机	87.84	96.41	91.92
HGT	逻辑回归	78.17	75.57	76.85
	随机森林	78.20	81.85	79.98
	多层感知机	85.82	91.31	88.48
HGCL	逻辑回归	79.20	76.20	77.67
	随机森林	80.15	83.10	81.62
	多层感知机	88.25	92.75	90.50

注：下划线表示基线模型中的最优值，粗体表示所有模型中的最优值。

横向对比三种异质图神经网络学者和主题特征聚合模式，HAN的综合表现最好，HGCL次之，HGT的综合表现相对较差。这一性能差异主要源于

三者在处理异质关系时采用了不同的策略。HAN依赖于预定义的元路径来聚合邻居信息,这种方式能够基于局部网络结构对学者合作、学者兴趣、主题共现等不同类型的关系进行严格定义,能精准捕捉学术网络中具有明确语义的关系,具有较高的准确性与可靠性。HGCL是通过构建“学者-学者”“主题-主题”“学者-主题”多个视图并利用正负样本的对比学习来增强节点特征,其优势在于能缓解数据稀疏性问题,并通过对比学习有效捕捉学者偏好的不变性表征,具有较强的学者兴趣识别能力。HGT则是通过元关系语义自动捕捉实体间的异质关系,虽然这种算法灵活性较高、更适合大规模图,但其邻居采样过程可能引入更多噪声,从而降低模型的推荐精度。在本文构建的学术网络中,学者、文献、主题间的异质关系具有较强的可解释性,HGT的自动化策略反而可能模糊了已知的、重要的网络语义关系,导致其性能相对较弱。由此可见,在学术网络这类关系语义较为明确的场景中,引入自定义元路径这类基于网络拓扑结构精确定义关系类型的强约束条件能更有效地引导模型学习,而基于元关系语义这类不依赖网络结构的方式定义关系类型,则可能因缺乏约束而降低模型性能。

三种学者和主题特征聚合模式在实际应用中各具优势,应当根据使用场景差异进行合理选择。HAN通常为首选方案,但其过于依赖人工设计元路径,可能会产生语义覆盖不全或模型复杂度过高的问题,因此不适合处理结构复杂或规模较大的数据。HGCL的对比学习机制能有效缓解数据稀疏性问题,在新兴领域、冷门主题等对推荐新颖性要求较高的场景中具有较高的适用性。HGT虽然性能相对较差,但其在多层感知机上的F1值比最好的基线模型高出9.12个百分点,说明其仍具有一定的应用价值。在面对超大规模学术网络时,HGT的元关系语义能够灵活地表达多种关系语义,能够避免复杂耗力的元路径设计或跨视图学习过程,从而降低训练成本,提升训练效率。

此外,机器学习分类器对模型性能也存在显著影响。横向对比三种分类器,多层感知机的表现显著优于其他分类器,而逻辑回归的表现则显著差于其他分类器。MLP具有强大的非线性表征能力,上游异质图神经网络生成的高维嵌入中蕴含复杂的非线性模式,MLP能有效捕捉这些模式,从而实现精准的链路预测。逻辑回归作为一种线性模型,难以刻画高维嵌入向量中的复杂模式,因此性能最差。

随机森林虽然也具有一定的非线性建模能力,但其决策树机制在处理高维稠密向量时,不如MLP的连续梯度优化机制灵活高效。

4 结语

为帮助学者选取契合其研究基础和研究兴趣的主题,本文构建了一种基于异质图神经网络的学者研究主题推荐模型,并以Scopus数据库中6521名来自中国人民大学的学者为例,通过12组实验评估模型性能,详细分析了模型各个模块对推荐性能的影响。

研究发现:其一,本文提出的基于异质图神经网络的推荐模型,相较于最佳基线模型在精确率、召回率和F1值上分别提升了9.29、17.21和12.56个百分点,充分证明了该模型在主题推荐任务中的优越性;其二,基于HGCL学者和主题特征聚合模式并搭配多层感知机的推荐模型,在精确率上的表现最佳,基于HAN学者和主题特征聚合模式并搭配多层感知机的推荐模型在召回率和F1值上表现最佳;其三,横向对比三种异质图神经网络聚合模式,通过自定义元路径定义关系类型的HAN综合表现最好,说明基于网络拓扑结构对节点关系类型进行精确定义是提升推荐性能的关键;其四,从分类器角度来看,多层感知机在学者主题推荐任务上的表现最佳,说明对复杂数据特征学习能力较强的分类算法更适用于主题推荐。

本文首次尝试构建学者研究主题推荐模型,强调对学者与主题节点异质性和关系异质性的表征和学习,为学者个性化选题以及主题层面的学术资源推荐提供了一种参考方法。本文通过将异质图神经网络算法引入“主题推荐”这一具体任务场景,提升了模型对学者与主题节点间复杂关联模式的挖掘能力以及对节点异质性和关系异质性的表征能力,可以更加准确地学习主题扩散与学者选题的潜在规律,从而实现面向学者的个性化主题推荐。通过与基线方法的对比,验证了本文模型在学者研究主题推荐中的有效性,并通过多组实验对比了HAN、HGT和HGCL三种学者和主题特征聚合模式的性能,为类似任务场景中的方法研究提供了参考。从实践层面来看,本文提出的模型能够从大量研究主题中筛选出与学者研究基础和研究兴趣较匹配的主题,从而帮助学者提高选题效率、获取创新灵感、拓展研究思路。受算力成本和同名学者姓名消歧等因素的限制,本文仅使用了具有较高质量的中国人

民大学学者数据，并以人文社会学科为主；该模型在自然科学等其他学科方面的效果还有待进一步验证。未来应拓宽学科范围、扩充数据规模，进一步根据不同学科规律调整模型结构、优化聚合模式，以提高模型在不同学科领域数据上的效果，进而赋予模型多学科、多场景的泛化能力。

参 考 文 献

- [1] 霍朝光, 张斌, 董克. 复杂网络视域下的学术行为预测研究述评: 选题、合作与引用[J]. 情报理论与实践, 2021, 44(6): 180-188, 27.
- [2] Amjad T, Daud A, Song M. Measuring the impact of topic drift in scholarly networks[C]// Companion Proceedings of the Web Conference 2018. Republic and Canton of Geneva: International World Wide Web Conferences Steering Committee, 2018: 373-378.
- [3] Ma Y H, Ji Z X, Song L. A two-layer network model reveals the adhesion scientist career stage and research topic in China[J]. IEEE Access, 2020, 8: 52726-52737.
- [4] Ledford H. How to solve the world's biggest problems[J]. Nature, 2015, 525(7569): 308-311.
- [5] Zeng A, Shen Z S, Zhou J L, et al. Increasing trend of scientists to switch between topics[J]. Nature Communications, 2019, 10: Article No.3439.
- [6] 蒲姗姗, 何燕. 个性化学术资源推荐研究: 现状、特点及展望[J]. 图书馆学研究, 2019(16): 9-17.
- [7] 张晓娟, 刘怡均, 刘杰, 等. 个性化学术论文推荐研究综述[J]. 情报学报, 2024, 43(1): 106-126.
- [8] 霍朝光, 但婷婷, 罗飞, 等. 基于图神经网络的跨学科引文推荐方法研究[J]. 情报理论与实践, 2025, 48(7): 189-198.
- [9] Huo C G, Li W J, Han Y J. Recommendation for scholar interdisciplinary collaboration[C]// Proceedings of the Eighteenth International ISKO Conference. Würzburg: Ergon-Verlag, 2024: 371-378.
- [10] Malhotra R, Taneja A, Arora A. Temporal recommendations for discovering author interests[C]// Proceedings of the 2019 Twelfth International Conference on Contemporary Computing. Piscataway: IEEE, 2019: 1-6.
- [11] Jelodar H, Wang Y L, Xiao G, et al. Recommendation system based on semantic scholar mining and topic modeling on conference publications[J]. Soft Computing, 2021, 25: 3675-3696.
- [12] Paul D, Chakdar D, Saha S, et al. Online research topic modeling and recommendation utilizing multiview autoencoder-based approach[J]. IEEE Transactions on Computational Social Systems, 2024, 11(1): 1013-1022.
- [13] 李跃艳, 王昊, 邓三鸿, 等. 近十年信息检索领域的研究热点与演化趋势研究——基于 SIGIR 会议论文的分析[J]. 数据分析与知识发现, 2021, 5(4): 13-24.
- [14] Parvatikar S, Joshi B. Online book recommendation system by using collaborative filtering and association mining[C]// Proceedings of the 2015 IEEE International Conference on Computational Intelligence and Computing Research. Piscataway: IEEE, 2015: 1-4.
- [15] Zhang C X, Song D J, Huang C, et al. Heterogeneous graph neural network[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York: ACM Press, 2019: 793-803.
- [16] Nascimento C, Laender A H F, da Silva A S, et al. A source independent framework for research paper recommendation[C]// Proceedings of the 11th Annual International ACM/IEEE Joint Conference on Digital Libraries. New York: ACM Press, 2011: 297-306.
- [17] Amami M, Pasi G, Stella F, et al. An LDA-based approach to scientific paper recommendation[C]// Proceedings of 21st International Conference on Applications of Natural Language to Information Systems. Cham: Springer, 2016: 200-210.
- [18] 李晓敏, 王昊, 李跃艳. 基于细粒度语义实体的学术论文推荐研究[J]. 情报科学, 2022, 40(4): 156-165.
- [19] 屈冰洋, 王亚民. 基于深度学习的科技信息文献推荐模型研究[J]. 情报理论与实践, 2021, 44(11): 160-165.
- [20] 杨秀璋, 武帅, 杨琪, 等. 多视图融合 TextRCNN 的论文自动推荐算法[J]. 计算机工程与应用, 2023, 59(2): 110-119.
- [21] Tan S C, Zhang T, Zhao S, et al. Self-supervised scientific document recommendation based on contrastive learning[J]. Scientometrics, 2023, 128(9): 5027-5049.
- [22] Di Rocco J, Di Ruscio D, Di Sipio C, et al. TopFilter: an approach to recommend relevant GitHub topics[C]// Proceedings of the 14th ACM / IEEE International Symposium on Empirical Software Engineering and Measurement. New York: ACM Press, 2020: Article No.21.
- [23] Pennock D M, Horvitz E J, Lawrence S, et al. Collaborative filtering by personality diagnosis: a hybrid memory- and model-based approach[C]// Proceedings of the 16th Uncertainty in Artificial Intelligence. San Francisco: Morgan Kaufmann, 2000: 473-480.
- [24] Wang W, Tang T, Xia F, et al. Collaborative filtering with network representation learning for citation recommendation[J]. IEEE Transactions on Big Data, 2022, 8(5): 1233-1246.
- [25] Izadi M, Nejati M, Heydarnoori A. Semantically-enhanced topic recommendation systems for software projects[J]. Empirical Software Engineering, 2023, 28(2): Article No.50.
- [26] Gupta S, Varma V. Scientific article recommendation by using distributed representations of text and graph[C]// Proceedings of the 26th International Conference on World Wide Web Companion. Republic and Canton of Geneva: International World Wide Web Conferences Steering Committee, 2017: 1267-1268.

- [27] Sedhain S, Menon A K, Sanner S, et al. AutoRec: autoencoders meet collaborative filtering[C]// Proceedings of the 24th International Conference on World Wide Web. New York: ACM Press, 2015: 111-112.
- [28] Cao S S, Lu W, Xu Q K. Deep neural networks for learning graph representations[C]// Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2016: 1145-1152.
- [29] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61-80.
- [30] Wu Z H, Pan S R, Chen F W, et al. A comprehensive survey on graph neural networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(1): 4-24.
- [31] Wang X, Ji H Y, Shi C, et al. Heterogeneous graph attention network[C]// Proceedings of the World Wide Web Conference. New York: ACM Press, 2019: 2022-2032.
- [32] 霍朝光. 科学预测——预见科学之美[M]. 北京: 清华大学出版社, 2025: 57-60.
- [33] Huo C G, Han Y J, Huo F F, et al. An approach for interdisciplinary knowledge discovery: link prediction between topics[J]. Physica A: Statistical Mechanics and Its Applications, 2025, 665: 130517.
- [34] Zaheer M, Guruganesh G, Dubey A, et al. BigBird: transformers for longer sequences[C]// Proceedings of the 34th Conference on Neural Information Processing Systems. Red Hook: Curran Associates, 2020: 17283-17297.
- [35] Schuster M, Paliwal K K. Bidirectional recurrent neural networks [J]. IEEE Transactions on Signal Processing, 1997, 45(11): 2673-2681.
- [36] Hu Z N, Dong Y X, Wang K S, et al. Heterogeneous graph transformer[C]// Proceedings of the Web Conference 2020. New York: ACM Press, 2020: 2704-2710.
- [37] Chen M R, Huang C, Xia L H, et al. Heterogeneous graph contrastive learning for recommendation[C]// Proceedings of the Sixteenth ACM International Conference on Web Search and Data Mining. New York: ACM Press, 2023: 544-552.
- [38] He X R, Liu S, Keung J, et al. Co-clustering for federated recommender system[C]// Proceedings of the ACM Web Conference 2024. New York: ACM Press, 2024: 3821-3832.
- [39] Ba Q L, Li X Y, Bai Z Y. Clustering collaborative filtering recommendation system based on SVD algorithm[C]// Proceedings of the 2013 IEEE 4th International Conference on Software Engineering and Service Science. Piscataway: IEEE, 2013: 963-967.
- [40] Lemire D, Maclachlan A. Slope One predictors for online rating-based collaborative filtering[C]// Proceedings of the 5th SIAM International Conference on Data Mining. Philadelphia: SIAM, 2005: 471-475.

(责任编辑 魏瑞斌)