

基于 CCA 的学术论文画像： 理论框架与实证研究

王心玥，赵丹群

(北京大学信息管理系，北京 100871)

摘 要 学术论文画像主要分为基于原文语料的静态画像和基于引文语料的动态画像两大类。本文聚焦后者，将最新的引文内容分析 (citation content analysis, CCA) 方法引入画像研究，通过收集同行引用语料对论文发表后产生的“学术影响”进行动态刻画和精准标识，画像成果对论文评价和学术资源检索/推荐等下游任务的解决具有重要支撑作用。首先，基于理论分析，构建“影响力-影响域-影响路径”三维度学术论文画像框架 (impact power, impact field & impact path, Im-PFP)；其次，选择单篇高被引文献“Co-citation in the scientific literature: a new measure of the relationship between two documents” (Small, 1973) 作为研究案例，运用自建的完整引文语料集，开展论文画像实证研究。实证研究检验了所提三维度画像框架 Im-PFP 的普适性和应用价值，其可拓展到不同学科领域的单篇或多篇高被引论文的画像研究。画像结果不仅可对案例文献的学术生命周期进行阶段划分，还可对其学术影响力、影响域和影响路径的历时性变化进行深度解读和评价分析。

关键词 论文画像；引文内容分析；生命周期；引文主题识别；主路径分析

Academic Paper Profiling Based on CCA: A Theoretical Framework and Empirical Study

Wang Xinyue and Zhao Danqun

(Department of Information Management, Peking University, Beijing 100871)

Abstract: Academic paper profiling can be categorized into two types: static profiling based on full text and dynamic profiling based on its citation corpus. This study focuses on the latter, and introduces citation content analysis (CCA) method to dynamically characterize a paper's academic impact by collecting and analyzing peer-cited texts after its publication. Such dynamic profile provides critical support for downstream tasks such as paper evaluation and academic resource retrieval and recommendation. First, a three-dimensional framework profiling paper's academic impact—"impact power, impact field & impact path" (Im-PFP) is developed through theoretical analysis. Then, an empirical study was conducted using a self-compiled citation corpus, with a single highly cited paper—"Co-citation in the scientific literature: a new measure of the relationship between two documents" (Small, 1973) — as a case study. The empirical result validates the universality and practical value of the Im-PFP framework proposed in this study, which can be extended to profiling studies of single or multiple highly cited papers across different disciplines. Profiling outcomes enable both the classification of an academic paper's lifecycle stages and the analysis of temporal evolution of its impact power, impact field and impact path.

Keywords: paper profiling; citation content analysis (CCA); paper's lifecycle; citation topic identification; main path analysis

收稿日期：2025-06-05；修回日期：2025-11-27

作者简介：王心玥，2000 年生，博士研究生，研究方向为科学计量学；赵丹群，通信作者，1966 年生，博士，教授，博士生导师，研究方向为科学计量学、引文分析与学术评价、信息检索与信息组织等，E-mail: zdq@pku.edu.cn。

0 引言

针对各种学术对象(客体)开展画像研究一直是情报学关注的重要任务类型,并形成了诸多研究成果,如针对学者的画像研究^[1-3]、针对科研机构的画像研究^[4-5]以及针对学科/专业的画像研究与知识图谱绘制^[6-7]等。这些研究工作的广泛开展都离不开对相关学术论文数据的获取与利用,更彰显针对“学术论文”这一学术对象(客体)开展画像研究的必要性、重要性和基础性。这是因为学术论文作为最重要的科研成果表现形式,是用来评估学者产出与学术贡献、刻画科研机构研究优势与竞争力以及洞察学科/专业发展趋势与前沿进展的最核心要素和最基本单元之一。简言之,论文“画像”是利用论文自身的发表数据及引用数据对其进行全面刻画和描述,以应用或服务于学术资源检索/推荐、学术评价等下游任务。依据画像所用的语料不同,论文画像可分为基于原文语料的画像(原文画像或自述画像)和基于引文语料的画像(引文画像或他评画像)两大类。其中,前者侧重描述论文的基本发表信息和主要研究内容(主题),论文一经发表即可进行画像,且历时而不变(静态性);后者则因引文语料富含同行评议信息和历时性积累而兼具动态性和评价性,并会在其生命周期过程中持续展现并扩散其“学术影响”。本文主要聚焦后者——引文画像研究,全面引入最新的引文内容分析(citation content analysis, CCA)方法,以对论文发表后的“学术影响”进行精准识别和动态刻画。

目前,CCA已基于引文语料广泛开展了引文主题、引文情感、引文功能(目的/意图)等内在特征的自动识别和多维分析,并通过对论文引用/被引用、耦合和同被引关系的深入挖掘,来揭示不同作者之间的社会与智力互动^[8-9]。相较于原文语料,引文语料获取门槛较高,但其具有的来源广泛、网络关系复杂、富含同行评议性和引用时间戳等一系列鲜明特征,能够更客观、全面地反映论文在不同生命周期时段的学术影响,对构建动态、细粒度画像具有重要价值。特别是对高被引论文来说,其丰富的引文语料更具挖掘利用空间,得到的论文画像也更为精准和有效。

鉴于此,本文拟利用CCA方法对学术论文的引文画像开展较系统的理论探索和实证研究。首先,对传统的单维度“学术影响力”刻画进行拓展,尝试构建包含影响力(量化指标)、影响域(定性标

签)和影响路径(可视化)3个维度的论文画像框架;其次,选择一篇高被引论文作为研究案例,自行创建其完整的引文语料集,在实施多项引文内容分析(CCA)的基础上,完成案例论文的三维度画像,检验画像框架的实用性并对画像成果进行深入解读分析。

1 相关研究综述

本节主要从论文画像和引文内容分析(CCA)两个方面对相关研究进展进行综述分析。

1.1 论文画像

文献调研发现,近年来国内外有关论文画像的研究成果较少。截至2025年11月,国内方面,仅有3篇论文直接相关,分别使用了论文自身数据、同行评议文本和网络数据等多源数据,开展面向学术评价的论文画像研究^[10-12]。国外方面,此类研究通常基于多篇论文的原文内容,致力于描绘学科领域的研究进展与发展脉络^[13-14],与本文关注的单篇论文画像问题相关性不强。

若将调研范围扩展至论文画像的3个不同维度,间接相关的成果数量激增,并且大量聚集在“学术影响力”维度,其他两个维度的成果数量占比很小^[15]。若将调研范围转向学术画像类研究,发现也有一些可借鉴的成果。其中,数量最多的是学者画像——通过多源数据收集,提取学者的个人基本信息和科研活动信息刻画学者形象,用于解决学术资源的检索/推荐^[16]和学术评价^[17]等任务。此外,学术期刊和科研机构也是较常见的画像对象,重点关注这些客体的学术产出、影响力、运营特点与合作关系等维度^[5,18-20]。

1.2 引文内容分析

本文的画像研究主要建立在CCA方法的基础上,以下是对其研究进展的梳理分析。

第一,引文主题(citation topic)识别。引文主题是引文语料中蕴含的最重要、最具应用价值的内容特征,目前研究重点在于通过识别高被引论文的引文主题,揭示相关学科领域的发展历程及代表性文献的学术贡献^[21]。已有研究发现,相较于从原文语料中识别的主题特征,从引文语料中提取的主题更具代表性^[22],这一研究结论对基于CCA方法的论文画像非常重要。

第二,引文情感(citation sentiment)分析。研

究重点主要为各种自动分类模型的性能优化，用于对施引作者在引用过程中表达出的学术态度或情感倾向进行准确识别。初期使用较多的情感词典方法因词典质量和规模的限制而准确率较低^[23]，使得传统机器学习方法（如支持向量机^[24]、朴素贝叶斯^[25]和随机森林^[26]等）逐渐成为主流。近年引入的卷积神经网络、长短期记忆神经网络等深度学习模型进一步推动了准确率的提升^[27]。

第三，引文功能（citation function）分析，也可称为引文目的（purpose）/意图（intension）分析，主要关注被引文献在施引文献中发挥的作用。与前述两个研究方向侧重实证不同，其重点在于引文功能类型的划分。虽相关研究数量较多，但目前仍未能达成共识，现有分类框架的类目数量从3类到13类不等^[28-29]，框架侧重点也存在分歧，导致研究结果之间的可比性较差，对学术交流造成了一定阻碍。

第四，引文位置（citation position）分析，主要关注引文句在施引文献中的章节分布。目前，对不同位置上的引用重要性已形成共识性排序（由高到低）：结论、结果、方法、综述和引言^[30]。它们常被赋以不同权重，用于构建学术评价指标^[31]，体现其在论文画像中的应用潜力。另有研究发现，引文位置与引文功能在统计学上呈现显著相关^[32]。为此，本文后续的实证分析仅考虑选用两者中的引文位置特征。

综上，与本文研究紧密相关的两个方面——论文画像和引文内容分析，虽已各自取得一定研究进展，但存在以下3个问题亟待解决：

（1）论文画像研究尚未受到重视，现有成果还停留在使用（设计）量化指标来刻画“影响力”这种单维度研究上，缺乏对“学术影响”内涵的全面解析和多维画像框架的构建。

（2）CCA语料获取困难，极大地限制了包括论文画像在内的各类应用研究。例如，Web of Science数据库提供的引文功能分类服务，其可获取并使用的引文数据占全部语料的比例很小（普遍不足30%，对于发表时间较早的论文，该比例甚至不足10%^[33]）；同样地，受困于引文语料获取的高门槛，刘盛博等^[34]的研究中仅从1800余篇施引文献中随机选取200篇（约11%）。为完成本文的实证探索，本团队自建针对案例论文画像的完整CCA语料集。

（3）CCA各细分方向的研究进展目前尚处早期阶段，针对引文语料蕴含的主题、情感、功能与位

置等多维特征开展全面挖掘和深入利用的成果较少；尤其在论文画像方面，仅有一项研究尝试引入引文情感，其他引文特征则尚未涉及，存在较多研究空白。

2 论文画像框架构建

前文已指出，基于引文语料的论文画像具有极强的动态性与评价性（他评），可集中反映学术同行对论文内容的具体看法和态度，客观揭示其发表后形成的学术影响及传播路径。为此，本文围绕“学术影响”画像主题，借鉴牛顿力学中对“力”（force）这一基本概念的理解和界定，将其隐喻、映射到论文的引文画像研究中。作为改变物体运动状态或形变的物理量，力的作用效果取决于其大小、作用点和方向（称为“力的三要素”）。以此类比，本文提出并构建一个涵盖“影响力（impact power）-影响域（impact field）-影响路径（impact path）”的三维度画像框架（impact power, impact field & impact path, Im-PFP）。该框架旨在对传统的单维度“影响力”进行拓展，基于同行引用视角来全面刻画论文的学术影响力大小（定量指标）、影响的主要场域（定性标签）以及影响的传播方向（可视化）。

2.1 影响力

“影响力”一直是学术评价的核心议题^[35]，也是学术论文生命周期过程中得到研究和关注的最重要特征^[36]。“影响力”维度旨在使用量化指标来反映和揭示论文发表后形成的学术影响强度，对应“力的三要素”中的“大小”这一要素，传统上多采用“被引次数”来衡量。

鉴于“被引次数”过于简单粗放，无法有效区分不同引文的重要性，在实证研究中，本文基于CCA方法，提出并使用一种融合引文语料情感及位置特征信息的“加权被引次数”来加以改进（详见4.1节）。在此基础上，对论文的学术生命周期进行阶段划分和历时性观察，以求更细致地描绘论文影响力的变化轨迹。

2.2 影响域

作为Im-PFP框架的第二个维度，“影响域”旨在定量测度“影响力”的基础上，进一步揭示或探明论文发表后产生的主要学术影响范围（或场域），并使用主题标签（定性方式）加以标识，以对应呈

现“力的三要素”中的“作用点”要素。

描述论文“影响域”的标签可通过对引文语料中的主题特征挖掘得到。在某种程度上说,论文“影响域”的刻画也可将其解读为论文实际做出的学术贡献,有助于清晰地展现其具体贡献内容。特别是以正向引用情感为主的高认可度“影响域”,其学术评价意涵更为突出。

“影响域”画像可有效弥补单纯依靠“影响力”量化指标的不足与局限,也契合计量学领域“from indicators to indicating”的研究取向^[37],其具体的实证画像方法及画像结果详见3.3节和4.2节。

2.3 影响路径

厘清“影响力”和“影响域”之后,Im-PFP框架的第三个维度——“影响路径”,旨在基于论文之间的引用/被引用关系(网络)进一步挖掘、揭示其学术影响的传播路径和扩散过程,尝试从“力的三要素”之“方向”要素出发,形成更加立体和多面化的论文画像成果。

有关“影响路径”的画像方法及画像结果详见3.4节和4.3节,其中主要使用了主路径分析法来识别引文网络中的核心路径。

整体来看,以“力的三要素”为基,遵循“影响大小-影响作用点-影响方向”这一逻辑展开和构建的Im-PFP框架,3个维度互为补充递进,可共同描绘出论文的全景画像。此外,该框架充分挖掘利用了引文语料蕴含的主题、情感、位置和时间戳等特征信息,具有普适性,可扩展应用于不同学科领域的单篇或多篇论文画像。

3 论文画像实证研究设计

本节主要讨论如何基于Im-PFP框架开展论文画像实证研究,将具体实证流程划分为两大模块(或步骤)。首先,数据准备,主要完成对案例文献的引文语料获取、标注和预处理,为画像提供数据支撑。其次,基于CCA方法,依次完成论文的三维度画像。其中,①“影响力”画像,设计“加权被引次数”指标,计算指标值并据此划分案例文献的学术生命周期阶段,以呈现其影响力的历时性变化;②“影响域”画像,使用BERTopic算法识别案例文献的引文主题,得到初始的影响域,随后结合引文情感特征,提取其中具有高认可度的影响域,用于描绘论文的主要影响场域;③“影响路径”

画像,主要通过SPC(search path count)法赋权构建引文网络,采用5种路径搜索算法识别其主路径,可视化展示论文主要影响域的传播路径(网络)。

实证研究整体设计如图1所示。

3.1 数据采集与预处理

3.1.1 案例文献选择

为确保所选案例文献具有足量的引文数据,选定计量学最高奖项——普赖斯奖得主Henry Small在1973年发表于*Journal of the American Society for Information Science*的高被引论文“Co-citation in the scientific literature: a new measure of the relationship between two documents”^[38]作为画像对象。该文不仅是Henry Small的最重要代表作,也是引文分析领域的经典之作。截至2023年12月31日,其累计被引量已达3300余次。

3.1.2 引文语料采集

现阶段尚未对引文语料采集范围达成共识,本文主要采集引文句及其前后两句上下文,以便能更好地分析施引者的引用意图。在Scopus数据库中,共采集案例文献的3438条引文语料^①,同时,收集其施引文献的作者、发表年等题录数据备用。由于施引文献来源广泛,引用标记格式复杂(涉顺序编制与哈佛编码体系),目标引文句定位困难(图2),目前仅能手动采集语料,颇为耗时且烦琐。

3.1.3 数据预处理

数据预处理主要操作如下:①借助AIGC(artificial intelligence generated content)类工具Kimi去除全部引用标记;②以Python 3.17为平台,使用NLTK(natural language toolkit)自然语言处理工具包,将文本改为小写,并进行分词、去停用词、去除不必要的数字和标点等数据清洗;③进行词形还原,避免过多同义词的出现影响主题分析结果。

3.2 数据标注

针对采集到的全部引文语料,需逐条标注其引文位置、引文情感及多引情况。“多引”标注主要依据案例文献所在引用标记符号内的共同文献数量进行区分,如“[1-3]”标注为“3”,其余特征标注说明如下。

① 对来自同一施引文献的多次引用进行分别计数,即采用“Count X”方式。




图1 实证研究设计图




图2 引文语料采集流程

3.2.1 引文位置标注

引文位置标注主要由施引文献的篇章结构决定,为更好地契合计量学领域发表论文的篇章结构特征^[39],本文将通用的“IMRaD”结构调整为“IRMraD”(表1),即新增了“文献综述”模块(“R”),并按“IRMraD”框架进行标注。需要说明的是,位置标注操作实际上可与引文数据采集同时进行,无须后续单独进行。

3.2.2 引文情感标注

引文情感在研究中已形成了较稳定和统一的标注框架,即分正向、负向和中立3类,本文同样遵循该框架,详情如表1所示。尽管有学者尝试引文情感的自动化标注,但因数据不平衡等问题^[23],标注效果常常难以达到预期。鉴于此,本文采用人工

表1 引文数据标注框架及说明

一级标注	二级标注	标注说明
引文位置	Introduction	研究背景介绍
	Review	回顾先前研究
	Methods	研究采用的方法/数据
	Results	研究结果
引文情感	Discussion	讨论总结
	Positive	对被引文献呈赞赏/认可态度(正向)
	Negative	对被引文献呈否定/批判态度(负向)
	Neutral	对被引文献仅客观提及(中立)

标注方式,由情报学研究人员对语料进行单人两次标注(间隔超一个月),Holsti一致性系数为0.949,说明标注结果一致性较高,具有可靠性。引文数据的特征标注示例如表2所示。

表2 引文数据标注示例

引文内容文本	引文位置	引文情感	多引情况
A co-citation analysis was used to interpret the similarity of content between two documents by counting the number of documents which have been cited in a pair (Garfield, 1979; Small, 1973).	Introduction	Neutral	2
In citation analysis, two major methods have proven to be most effective for the analysis of domains and have been adapted in many bibliometric studies: bibliographic coupling and co-citation[8-11].	Review	Positive	4
Bibliographic coupling was chosen for this analysis because of its accuracy in representing the structure of sets of scientific papers, and because it can successfully map both cited and uncited articles, which co-citation mapping (Small 1973) cannot . This allows for the mapping of even the most recent, and therefore still uncited, articles supported by OER.	Results	Negative	1

3.3 引文主题识别

本文选用BERTopic算法开展引文主题识别。相较于其他模型,BERTopic能更有效地识别文本主题信息,主要包括6个步骤:①将引文语料转换为向量表示;②使用UMAP(uniform manifold approximation and projection)算法进行降维;③借助HDBSCAN(hierarchical density-based spatial clustering of applications with noise)算法进行聚类;④采用CountVectorizer进行分词;⑤通过c-TF-IDF(class-based term frequency-inverse document frequency)获得代表各主题内容的关键词;⑥输出主题识别结果(主题标签)。

此外,本文采用适用于短文本的all-mpnet-base-v2模型进行文本向量化,借助OCTIS(optimizing and comparing topic models is simple)库对多个参数组合进行网格搜索,并基于主题一致性和多样性指标选取最优模型。经多轮实验比较,最终的

算法参数设置如下:ngram_range=(1,3),n_neighbors=10,n_components=3,min_cluster_size=90,min_samples=12。

3.4 主路径分析

主路径分析(main path analysis,MPA)由Hummon等^[40]于1989年提出,现被广泛用于描绘学科领域的发展历程和演化轨迹^[41]。本文借助HistCite自动构建案例文献的引文网络,选取5种路径搜索算法——前向局部、后向局部、局部关键路径、全局关键路径和标准全局,权重设置使用目前最常用的SPC方法^[42]。最终,选取其中的最优主路径识别结果来解读案例文献的影响路径。

4 论文画像实证及结果讨论

根据第2节和第3节构建Im-PFP画像框架和画像实证方案,以下针对案例文献进行三维度画像,

并就画像结果展开分析讨论。

4.1 案例文献的影响力画像

学术文献影响力的最常用测度指标为“被引次数”，故首先借助 Loglet Lab4 软件利用 Logistic 曲线




图3 案例文献的学术影响力拟合曲线(彩图请见 <https://qbx.istic.ac.cn>)

鉴于传统“被引次数”历来备受诟病，以下针对每条引文语料，引入4项引文特征——引文情感、引文位置、是否多引和施引文献的被引次数，以设计新的影响力测度指标——“加权被引次数”，对案例文献的影响力进行重新刻画。计算公式为

$$\text{weighted}_{ij} = w_{\text{sent}_{ij}} \times w_{\text{pos}_{ij}} \times \frac{1}{\text{multi}_{ij}} \times \log(\text{citation}_{ij} + 1) \quad (1)$$

其中， weighted_{ij} 指案例文献第*i*年第*j*次被引用的重要性； $w_{\text{sent}_{ij}}$ 和 $w_{\text{pos}_{ij}}$ 分别为第*j*条引文语料中引文情感和引文位置的对应权重，具体取值参考李铮等^[30]的研究结果（表3）； multi_{ij} 为第*j*条引文语料中的多引文献数量； citation_{ij} 为第*j*条引文语料所在施引文献的被引次数。最终，由公式

$$\text{weighted_citation}_i = \sum_{j=1}^n \text{weighted}_{ij} \quad (2)$$

计算得到案例文献第*i*年的加权被引次数（ $\text{weighted_citation}_i$ ）。

基于累积“加权被引次数”重新拟合影响力曲线，如图3b所示。结果显示，2002年加权被引次数达到饱和值的2%，2014年达到10%，预计于2025年达到50%，并于2050年进入饱和状态。此次拟合效果较好，MAPE（mean absolute percentage error）值为0.27，表明新指标由于整合了引文内容特征，较传统“被引次数”更能反映案例文献的实际影响力变化历程，突破了传统指标将所有引文视同一律的局限，有利于提高学术评价的精准度。

拟合案例文献的累积被引次数。结果发现，截至2023年年底，案例文献的被引次数仅达到饱和值的1/5，预测最终被引量能接近2万次，如图3a所示。该预测结果与预期差异较大，难以准确刻画论文影响力的演化过程。

表3 不同引文特征的权重设置^[30]

引文内容特征	类别	权重
引文位置	Introduction	0.1094
	Review	0.1651
	Methods	0.1901
	Results	0.2495
	Discussion	0.2859
引文情感	Positive	0.6806
	Negative	0.1180
	Neutral	0.2014

基于图3b的“加权被引次数”影响力拟合结果，可对案例文献的学术生命周期进行阶段性观察和分析。①影响力尚低的沉睡期（1974—2002年），存在一定程度上的延迟承认现象（这或与早期发文数量低、被引机会少有关）；②影响力渐显的唤醒期（2003—2014年）；③影响力快速扩散的活跃期（2015—2023年），显示加权被引次数有显著提升。

图3b还针对案例文献已走过的生命周期三阶段，通过不同颜色对影响力的变化趋势进行了直观区分。后续对“影响域”和“影响路径”的分析将沿用此三阶段划分，以对案例文献的学术影响进行历时性描绘。

4.2 案例文献的影响域画像

在对案例文献“影响力”画像的基础上，进一步对其“影响域”进行画像，并使用定性的主题标签加以描述和标识。先对初始影响域进行识别，再

引入引文情感因素, 提取其中的高认可度影响域并完成画像。

4.2.1 初始影响域识别

案例文献的初始影响域主要使用 BERTopic 算法

进行识别, 最终获得 7 个重要的引文主题 (影响域)。将它们的关键词 (Top 11) 及其代表性引文 (Top 5) 交由 DeepSeek 分析, 再经研究者对生成文本内容的理解给出各自的描述性标签, 如表 4 所示 (引文主题 0~6 依其重要性降序排列)。

表 4 案例文献的初始影响域识别结果

引文主题	关键词 (Top 11)	影响域标签
0	publication, relationship, cocited, citation, field, cocitation defined, similarity, measure, cited cocitation, time, scientific	共被引
1	coupling, bibliographic, bibliographic coupling, cocitation, cocitation bibliographic, cocitation bibliographic coupling, bibliographic coupling cocitation, similarity measure, link, linkbased, bibliometric	共被引与文献耦合
2	network, cocitation, citation, citation network, cluster, bibliographic coupling, relationship, coauthorship, coupling network, cocitation network, field	引文网络
3	citation, bibliometric, field, impact, publication, bibliometrics, scholarly, evaluate, statistical, researcher, indicator	影响力评估
4	intellectual, development, knowledge, scientific field, network, mapping, interrelationship, cocitation network, idea, pattern, structure scientific	学科结构演变
5	bibliographic, coupling, coword, visualization, bibliographic coupling, science mapping, bibliometric, network, cooccurrence keywords, vosviewer software, coauthorship	可视化
6	cocited, publication, relationship, share, field, common, citation, intellectual similarity, related, perspective, stronger	相似性

观察表 4, 再结合 Van Raan^[43]对 Small 学术成果的评价可知, 本文所选案例文献主要围绕其首创概念——“co-citation (共被引)”逐渐形成多个紧密关联的学术影响域。其中, “共被引” (引文主题 0) 最具创新性和主导性, 是其他影响域的形成基础; “共被引”和“文献耦合”的联袂研究 (引文主题 1), 共同推动了引文聚类分析的深入发展; 在引文网络构建 (引文主题 2)、影响力评估 (引文主题 3)、学科结构演变分析 (引文主题 4)、可视化 (引文主题 5) 和文献相似性计算 (引文主题 6) 等研究方向上, 较大规模的学术影响也陆续产生。这一影响域识别结果对于优化学术资源推荐具有启发意义。例如, 对与原文主题重叠者 (继承类引文主题或影响域), 可进行强化推荐或提高其推荐优先级 (权重); 而对与原文主题不同者 (衍生类引文主题或影响域), 则可进行新的拓展性推荐, 以破除推荐过程中可能形成的“信息茧房”效应。

结合此前案例文献生命周期的三阶段划分, 图 4 直观描绘了 7 个引文主题 (影响域) 的历时性演化情况。其中, 左纵坐标轴对应加权被引次数 (柱状), 右纵坐标轴对应增长率 (点线)。

在图 4 中, “共被引” (引文主题 0/影响域 1) 及其与文献耦合的比较 (引文主题 1/影响域 2) 在 3 个阶段中始终保持较高的研究关注度和影响力水平, 其他影响域的表现则更具阶段性, 反映出案例

文献学术影响的不同扩散变化过程。例如, 在沉睡期内, “学科结构演变”较为突出, 体现出研究者对使用共被引方法发掘学科领域的知识结构、识别研究前沿存在较大兴趣; 在唤醒期内, “可视化”的关注度和影响力迅速增长 (461%), CiteSpace 和 VOSviewer 等软件的诞生极大地推动了共被引分析的可视化应用; 在活跃期内, 得益于开放引文、开放科学等宣言/倡议的发布^[44]以及 Microsoft Academic Graph (MAG) 等学术数据库的开放, 共被引分析在所有影响域中的影响力水平均显著提升, 在“影响力评估”方向上的表现尤其突出 (593%)。

4.2.2 高认可度影响域提取

初始影响域的识别只是初步明确了受同行关注的主要研究主题, 但尚不能清晰判别案例文献在这些主题上的受认可程度。为此, 引入引文语料的情感特征, 对各初始影响域的负向情感引用占比进行计算 (表 5), 筛选出占比低且重要性高的影响域。

观察表 5 可以发现, 影响域 1、3、4、5、6 的负向引用占比均低于 1%, 说明案例文献在这些内容上不仅引发广泛研究和关注, 也获得了施引同行的充分认可。据此, 将这些高认可度影响域 (5 个) 筛选出来, 并将其进一步解读为案例文献的主要学术贡献领域 (或方向)。相比之下, 影响域 7 和 2 的负向引用占比较高, 前者被认为缺少理论依据^[45],




图 4 不同引文主题(影响域)的加权被引次数及增长率演化

表 5 初始影响域负向情感引用占比统计

影响域序号	负向情感引文数	全部引文语料数	负向情感引用占比/%
4	1	197	0.51
5	1	178	0.56
6	1	172	0.58
1	6	992	0.60
3	2	242	0.83
2	16	514	3.11
7	12	108	11.11

注:粗体表示负向情感引用占比高于1%的影响域。

准确性有限^[46-47]；后者则在比较中暴露出冷启动问题^[48]。

4.3 案例文献的影响路径画像

案例文献的影响路径画像可揭示其主要学术影

响的传播轨迹(方向)。基于3.4节的研究设计,运用主路径分析法共识别出5条路径,以路径内论文的“加权被引次数”均值为依据,判定“前向局部”算法得到的路径最能体现案例文献的学术影响过程,绘制路径信息如图5所示。其中,节点表示主路径上的施引论文(起点为案例文献,除外),节点大小为其受案例文献影响的程度,颜色用于区分不同的生命周期阶段。

观察图5可知,基于对案例文献的引文网络分析,其学术影响形成了一条跨越50年且无分支的主传播路径(1973—2023年,共涉及22篇节点文献),充分体现出案例文献在多个研究方向(领域)内持续稳定的学术影响。节点文献中的关键学者,如White、McCain、Schneider、Cobo和Batistic等,虽研究方向有所不同,但均多次引用案例文献,并

在不同时期共同推动“共被引”研究影响的不断扩散和传播。

图 6 进一步细化展示了案例文献各引文主题（影响域）的路径节点论文分布情况及其受影响程




图 5 案例文献的影响路径识别结果(彩图请见 <https://qbx.istic.ac.cn>)




图 6 4 个主要引文主题的影响路径识别(彩图请见 <https://qbx.istic.ac.cn>)

度。其中，引文主题0和1贯穿了路径全程，构成影响路径的核心，引文主题1虽负向情感占比较高，存在一定争议，但在影响传播过程中出现频次较高，故仍将其纳入分析；引文主题4和5的影响扩散呈现阶段性和周期性，而其余3个引文主题的出现频次较低，影响信号较弱，图6未对其进行展示。

结合对路径各节点论文的深入研读，可进一步厘清不同引文主题（影响域）的具体影响与传播路径。例如，图6a中的引文主题0（“共被引”），是从Small等的自引^[49-50]出发，经White等^[51]提出“作者共被引分析”（author co-citation analysis, ACA）并由Culnan^[52]推进发展，在沉寂期后，2011年，Cobo将共被引和共词分析相结合，又重新引发关注，并在成果演变研究中多有应用^[53-54]。图6b中的引文主题1（“共被引与文献耦合”）则主要围绕该主题所涉两大基本概念的比较研究展开^[55-56]。图6c展示的影响路径前段（1974—1996年）聚焦引文主题4，主要通过作者共被引分析（ACA）讨论学科结构演化^[57-58]，并尝试优化分析效果^[59]；其后段（1997—2023年）集中于引文主题5，充分认可共被引对可视化研究的重要价值^[60]，并推动可视化工具的更新^[61]。

5 结语

本文主要基于CCA方法，借鉴力学原理提出并构建学术论文的“影响力-影响域-影响路径”三维画像框架（Im-PFP），并以普赖斯奖得主Henry Small于1973年发表的一篇高被引论文为案例，自建完整引文语料集开展论文画像实证研究，对案例文献的学术生命周期阶段及其学术影响进行全面刻画和深入解读。

研究发现，通过收集单篇或多篇学术论文（尤其是高被引论文）的全部引文语料并进行标注，即利用BERTopic、HistCite等算法工具，可对论文发表后产生的学术影响实施多维度画像分析，并通过定性、定量和可视化等方法的有机融合来完整揭示和细粒度刻画其影响力、影响域和影响路径的历时性变化。本文所得主要为施引同行视角下的论文画像（引文画像），其与原文画像互为补充，可为后续的学术资源检索/推荐、学术评价等研究任务提供更完整的解决方案。

本文主要贡献是构建了具有普适性的论文画像框架Im-PFP，并通过自建的案例文献引文语料集，对

该框架进行了实证检验。结果表明，该框架具有实用价值，能够细粒度描绘学术论文的影响特征，对传统单维度的“影响力”刻画研究进行了有效拓展。存在的问题是Im-PFP画像对引文语料依赖性强，不能适用于缺乏引文数据的论文，如低被引或零被引论文。

此外，受限于开放引文语料获取困难，本文仅完成了针对单篇高被引论文的画像分析。期待在后续研究中努力探寻引文语料的高效采集和标注方法，降低时间成本，为大规模的学术论文画像研究提供更充足的语料支撑，同时推动对Im-PFP画像框架的进一步检验、优化和推广应用。

参考文献

- [1] 王东, 李青, 张志刚, 等. 科研人员画像构建方法研究[J]. 情报学报, 2022, 41(8): 812-821.
- [2] 董文慧, 熊回香, 杜瑾, 等. 基于学者画像的科研合作者推荐研究[J]. 数据分析与知识发现, 2022, 6(10): 20-34.
- [3] 王心玥, 赵丹群. 数智时代的学者画像研究: 问题与进路[J]. 图书情报知识, 2026, 43(1): 88-97, 123.
- [4] 郭红梅, 曾建勋. 基于本体的科研机构标签体系研究[J]. 情报学报, 2022, 41(6): 574-583.
- [5] 胡潜, 吴茜, 董寒宇. 基于文献数据化的科研机构历时画像构建研究[J]. 情报理论与实践, 2024, 47(7): 88-96.
- [6] 耿海英, 张建东, 杨立英, 等. 不同学科分类体系下学科结构画像的对比分析[J]. 情报科学, 2023, 41(10): 83-90, 120.
- [7] 胡正银, 刘蕾蕾, 代冰, 等. 基于领域知识图谱的生命医学学科知识发现探析[J]. 数据分析与知识发现, 2020, 4(11): 1-14.
- [8] Zhang G, Ding Y, Milojević S. Citation content analysis (CCA): a framework for syntactic and semantic analysis of citation content [J]. Journal of the American Society for Information Science and Technology, 2013, 64(7): 1490-1503.
- [9] Zhao D Q, Guo Q Y, Chen H P, et al. Corpus construction and mining for citation context analysis[J]. Data Science and Informetrics, 2021, 1(1): 96-114.
- [10] 丁堃, 赵昕航, 林原, 等. 面向学术评价的论文画像研究[J]. 情报理论与实践, 2022, 45(9): 94-101.
- [11] 吴江. 基于论文画像的科研论文影响力评价方法研究[J]. 四川图书馆学报, 2022(3): 52-56.
- [12] 张吉玉, 张均胜, 乔晓东. 辅助新颖性评估的科技论文评述画像构建方法[J]. 情报理论与实践, 2023, 46(1): 159-167.
- [13] Sudolska A, Lis A, Chodorek M. Research profiling for responsible and sustainable innovations[J]. Sustainability, 2019, 11(23): 6553.
- [14] Camara Viana L F, Hoffmann V E, da Silva Miranda Junior N. Regional resilience and innovation: paper profiles and research agenda[J]. Innovation & Management Review, 2023, 20(2):

- 119-131.
- [15] Anderson M H, Lemken R K. Citation context analysis as a method for conducting rigorous and impactful literature reviews[J]. *Organizational Research Methods*, 2023, 26(1): 77-106.
- [16] 陈翀, 李楠, 梁冰, 等. 基于成果特征的学者学术专长识别方法[J]. *图书情报工作*, 2019, 63(20): 96-103.
- [17] 徐曾旭林, 谢靖, 于倩倩. 人才多元评价模型设计方法研究[J]. *数据分析与知识发现*, 2021, 5(8): 122-131.
- [18] Meng L, Wu B. Core discovery and relation extraction in organization profiling[C]// *Proceedings of the 13th International Conference on Semantics, Knowledge and Grids (SKG)*. Piscataway: IEEE, 2017: 219-222.
- [19] 田瑞强, 潘云涛. 全面画像视角下的世界一流科技期刊研究[J]. *中国科技期刊研究*, 2021, 32(9): 1111-1119.
- [20] 潘飞, 孙文礼, 王骁龙, 等. “中国科技期刊卓越行动计划”资助期刊群体画像构建与分析——以领军期刊与重点期刊为例[J]. *中国科技期刊研究*, 2024, 35(6): 831-840.
- [21] Lu C, Ding Y, Zhang C Z. Understanding the impact change of a highly cited article: a content-based citation analysis[J]. *Scientometrics*, 2017, 112(2): 927-945.
- [22] 祝清松, 冷伏海. 基于引文内容分析的高被引论文主题识别研究[J]. *中国图书馆学报*, 2014, 40(1): 39-49.
- [23] 王心玥, 赵丹群. 引文情感识别研究进展及评述[J]. *情报理论与实践*, 2024, 47(1): 173-181, 189.
- [24] Athar A. Sentiment analysis of citations using sentence structure-based features[C]// *Proceedings of the ACL 2011 Student Session*. Stroudsburg: Association for Computational Linguistics, 2011: 81-87.
- [25] Sula C A, Miller M. Citations, contexts, and humanistic discourse: toward automatic extraction and classification[J]. *Literary and Linguistic Computing*, 2014, 29(3): 452-464.
- [26] Raza H, Faizan M, Hamza A, et al. Scientific text sentiment analysis using machine learning techniques[J]. *International Journal of Advanced Computer Science and Applications*, 2019, 10(12): 157-165.
- [27] Lauscher A, Glavaš G, Ponzetto S P, et al. Investigating convolutional networks and domain-specific embeddings for semantic classification of citations[C]// *Proceedings of the 6th International Workshop on Mining Scientific Publications*. New York: ACM Press, 2017: 24-28.
- [28] Cohan A, Ammar W, Van Zuylen M, et al. Structural scaffolds for citation intent classification in scientific publications[C]// *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Stroudsburg: Association for Computational Linguistics, 2019: 3586-3596.
- [29] Jha R, Jbara A A, Qazvinian V, et al. NLP-driven citation analysis for scientometrics[J]. *Natural Language Engineering*, 2017, 23(1): 93-130.
- [30] 李铮, 邓三鸿, 孔嘉, 等. 学者学术影响力识别研究——基于引文全数据的视角[J]. *图书情报工作*, 2020, 64(12): 87-94.
- [31] 魏绪秋, 姜召昊, 常霞, 等. 基于引证意图的学术论文创新性评价研究[J]. *情报理论与实践*, 2023, 46(9): 24-30, 46.
- [32] 王剑, 高峰, 满芮, 等. 基于引用频次和内容分析的引文分布与动机关系研究[J]. *情报杂志*, 2013, 32(9): 100-103.
- [33] Web of Science. Citation network[EB/OL]. [2025-11-27]. <https://webofscience.clarivate.cn/wos/woscc/full-record/WOS:A1990DX15600001>.
- [34] 刘盛博, 王博, 唐德龙, 等. 基于引用内容的论文影响力研究——以诺贝尔奖获得者论文为例[J]. *图书情报工作*, 2015, 59(24): 109-114.
- [35] Al-Jamimi H A, BinMakhashen G M, Bornmann L. Use of bibliometrics for research evaluation in emerging markets economies: a review and discussion of bibliometric indicators[J]. *Scientometrics*, 2022, 127(10): 5879-5930.
- [36] Gou Z Y, Meng F, Chinchilla-Rodríguez Z, et al. Encoding the citation life-cycle: the operationalization of a literature-aging conceptual model[J]. *Scientometrics*, 2022, 127(8): 5027-5052.
- [37] Marres N, de Rijcke S. From indicators to indicating interdisciplinarity: a participatory mapping methodology for research communities in-the-making[J]. *Quantitative Science Studies*, 2020, 1(3): 1041-1055.
- [38] Small H. Co-citation in the scientific literature: a new measure of the relationship between two documents[J]. *Journal of the American Society for Information Science*, 1973, 24(4): 265-269.
- [39] *Scientometrics*[EB/OL]. [2025-11-27]. <https://link.springer.com/journal/11192/articles>.
- [40] Hummon N P, Dereian P. Connectivity in a citation network: the development of DNA theory[J]. *Social Networks*, 1989, 11(1): 39-63.
- [41] Liu J S, Lu L Y Y, Ho M H. A few notes on main path analysis[J]. *Scientometrics*, 2019, 119(1): 379-391.
- [42] Yu D J, Yan Z P. Main path analysis considering citation structure and content: case studies in different domains[J]. *Journal of Informetrics*, 2023, 17(1): 101381.
- [43] Van Raan A F J. Comments on Henry Small, recipient of the 1987 Derek de Solla Price award[J]. *Scientometrics*, 1988, 14(5): 361-363.
- [44] OECD. Making open science a reality[R]. Paris: OECD Publishing, 2015: 25.
- [45] Kwok K L. A probabilistic theory of indexing and similarity measure based on cited and citing documents[J]. *Journal of the American Society for Information Science*, 1985, 36(5): 342-351.
- [46] Li P, Liu H Y, Yu J X, et al. Fast single-pair simrank computation [C]// *Proceedings of the 2010 SIAM International Conference on Data Mining*. Philadelphia: Society for Industrial and Applied Mathematics, 2010: 571-582.

- [47] Yu W R, McCann J, Zhang C Y, et al. Scaling high-quality pairwise link-based similarity retrieval on billion-edge graphs[J]. *ACM Transactions on Information Systems*, 2022, 40(4): Article No.78.
- [48] Belter C W. A bibliometric analysis of NOAA's office of ocean exploration and research[J]. *Scientometrics*, 2013, 95(2): 629-644.
- [49] Small H, Griffith B C. The structure of scientific literatures I: identifying and graphing specialties[J]. *Science Studies*, 1974, 4(1): 17-40.
- [50] Griffith B C, Small H G, Stonehill J A, et al. The structure of scientific literatures II: toward a macro- and microstructure for science[J]. *Science Studies*, 1974, 4(4): 339-365.
- [51] White H D, Griffith B C. Author cocitation: a literature measure of intellectual structure[J]. *Journal of the American Society for Information Science*, 1981, 32(3): 163-171.
- [52] Culnan M J. Mapping the intellectual structure of MIS, 1980-1985: a co-citation analysis[J]. *MIS Quarterly*, 1987, 11(3): 341-353.
- [53] Batistič S, Černe M, Vogel B. Just how multi-level is leadership research? A document co-citation analysis 1980 - 2013 on leadership constructs and outcomes[J]. *The Leadership Quarterly*, 2017, 28(1): 86-103.
- [54] Batistič S, van der Laken P. History, evolution and future of big data and analytics: a bibliometric analysis of its relationship to performance in organizations[J]. *British Journal of Management*, 2019, 30(2): 229-251.
- [55] Zupic I, Čater T. Bibliometric methods in management and organization[J]. *Organizational Research Methods*, 2015, 18(3): 429-472.
- [56] Cobo M J, López-Herrera A G, Herrera-Viedma E, et al. Science mapping software tools: review, analysis, and cooperative study among tools[J]. *Journal of the American Society for Information Science and Technology*, 2011, 62(7): 1382-1402.
- [57] McCain K W. The author cocitation structure of macroeconomics [J]. *Scientometrics*, 1983, 5(5): 277-289.
- [58] McCain K W. Longitudinal author cocitation mapping: the changing structure of macroeconomics[J]. *Journal of the American Society for Information Science*, 1984, 35(6): 351-359.
- [59] Zitt M, Bassecoulard E. Reassessment of co-citation methods for science indicators: effect of methods improving recall rates[J]. *Scientometrics*, 1996, 37(2): 223-244.
- [60] Schneider J W, Borlund P. Introduction to bibliometrics for construction and maintenance of thesauri: methodical considerations [J]. *Journal of Documentation*, 2004, 60(5): 524-549.
- [61] Cobo M J, López-Herrera A G, Herrera-Viedma E, et al. SciMAT: a new science mapping analysis software tool[J]. *Journal of the American Society for Information Science and Technology*, 2012, 63(8): 1609-1630.

(责任编辑 王克平)