

基于语义图提示学习的篇章事件抽取框架

余传明, 成 伟

(中南财经政法大学信息工程学院, 武汉 430073)

摘 要 为解决现有模型主要聚焦于句子级的语义抽象, 难以充分发挥 AMR (abstract meaning representation) 语义结构信息以及语义依赖关系优势的问题, 本文提出一种基于语义图提示的篇章事件抽取框架 (semantic graph prompt learning for document-level event extraction, SeGPL), 通过引入多粒度 AMR 融合机制和自适应的图提示特征, 有效增强了模型的语义建模能力。与最优基线模型 TSAR (two-stream AMR-enhanced extraction model) 相比, 在 WikiEvents 数据集上, SeGPL 在论元识别和论元分类任务中的 head F1 分数分别提升了 2.16 和 3.36 个百分点; 在 RAMS (richly annotated multilingual schema-guided event structure) 数据集中, span F1 分数和 head F1 分数分别提升了 0.41 和 1.13 个百分点, 为解决长文本中的事件信息抽取提供了参考。

关键词 篇章级事件抽取; 抽象语义表示; 图提示学习; 多粒度信息融合

Framework for Document-level Event Extraction Based on Semantic Graph Prompt Learning

Yu Chuanming and Cheng Wei

(School of Information Engineering, Zhongnan University of Economics and Law, Wuhan 430073)

Abstract: To address the issue that most existing models focus on sentence-level semantic abstraction and thus fail to fully exploit the advantages of abstract meaning representation (AMR) semantic structure information and semantic dependency relationships, this study proposes a document-level event extraction framework based on semantic graph prompts (SeGPL). By introducing a multigranularity AMR fusion mechanism and adaptive graph prompt features, the semantic modeling ability of the model was significantly improved. Compared to the strongest baseline TSAR, SeGPL achieved improvements of 2.16 and 3.36 percentage points in the head F1 scores for argument identification and classification on the WikiEvents dataset, respectively; on the RAMS dataset, it demonstrated increases of 0.41 and 1.13 percentage points in span F1 and head F1 scores, respectively, providing insights into event information extraction in long texts.

Keywords: document-level event extraction; abstract semantic representation; graph prompt learning; multigranularity information fusion

0 引 言

篇章级事件抽取是信息抽取的核心任务, 旨在从

非结构化文本中识别事件论元并进行角色分类, 从而为机器阅读^[1-2]、问答系统^[3-5]、推荐系统^[6-7]等下游应用提供支持。如图 1 所示, 给定一个运输事件, 模型需

收稿日期: 2025-03-11; 修回日期: 2025-11-23

基金项目: 国家自然科学基金面上项目“基于知识增强的科技文献创新识别与评价模型研究”(72374219), “危机情境下网络信息传播失序识别与干预方法研究”(72174153)。

作者简介: 余传明, 1978 年生, 博士, 教授, 博士生导师, 主要研究方向为智能信息处理、科技情报, E-mail: yucm@zuel.edu.cn; 成伟, 1999 年生, 博士研究生, 主要研究方向为数据挖掘、知识管理与知识工程。

要根据触发词“flew”从文本中进行抽取论元“Belfast”，并预测每个论元所对应的角色类型“destination”。与句子级事件抽取相比，篇章级任务面临更为复杂的挑

战：首先，事件论元往往分布在文档的不同位置，要求模型具备长距离依赖建模能力；其次，复杂的篇章语境使准确识别事件相关论元变得更加困难。




图1 事件论元抽取示例

与句子级事件抽取任务不同，篇章级事件抽取面临两个关键挑战。其一，现有方法多数聚焦于句子级的抽象语义表示（abstract meaning representation, AMR），却忽略了不同粒度AMR信息之间存在的互补作用，导致难以精准地捕捉到事件要素在不同语义层次上的依存关系，并且缺乏有效的机制去整合不同粒度的AMR信息，无法充分捕捉事件要素在不同语义层次的关联性。其二，现有方法未能充分运用AMR原有的语义结构特性，很难充分发挥AMR语义结构信息以及语义依赖关系的优势。

为解决上述问题，本文提出一种基于语义图提示学习的篇章事件抽取框架（semantic graph prompt learning for document-level event extraction, SeGPL）。具体而言，本文的主要贡献如下。

（1）提出多粒度AMR信息融合机制（multi granularity information fusion, MGIF），将基础语义、时间时序关联、参与者关联和事件目标关联等多粒度的AMR表示结合起来，以此增强语义建模能力。这种多粒度融合机制既提升了模型对复杂篇章结构的理解能力，也增强了事件要素识别的完整性与准确性。

（2）提出一种新颖的基于图提示学习的篇章级事件抽取框架。首先，该框架设计自适应图提示特征，将AMR结构信息显式注入预训练模型。其次，图提示学习机制（graph prompt learning, GPL）使模型能够直接利用AMR语义依赖关系指导事件抽取，实现AMR全局语义与下游事件结构的深度对

齐。同时，自适应图提示特征可动态捕获文档级演变的语义关系，借助结构化提示增强模型对篇章事件线索的感知能力。

1 相关工作

1.1 句子级事件抽取

句子级事件抽取是从单个句子中识别和提取事件相关的结构化信息。在早期的研究工作当中，研究人员主要借助传统的机器学习来开展句子级事件抽取。例如，Li等^[8]提出一种联合事件抽取系统，该系统依靠整合词汇资源，提取关系以及事件的联合特征，使得句子中论元提取的效果得到了有效提升。这种方法尽管可借助事件的联合关系来实现论元提取，却存在依赖外部知识判断触发词的问题。随着深度学习的不断发展，研究者开始探索基于神经网络的方法。例如，Chen等^[9]提出利用基于动态多池化卷积神经网络的事件抽取框架来捕捉句子的关键特征，有效实现了句子的论元识别；尹浩然等^[10]提出基于双向循环神经网络的联合框架，运用双向循环神经网络对句子语义特征、依存句法关系进行特征提取，使句子级事件抽取的效果得到提升。然而，这些方法在面对领域数据时存在泛化能力差的问题，并难以在领域数据中进行有效的事件抽取。

近年来，提示学习在小样本数据中的出色表现引发了研究者的普遍关注。例如，郭嘉梁等^[11]依靠

上下文设计了混合提示模板，提升了模型对任务的理解以及推理能力；陆伟等^[12]提出一种基于先验提示模板的事件抽取方法，依据先验知识构建先验提示模板设计构造策略，并且在模型编码层嵌入基于先验知识的提示模板，为事件核心元素的抽取提供了新的视角。

随着大语言模型（large language model, LLM）的发展，越来越多的研究者开始尝试将其应用于事件抽取领域。例如，斯彬洲等^[13]在电诈领域通过构建两阶段层次化提示指令，利用大语言模型抽取诈骗案例相关风险事件，为事件抽取提供了新思路，然而效果仍未达到预期，大语言模型的幻觉问题导致生成的内容与实际事实不符。

1.2 篇章级事件抽取

篇章级事件抽取能够从大规模文本中提取结构化的事件信息。从理论层面来讲，该任务对自然语言处理领域的语义表示^[14]、知识推理^[15]以及知识建模^[16]等研究具有重要推动作用，要求模型理解事件在篇章中的时序、因果等复杂语义关系。在实践中，篇章级事件抽取在信息检索、决策支持以及舆情监控等领域具有广泛的应用价值。例如，在舆情监控领域，可从应急管理数据中提取时间、地点、对象等信息，帮助相关部门及时发布危机预警，快速做出响应，以减少损失^[17]。因此，越来越多的研究者在篇章级事件抽取方面展开研究。例如，Yang等^[18]首次提出将实体和事件进行联合建模，对文档中实体、事件及其关系之间的依存关系进行建模，实现篇章级上下文感知预测。该方法虽引入篇章级上下文信息，但仍然依赖大量人工标注数据。为解决标注数据稀缺的问题，Yang等^[19]提出DCFEE（document-level Chinese financial event extraction）系统，通过自动生成标注数据来降低对人工标注的依赖，实现了从整个文档中抽取事件的功能，但是其自动生成标注质量仍有待提高，在捕获长距离依赖关系方面存在提升空间。Xu等^[20]引入异构图交互网络，利用图结构来表示句子和实体之间的复杂关系，识别分散在不同句子中的实体。Huang等^[21]利用触发器分类器预测每个事件类型的得分，并采用交换噪声策略随机交换部分低置信度的触发词预测，有效缓解了模型过拟合的问题。

为进一步提升篇章级别事件抽取的效率和泛化能力，Ma等^[22]将提示学习引入篇章级事件抽取，为每个论元角色设计不同类型的提示模板，以实现

其最优跨度分配。Hu等^[23]通过引入特定任务的提示模板将下游任务转换为与预训练目标一致的形式，使外部知识能够通过事件进行交互来增强事件表示。Peng等^[24]为每个事件类型设计了单独的提示模板，为模型提供了额外先验知识，有效提升了抽取性能。然而，这些方法未能充分对长距离依赖关系进行建模。为解决这一问题，Xu等^[25]引入抽象语义表示来辅助文档理解，利用其跨度表示捕捉触发词与论元间的长距离依赖关系，以增强模型对文档深层语义的理解。Yang等^[26]提出一种基于抽象语义图的事件论元抽取方法，将任务转化为基于自定义AMR图的链接预测问题。该方法在保持较高效率的同时增强了模型长距离关系的建模，但由于AMR图结构信息往往被割裂处理，未能充分发挥AMR在语义表示方面的优势。

1.3 提示学习

提示学习是一种采用精心设计的模板，使预训练语言模型能够更好地适应下游任务需求的方法。通过提示模板引导模型输出符合任务要求的结果，在推理时不需要或仅需微调少量模型参数即可完成任务，从而提高预训练语言模型在下游任务中的适应性与效率^[27]。从理论层面来讲，提示学习将分类、生成、推理等任务进行了统一，通过少量的提示微调即可引导下游任务的训练，为推动参数高效微调的研究奠定了基础。从实践层面来讲，提示学习仅需少量提示样本即可实现下游任务适配，大幅降低了计算和推理成本。

早期的研究者通过手动创建直观的提示模板进行提示学习。例如，Petroni等^[28]通过手动创建完形填空模板进行开放域问答的任务；Brown等^[29]手动设计了硬提示模板，以处理各种任务，包括问答、翻译以及常识推理的探测任务；Gui等^[30]利用构造的硬提示将文本分类和拼写检查任务相结合，解决了垃圾信息中故意使用错别字以逃避检测的问题。通过手动创建提示模板这种方式虽然直观，但是高度依赖设计者的领域知识，稍有偏差便可能造成提示偏差的问题。为解决这些问题，研究者开始设计自动化提示模板，通过自动生成离散或连续的提示（软提示）解决手动创建提示模板造成提示偏差的问题。例如，Qiu等^[31]基于梯度搜索方法，对实际token进行短序列生成，并将生成的短序列用于期望目标的预测；Ghorbanpour等^[32]通过设计软提示模板将任务指令直接在模型的嵌入空间中进行提

示, 提高检测有害内容的能力; Mai 等^[33]将软提示模板引入问答领域, 让下游任务根据训练数据进行调优, 充分利用了预训练语言模型的通用性。

近年来, 提示学习在事件抽取、知识图谱、关系抽取等任务中得到了广泛应用。例如, Xu 等^[34]在事件抽取任务中利用提示学习方法构建事件提示进行论元抽取, 并结合句子占位符来提取特定于事件的信息; Chen 等^[35]将知识图谱编码为结构化提示, 以增强预训练语言模型的知识表达能力, 无须重新训练模型, 从而与预训练语言模型和下游模型解耦, 节省计算资源; Le 等^[36]在关系抽取任务中, 通过为每个任务单独设计提示池, 捕捉每个任务之间内部的差异, 有效缓解了持续关系抽取任务中灾难性遗忘的问题。

尽管提示学习在事件抽取以及相关任务领域取得了一定程度的发展, 在面对复杂语义结构和篇章级任务时, 仍然无法灵活地捕捉文档中不断演变的语义关系等问题, 因此, 本文引入图提示学习, 依靠自适应的图提示特征将 AMR 的结构信息融入预训练模型中。模型利用 AMR 的语义结构与依赖关系来调整提示特征, 捕捉文档中持续变化的语义关系, 以此提升事件抽取的效果。

2 研究问题与研究方法

2.1 研究问题

篇章级事件抽取任务旨在从非结构化文本中抽取事件论元及其各自的角色, 通常包含论元识别和论元分类 2 个核心子任务。论元识别任务的目标是

从文档中识别出与事件相关的论元或头词, 即给定一个文档 $D = \{S_1, S_2, \dots, S_n\}$, 对于文档中的每个事件, 输出其论元或头词跨度集合 $A = \{a_1, a_2, \dots, a_n\}$ 。其中, S_i 表示文档中的第 i 个句子, a_i 表示抽取到的论元。论元分类任务的目标是识别出论元的角色类别, 即给定文档 $D = \{S_1, S_2, \dots, S_n\}$ 和论元跨度集合 $A = \{a_1, a_2, \dots, a_n\}$, 输出每个论元 a_i 的角色类别 r_i 。

针对上述任务, 本文提出一种基于语义图提示学习的篇章事件抽取框架, 并在 WikiEvents 和 RAMS (richly annotated multilingual schema-guided event structure) 数据集上探究以下问题:

(1) 多粒度 AMR 信息融合机制能否有效增强语义建模能力, 提升篇章级事件抽取效果?

(2) 通过自适应的图提示特征将 AMR 的结构信息显式地注入预训练模型中, 能否更好地将 AMR 的语义信息与下游事件结构对齐, 提升篇章级事件抽取效果?

2.2 研究方法

本文提出的基于语义图提示学习的篇章事件抽取框架的整体架构如图 2 所示。该框架主要由 4 个核心模块组成: ①模型输入模块, 作为整个模型的基础, 为后续的语义建模和事件抽取提供输入; ②语义信息抽取模块, 负责从输入的文档中提取结构化的语义信息, 生成抽象语义表示图; ③跨度表示模块, 将原始文本中的跨度信息与 AMR 生成的语义图结构进行融合, 采用双重注意力机制和多模态跨度融合表示, 使模型能够有效地捕捉跨度内部的语义结构以及跨度之间的依赖关系; ④层次化图谱推理模块




图 2 ScGPL 整体架构

理模块，负责对事件论元进行推理和分类，先利用图提示学习机制，模型将 AMR 的结构信息显式地注入预训练模型中，再利用多层图卷积网络进一步捕获事件相关论元之间的长距离依赖关系，最后基于图的推理完成事件抽取任务。

2.2.1 语义信息抽取模块

语义信息抽取模块作为架构中的基础组件，其主要任务是从非结构化文档输入中提取结构化的语义知识。通过实现抽象语义表示，该模块系统地将文本信息分解为语义图结构。具体来说，对于输入文档 $D = \{S_1, S_2, \dots, S_n\}$ ，每个句子 S_i 通过 AMR 解析得到相应的语义图结构 $G_i = (V_i, E_i)$ ，其中 V_i 表示概念节点集合， E_i 表示节点间的语义关系边集合。例如，对于句子 “officers with the Killeen Police Department arrested Abdo on July 27, 2011”，其 AMR 解析结果可表示为

$$G_{\text{AMR}} = \begin{cases} V = \{ \text{arrest, Abdo, Police, 2011} \} \\ E = \{ (\text{arrest, arg0, Abdo}) \\ (\text{arrest, arg1, Police}) \\ (\text{arrest, time, 2011}) \dots \} \end{cases} \quad (1)$$

其中，“arrest”作为核心谓词节点，通过语义角色 arg0 与施事者 “Abdo” 相连，通过 arg1 与受事者 “Police” 相连，同时通过时间关系 “time” 与 “2011” 相连。这种结构化的语义表示不仅保留了原始文本中的核心语义信息，还明确地标注了实体间的语义关系，为后续的 span 表示和图推理任务提供了良好的基础。

传统的方法一般依靠句子级 AMR 捕捉语义结构，然而在篇章级事件抽取任务中，由于篇章含有多个句子，仅仅依靠句子级 AMR 很难有效地捕捉跨句子的语义依赖关系，致使事件要素识别不够全面。基于此，本文设计一种语义信息抽取模块，借助 Claude 大语言模型利用提示词工程生成句子级和篇章级两种粒度的 AMR 表示，这种多粒度 AMR 信息融合机制保留了句子级 AMR 的结构信息，并借助篇章级 AMR 对句子间的时序、参与者和目标关系进行建模，有效地捕捉跨句子的语义依赖。

利用大语言模型生成的句子级和篇章级 AMR 表示，模型可更高效地关注事件相关的关键语义信息。具体而言，模型通过识别大语言模型生成句子级 AMR 提取单个句子内的抽象语义信息，使模型能够地捕捉句子中各个语义单元的核心含义及其相互关系；模型通过识别大语言模型生成篇章级时序

AMR 更好地捕获事件的发展脉络；模型通过识别篇章级参与者 AMR 更好地理解事件的角色信息，解决共指问题；模型通过识别大语言模型生成的篇章级目标关联 AMR，识别事件的核心目标，缓解因目标不明确而导致语义模糊、角色识别困难的问题。这种多粒度 AMR 信息融合机制不仅实现了句子级 AMR 语义特征的提取，还通过篇章级 AMR 整合跨句子的语义关系，从而构建事件的全貌表示，增强了模型的语义表示。提示词设计如图 3 所示，具体实现过程如下。

(1) 系统身份定位。为大模型设定专业身份背景，将大模型定位为多粒度语义表示的 AMR 解析专家，以此保证输出内容具备专业性和准确性。

(2) 任务定义。从文本中识别并构建包含基础语义、时序关联、参与者关联及目标关联的多粒度 AMR 表示。

(3) 定义 Prompt 指令范围。将模型的语析范围限定在关键维度：基础语义整合、事件间的时序关联、事件间的因果关联、事件的参与者关联、事件的目标关联，以此保证输出结果具有针对性。

(4) 输出格式规范。提供标准的 AMR 表示格式。为确保多粒度 AMR 生成质量与一致性，本文使用 Claude-3.5-Sonnet 模型生成多粒度 AMR，每次均采用相同的提示词使模型输出不同粒度的 AMR，通过系统身份定位、任务定义、定义 Prompt 指令范围、输出格式规范确保输出符合 AMR 的语义结构规范。此外，本文对每篇文章进行 5 次独立生成，保留至少出现 2 次的节点和边作为最终多粒度 AMR 图的内容；如果 5 次的结果均不相同，那么通过人工对比这 5 次结果，选取这 5 次结果中最好的多粒度 AMR。

2.2.2 跨度表示模块

2.2.1 节已利用大语言模型通过提示词工程从原始的文档中抽取到多粒度 AMR。为获得捕获论元跨度的上下文语义信息以及全局语义图结构跨度信息表示，本文通过构建跨度表示模块实现从原始文本到结构化特征表示的转换。该模块主要由两个关键组件组成，分别是双重注意力机制和多模态跨度融合表示。

(1) 双重注意力机制 (dual attention mechanism)

双重注意力机制用来捕获跨度内部的语义结构以及跨度之间的依赖关系，包含 word attention 和 multihead attention 两个子模块。其中，word attention 借助 token 级别注意力机制，实现对跨度内部语义

提示词设计

Role: #系统身份定位

You are an AMR parsing expert with multi-level semantic representation.

Task: #任务定义

As an AMR parsing expert, you need to extract multi-level semantic information from text and generate five different granularity AMR representations: (1) sentence level AMR-parsing the core semantic units (entities, events, attributes) and their relationships within a single sentence; (2) Text level AMR-Building cross sentence semantic coherence structures and global semantic networks; (3) Time series correlation AMR-Identify and represent the temporal sequence, duration, and temporal dependencies between events; (4) Participant Association AMR-tracks the role changes and participation patterns of entities in different events; (5) Event target association AMR-Analyze the causal chain, purposefulness, and outcome oriented relationships between events. Each AMR representation must ensure the completeness and accuracy of semantic relationships, using standard AMR tagging specifications.

Prompt Range: #定义Prompt指令范围

Your semantic parsing scope is limited to the following five key dimensions:

Basic semantic integration: Extract core semantic units (such as entities, events, attributes, etc.) from text and construct basic semantic structures.

Temporal correlation between events: Identify the temporal relationship between events and represent it using an AMR graph.

Causal relationship between events: Identify causal relationships between events and represent them using AMR diagrams.

Participant association of the event: Identify the participants of the event (such as the perpetrator, recipient, etc.) and label their relationship with the event.

Target association: Identify the target or purpose of an event and label their relationship with the event.

Output: #输出格式规范

Each node is represented by a variable in the format of (variable/concept), and named entities (such as location, time, person name) are represented by special nodes. Use the following labels to annotate semantic relationships:

: arg0: The agent (initiator of the action).

: arg1: Receiver (the recipient of the action).

: time: Time.

: location: Location.

: mod: Decorate relationships.

: result: The outcome of the event.

: cause: Causal relationship.

: purpose: Goal or objective.

图3 提示词设计

关联的捕获。引入多头注意力机制以输入序列中不同层次及不同角度的信息，即

$$\text{multihead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\mathbf{head}_1, \dots, \mathbf{head}_h) \mathbf{W}^O \quad (2)$$

其中， $\mathbf{Q}$ 代表查询向量； $\mathbf{K}$ 代表键向量； $\mathbf{V}$ 代表值向量； $\mathbf{head}$ 表示注意力机制头； h 代表多头注意力机制的头数。借助多头注意力机制，模型可在多个子空间并行进行学习，提升对复杂语义结构的建模能力。

(2) 多模态跨度融合表示 (multimodal span fusion representation)

多模态跨度融合表示模块将 AMR 生成的语义图结构与前一阶段获得的 span-level 特征进行融合。具体而言，对于每个 span 表示 $\mathbf{s}_i$ 以及对应的 AMR 节点表示 $\mathbf{v}_j$ ，借助注意力机制计算它们之间的语义相关性，即

$$\beta_{ij} = \frac{\exp(f_{\text{align}}(\mathbf{s}_i, \mathbf{v}_j))}{\sum_k \exp(f_{\text{align}}(\mathbf{s}_i, \mathbf{v}_k))} \quad (3)$$

其中， $\mathbf{s}_i$ 表示第 i 个 span 表示； $\mathbf{v}_j$ 表示对应的第 j 个 AMR 节点表示； $f_{\text{align}}(\mathbf{s}_i, \mathbf{v}_j)$ 是一个对齐函数，用于计算 span 表示和 AMR 节点之间的语义相似度。

最后，基于计算得到的注意力权重，融合后的表示通过残差连接和层归一化进行计算，即

$$\tilde{\mathbf{h}}_i = \mathbf{W}_1 \left[\mathbf{s}_i; \sum_j \beta_{ij} \mathbf{v}_j \right] \quad (4)$$

$$\mathbf{h}_i = \text{LayerNorm}(\tilde{\mathbf{h}}_i + \mathbf{s}_i) \quad (5)$$

其中， $\mathbf{W}_1$ 为可学习参数表示； β_{ij} 自适应注意力权重； $\mathbf{v}_j$ 与节点 i 在提示子图中相连的提示节点 j 的可学习特征； $\tilde{\mathbf{h}}_i$ 表示第 i 个跨度的初步融合特征； $\mathbf{s}_i$ 表示第 i 个跨度的特征表示。

这种融合机制可以自适应地整合文本语义特征以及图结构信息，并利用残差连接和归一化操作，使得模型的训练稳定性得到提升。跨度融合表示模块作为后续层次化图谱推理模块中最核心的节点初始特征，直接参与后续图提示学习、多层消息传递与特征更新，保证了后续基于图结构的事件论元的最终推理。

2.2.3 层次化图谱推理模块

基于 2.2.2 节跨度表示模块得到的多模态跨度融合表示，本节构建层次化图谱推理模块，利用图提示学习捕获 AMR 图结构中丰富的语义信息，利用

多次图卷积网络实现消息传递和特征更新，利用特征存储库整合不同GCN层的输出特征，最后，在统一的异构图空间中对所有候选论元进行全局推理。

(1) 图提示学习机制 (graph prompt learning)

受Sun等^[37]的启发，为了更好地利用AMR图结构中蕴含的丰富语义信息，本文将图提示学习机制与AMR图结构进行融合，该机制通过设计结构化的提示模板和自适应的图提示特征，将AMR的结构信息显式地注入预训练模型中。

具体而言，对于一个包含AMR图结构的事件实例 $G = (V, E)$ ，其中， $V = \{v_1, v_2, \dots, v_n\}$ 是包含 n 个节点的节点集，每个节点 v_i 具有特征向量 x_i ； E 表示AMR图中的语义关系边集。本文将图提示定义为 $G_p = (P, S)$ ，其中， $P = \{p_1, p_2, \dots, p_N\}$ 表示提示令牌集合； $S = \{(p_i, p_j) \mid p_i, p_j \in P\}$ 表示 token 之间的结构关系，用 token 对之间的成对关系表示。下文详细介绍各个组件的设计。

① 提示令牌设计。提示令牌集合 $P = \{p_1, p_2, \dots, p_N\}$ 中的每个令牌 p_i 维度与AMR节点特征相同。针对事件抽取任务的特点，本文为每种事件类型和论元角色设计特定的提示令牌，使其能够捕获不同语义角色的特征表示。

② 结构模板。提示令牌间的结构关系 $S = \{(p_i, p_j) \mid p_i, p_j \in P\}$ 基于事件框架的语义约束进行设计。本文通过可学习的参数矩阵来建模不同语义角色之间的关联，即

$$A = \bigcup_{i=1}^{|P|-1} \{a_{ij}\}_{j=i+1}^{|P|} \quad (6)$$

其中， A 表示最终的全局邻接矩阵； a_{ij} 表示提示令牌 p_i 和 p_j 之间的语义关联强度。这种结构化的设计使得模型能够显式地捕获事件要素间的依赖关系。

③ 自适应融合机制。为了自适应地融合AMR语义信息，本文设计了插入函数 f 将提示图 G_p 与原始AMR图 G 进行融合： $G' = \psi(G, G_p)$ 。具体地，节点特征的融合通过公式

$$\hat{x}_i = x_i + \sum_{k=1}^{|P|} w_{ik} p_k \quad (7)$$

实现。其中， $\hat{x}_i$ 表示节点特征的融合提示信息后的增强表示； w_{ik} 是节点 i 对第 k 个提示节点的权重；

$$w_{ik} = \begin{cases} \sigma(p_k \cdot x_i^T), & \text{if } \sigma(p_k \cdot x_i^T) > \delta \\ 0, & \text{otherwise} \end{cases} \quad (8)$$

这种设计允许模型根据上下文动态地选择相关的语义提示特征。

(2) 多层图卷积网络 (multi-layer GCN)

在获得融合后的节点表示后，为进一步捕获事件相关论元之间的长距离依赖关系，本文采用多层图卷积网络进行消息传递和特征更新。具体而言，对于融合后的图结构 $G = (V, E)$ ，第一层GCN的更新过程为

$$h_i^{(l+1)} = \sigma \left(\sum_{j \in N(i)} \frac{1}{c_{ij}} W^{(l)} h_j^{(l)} + b^{(l)} \right) \quad (8)$$

其中， $h_i^{(l+1)}$ 表示节点 i 在第 $l+1$ 层的隐藏状态； $h_j^{(l)}$ 表示节点 j 在第 l 层的隐藏状态； $N(i)$ 表示节点 i 的邻居节点集合； c_{ij} 为归一化系数； $W^{(l)}$ 和 $b^{(l)}$ 分别为第 l 层的权重矩阵和偏置向量； σ 为非线性激活函数。

(3) 特征存储库 (feature bank)

特征存储库主要负责存储以及管理多层GCN所生成的节点特征表示，与传统的单层特征存储不同，feature bank 运用多层级特征融合的方法，通过整合不同GCN层的输出特征使模型利用不同程度的语义信息。

首先，在特征初始化与存储环节，feature bank 会对节点的初始特征表示进行存储，即

$$B_0 = \{h_i^{(0)} \mid i \in V\} \quad (9)$$

其中， B_0 表示初始层的特征存储库； $h_i^{(0)}$ 表示节点 i 的初始特征表示； V 表示图中所有节点的集合。

其次，随着GCN层的深入，多层特征累积每层的输出特征都被保存到 feature bank 中，即

$$B_l = \{h_i^{(l)} \mid i \in V\}, l = 1, \dots, L \quad (10)$$

其中， B_l 表示初始特征存储库； L 表示GCN的总层数； $h_i^{(l)}$ 表示节点 i 在第 l 层GCN后的特征表示。

最后，通过特征融合机制所有层的特征通过拼接操作进行融合，即

$$h_i^{\text{concat}} = [h_i^{(0)}; h_i^{(1)}; \dots; h_i^{(L)}] \quad (11)$$

其中， $h_i^{(l)}$ 表示节点 i 在第 l 层GCN后的特征表示； h_i^{concat} 表示所有层的特征融合之后的最终特征表示。

(4) 基于图的推理 (graph-based reasoning)

基于图的推理是模型的最后一个关键组件，负责把前面所有模块的输出整合起来，做最终的事件论元分类。该模块利用分层推理策略，依靠特征交互和注意力机制，达成从局部到全局的渐进式推理。在分层特征提取阶段，模型从特征存储库中获取节点的多粒度表示。对于每个事件实例，本文分别提取候选论元特征 $\tilde{h}_i^{\text{arg}}$ 、主触发词特征 h^{trigger} 以及其他的相关触发词特征集合 H^{other} ，这种分层的特征组织方法能帮助模型捕捉事件要素间的层次化语

义关系。通过角色分类器预测每个候选论元对应的角色,即

$$p_i = \text{Classifier} \left(\left[\tilde{h}_i^{\text{arg}} ; h^{\text{trigger}} ; e_{\text{type}} \right] \right) \quad (12)$$

其中, $\tilde{h}_i^{\text{arg}}$ 为候选论元的特征表示; h^{trigger} 为触发词特征表示; e_{type} 为事件类型的嵌入表示。

3 实验

3.1 数据集与评估指标

本文选取在篇章级事件论元抽取任务中最具代表性的数据集来评估模型。一是 Li 等^[38]于 2021 年发布的 WikiEvents, 该数据集收录了 3900 多个样本, 包含 50 类事件和 59 种论元角色。二是 Ebner 等^[39]于 2020 年提出的 RAMS, 这是一个专注于跨句子事件的基准数据集, 有 9124 个带标注的事件实例, 设有 139 种事件类型与 65 个论元角色类别。本实验采用这两个数据集官方规定的训练集、开发集和测试集划分方式。

在评估 WikiEvents 数据集的事件论元提取时, 本文重点关注两个关键方面。首先, 检查论元边界是否能准确匹配标准答案; 其次, 验证论元角色的分类是否正确。评估指标采用 Li 等^[38]提出的头部 F1 (head F1) 和共指 F1 (coref F1)。其中, head F1 表示模型在事件抽取任务中识别事件头词时的 F1 值, 即使论元的完整边界预测不准确, 只要头词正确识别, 就被视为有效预测; coref F1 则参考了 Xu 等^[25]和 Yang 等^[26]的方法, 当模型提取的论元与真实标注的论元具有共指关系时, 被视为正确预测的 F1 值。在 RAMS 数据集上, 重点关注论元分类任务, 计算跨度 F1 (span F1) 和头部 F1 (head F1) 指标。其中, span F1 表示模型预测的论元范围与真实标注论元范围完全一致的 F1 值。

3.2 实验设置

本实验使用一台配备 Intel(R) Xeon(R) Gold 6154 CPU 和 NVIDIA GeForce RTX 3090 显卡的计算机, 利用 Pytorch 框架开发模型。在模型架构方面, 采用 huggingface 平台 RoBERTaLarge 作为主干网络, 将学习率设置为 $3e-5$, 批次大小设置为 2, 权重衰减大小设置为 0.1, 模型隐藏层大小设置为 1024, 剪枝率设置为 0.1。

3.3 实验结果

为了更清晰地呈现本文模型在篇章级事件抽取

任务方面的有效性, 本文将 SeGPL 与多个具有代表性和竞争力的基准模型进行比较。这些基准模型涵盖序列标注、生成式、提示学习以及 AMR 图结构建模等多种类型, 体现了从传统到前沿的方法演进; 所选模型在 WikiEvents 和 RAMS 数据集上均公开了实验结果, 并且评估指标一致, 保证了对比的公平性与全面性。

具体而言, 在 WikiEvents 数据集上, 本文对比了以下模型: ① BERT-CRF (bidirectional encoder representations from transformers - conditional random field)^[40], 该方法运用 BERT (bidirectional encoder representations from transformers) 模型结合 BIO (begin, inside, outside) 标注方式进行关系抽取和语义角色标注; ② OneIE^[41], 该方法通过四阶段抽取模型结合全局特征, 实现端到端的事件抽取; ③ BART-Gen (bidirectional and autoregressive transformer-based generation model)^[38], 该方法基于条件生成的篇章级事件参数抽取模型; ④ EA²E (event-aware argument extraction)^[42], 该方法基于文档内事件论元一致性假设, 通过建模事件间关系约束和增强上下文; ⑤ TSAR (two-stream AMR-enhanced extraction model)^[25], 该方法通过双流编码模块和 AMR 引导的交互模块, 分别解决了跨句长距离依赖和干扰上下文问题。

在 RAMS 数据集上, 本文对比了以下方法: ① BERT-CRF^[40]; ② BART-Gen^[38]; ③ EEQA (embodied reasoning question answering)^[43], 该方法采用提示调优和跨角色交互的方式在句子和篇章级别上提取事件论元。

表 1 为不同模型在 WikiEvents 数据集的论元识别和论元分类两个任务上的实验结果。在论元识别任务上, SeGPL 取得了明显效果, 相比于使用序列标注范式的 BERT-CRF, 本文模型提升了 8.95 个百分点, 表明本文模型在篇章级事件抽取任务的有效性。相比于同样使用 AMR 的语义结构信息作为模型提示信息的 TSAR 模型来说, 本文模型在论元识别的 head F1、coref F1 与论元分类的 head F1、coref F1 指标上分别提高了 2.16、0.86、3.36、2.06 个百分点。这表明通过多粒度 AMR 信息融合机制与图自适应提示学习机制, 将 AMR 语义结构信息与篇章级事件抽取任务进行有效结合, 能够提高模型在篇章级事件抽取上的效果。

由表 2 可以看出, 在 RAMS 数据集中, 本文提出的 SeGPL 模型同样展现了显著的效果优势。与现有最优基线模型 TSAR 相比, 本文模型在 span F1 和 head F1 指标上分别提升了 0.41 和 1.13 个百分点。此

表 1 WikiEvents 数据集实验结果

模型	论元识别		论元分类	
	head F1/%	coref F1/%	head F1/%	coref F1/%
BERT-CRF	69.83	72.24	54.48	56.72
OneIE	61.88	63.63	57.61	59.17
BART-Gen	71.18	72.58	66.08	67.49
EA ² E	74.62	75.77	68.61	69.70
TSAR	76.62	75.52	69.70	68.79
SeGPL	78.78	76.38	73.06	70.85

表 2 RAMS 数据集实验结果

模型	span F1/%	head F1/%
BERT-CRF	39.30	47.10
EEQA	48.78	46.74
BART-Gen	48.64	57.32
TSAR	51.18	58.53
SeGPL	51.59	59.66

外，与基础模型 BERT-CRF 和 BART-Gen 相比，SeGPL 在各项指标上都取得了显著提升。实验结果表明，SeGPL 模型在处理复杂的跨句子依赖关系方面具有明显优势。

3.4 消融实验

为了检验 SeGPL 模型中不同关键组件的有效性，本文在 WikiEvents 数据集上进行了消融实验，包括去自适应图提示特征、移除多粒度信息融合机制（将多粒度 AMR 替换为原始的句子级别的单一粒度 AMR 表示方式）以及同时将以上两个组件去除。实验结果如表 3 所示。

表 3 WikiEvents 数据集消融实验结果

模型	论元识别		论元分类	
	head F1/%	coref F1/%	head F1/%	coref F1/%
SeGPL	78.78	76.38	73.06	70.85
SeGPL w/o GPL	77.40	75.95	71.07	69.80
SeGPL w/o MGIF	77.36	75.60	70.94	70.38
SeGPL w/o ALL	75.99	74.01	69.44	68.06

由表 3 可以看出，GPL 和 MGIF 这 2 个核心组件均对模型效果产生了影响。当移除 GPL 后，在识别任务中，head F1 值和 coref F1 值分别下降了 1.38 和 0.43 个百分点；在分类任务中，head F1 值和 coref F1 值分别下降了 1.99 和 1.05 个百分点，这表明图提示学习策略在融合 AMR 语义结构信息方面是有效的。同样地，MGIF 的移除也导致了模型效果的明

显下降，在识别任务上，head F1 值和 coref F1 值分别降低了 1.42 和 0.78 个百分点，分类任务上分别下降了 2.12 和 0.47 个百分点，这表明 MGIF 能够增强模型效果。当将这两个核心组件被全部移除后，模型效果下降更为明显。其中，在论元分类任务上，head F1 值和 coref F1 值仅为 69.44% 和 68.06%，这表明 GPL 和 MGIF 共同影响事件抽取的效果，二者的结合可进一步提升模型效果。

3.5 与大语言模型的比较

近年来，随着人工智能的发展，大语言模型依靠其强大的语言生成、长文本处理和数学推理能力受到了研究者的广泛关注。本文与近期发布的多个具有代表性的大语言模型在 RAMS 数据集上进行对比分析。所选取的对比模型主要包括：①GPT-4.1 (generative pre-trained transformer-4.1)，是 2025 年 4 月由 OpenAI 发布的多模态大语言模型，在编程、指令遵循和上下文理解方面表现突出；②Grok-3，是 2024 年 12 月由 xAI 公司发布的第三代大语言模型，具备强大的思维链推理和逻辑一致性能力，在数学推理和长文本处理等方面表现出色；③GLM-4.5 (generalized linear model-4.5)，是 2025 年 7 月由智谱 AI 发布的新一代旗舰模型，在多任务处理、复杂问题解决和高效生成方面表现出色。实验结果如表 4 所示。

表 4 SeGPL 与代表性的大语言模型在 RAMS 数据集上的效果对比

模型	span F1/%	head F1/%
GLM-4.5	26.93	41.17
GPT-4.1	39.63	41.97
Grok-3	38.10	38.46
SeGPL	51.59	59.66

由表 4 可以看出，SeGPL 在 span F1 和 head F1 指标上分别达到 51.59% 和 59.66%，显著优于所选取的代表性大语言模型的表现。尽管大语言模型具备强大的语义理解能力，但其在处理篇章级事件抽取任务时难以做到论元的精确识别，由于大语言模型的输出容易出现幻觉问题，生成的事件论元可能包含不准确或无关的信息。相比之下，SeGPL 通过多粒度 AMR 信息融合和图提示学习，显式注入结构化语义信息，有效缓解偏差，提升了 span 识别的精确性。

3.6 复杂场景下的事件抽取与分析

为进一步分析模型在复杂场景下的适用性, 本文基于 WikiEvents 测试集, 将测试集中的 20 条文档按照触发词进行拆分, 生成以触发词为中心的事件实例, 并从中筛选出 50 个论元高度分散事件实例、

220 个模糊触发词事件实例、54 个角色重叠事件实例和 9 个跨句长距离事件实例, 比较本文模型与最优基线模型 TSAR 在复杂场景下的实际效果。实验结果如表 5 所示。其中, 灰色标注的为真实论元, 斜体标注的为触发词, “[]” 标注的为模型预测的论元; 下划线标注的为缺失论元。

表 5 WikiEvents 复杂事件分析

类别	示例	错误	
		SeGPL	TSAR
论元高度分散	The attack took place in Charikar, at a police training ground. At the time, Afghan president Ashraf Ghani was holding a political rally at the [site], attended by thousands of people. A suicide bomber riding a motorcycle drove into a crowd near a security checkpoint and <i>detonated</i> his explosives. 26 [people] and the bomber were killed, and 42 others injured. Women and children were among the victims of the attack. President [Ghani] was unharmed in the attack, remaining protected by a secure compound about half a mile from the site of the <u>blast</u> .	35	37
模糊触发词	A second source residing in Maidan Wardak province said more than 100 <u>members</u> of the National Directorate of Security (NDS) were <i>killed</i> in the complex attack.	111	115
角色重叠	<u>The Taliban</u> <i>killed</i> more than 100 [member]...when the <u>attackers</u> rammed a car full of explosives.	31	29
跨句长距离	Cuba sidesteps Colombia's request to extradite the rebels after Bogota blames the group for Thursday's car bombing. Colombia has asked Cuba to hand over the rebels affiliated with National <u>Liberation Army</u> (ELN), who were in Havana for peace talks, after a deadly car <i>bombing</i> in Bogota was blamed on the group.	5	7

由表 5 可以看出, 在论元高度分散的事件实例中, 与基线模型 TSAR 相比, SeGPL 错误预测的数量比 TSAR 少 2 个, 这说明 SeGPL 在该场景下具有一定的优势。但在一些事件实例中, 仍存在过度预测和缺失预测的问题。如表 5 论元高度分散类别所示, “people” 被过度预测和 “blast” 缺失预测。这可能是因为复杂语境 (如 “thousands of people attended”) 引入干扰, 导致模型误判无关跨度, 说明 SeGPL 仍需进一步优化注意力分配问题。

在模糊触发词事件实例中, SeGPL 错误预测的数量比 TSAR 少 4 个, 表明 SeGPL 在处理模糊触发词事件时具有更强的语义理解能力, 减少因触发词模糊而导致的错误判断。但在一些模糊触发词实例中, 如表 5 模糊触发词类别所示, 模型仍缺失预测的问题。这可能是因为复杂语境干扰模型聚焦核心论元, 在下一步工作中, 模型需结合领域知识图谱以便更精准地关联模糊触发词。

在角色重叠事件实例中, SeGPL 的效果稍逊于 TSAR, 模型在该场景下的表现存在一定的不足, SeGPL 的双重注意力机制和图提示学习虽能捕捉复杂语义关系, 但可能因动态权重分配不够精准导致角色边界模糊, 误将 “attackers” 分配到单一角色或错误合并多个角色。在下一步工作中, 需引入角色冲突检测模块, 通过显式建模角色间的语义约

束, 确保 “The Taliban” 和 “attackers” 在 “killed” 事件中的角色被正确区分。

在跨句长距离事件中, SeGPL 的错误数量为 5, 相比于 TSAR 的错误数量 7, 表现出一定优势。但在一些实例中, 如表 5 中的示例, SeGPL 模型仅预测出 “Army” 作为论元, 未能完整预测。这可能是因为 “Army” 和与 “National Liberation Army (ELN)” 存在一定共指关系, 模型需引入共指消解模块, 以确保跨句共指关系的准确识别。

3.7 错误分析与负例讨论

为进一步探究模型在事件抽取任务中的错误来源, 本文分析了模型事件抽取的失败结果, 典型的错误案例如表 6 所示。错误类型大致分为 3 类: 论元过度预测、论元缺失和论元边界不准。首先, 在进行事件论元提取的过程中, 模型会将高频出现的一些词汇作为论元进行识别, 如 “the victim” “ones” 等。然而, 这些论元并非当前触发词对应的真实论元。这可能是因为图提示学习阶段, 模型对高频实体给予了更高的权重, 导致与这些事件主题共现。其次, SeGPL 在进行事件抽取时存在论元缺失的问题。当模型抽取含有大量论元的语句时, 存在一定的遗漏问题, 尤其在待抽取的论元与触发词位置相距较远的情况下。这可能是因为模型

表6 错误案例分析

类别	示例	错误预测论元
论元过度预测	Boston Marathon Bomber Apologizes to Survivors BOSTON—Moments before a federal judge sentenced him to death, Boston Marathon bomber Dzhokhar Tsarnaev rose to his feet Wednesday and apologized to the victims and their loved ones for the first time.	Event: Justice. Sentence. Unspecified Trigger: sentenced 目标预测: judge、him 模型预测: judge、him、the victims、ones
论元缺失	Before the truce, the IRA active service unit (ASU) later dubbed the Balcombe Street Gang (due to the December 1975 Balcombe Street siege) had been carrying out bomb and gun attacks in Southern England since autumn 1974, mostly in and around London.	Event: Conflict. Attack. Unspecified Trigger: attacks 目标预测: bomb、gun、England 模型预测: bomb、gun
论元边界不准确	On 27 August 1975, a Provisional IRA bomb exploded without warning at the Caterham Arms public house in Caterham , Surrey, England. There were no fatalities but 33 people were injured, some severely. Two off - duty soldiers lost their legs as a result of the bombing.	事件类型: Conflict. Attack. Detonate Explode 触发词: exploded 目标预测: Caterham Arms public house、Caterham 模型预测: Caterham Arms、Caterham

更倾向于捕捉触发词周围的论元，对间隔较长的论元关注不足。最后，模型在预测过程中存在论元边界不准确的问题。这类问题主要体现在带有同位语、修饰语的复杂实体上，如“Caterham Arms public house”“Caterham”等。这些实体往往带有较长的修饰词，而模型采用的粒度主要是 token 级，模型对这种复杂实体感知不足，导致其倾向于预测较短的论元实体。未来研究可考虑引入基于语法依存的检测头，以提高模型对复杂实体的检测精度，缩小论元跨度匹配差距。同时，引入句法感知的相对位置编码，使模型对距离较长的论元保持更高的激活度。

3.8 模型泛化能力分析

为进一步评估本文模型的泛化能力，基于中文数据集 CMNEE (Chinese Military News Event Extraction Dataset) [44] 开展实验，评估模型在中文语境下的效果。CMNEE 数据集包含 17000 份文档，涵盖 29223 个事件。本文从 CMNEE 中文数据集中随机筛选 8000 条数据作为训练集，1000 条数据作为验证集，1000 条数据作为测试集。实验结果如图 4 所示，SeGPL 模型在 CMNEE 数据集上的 span F1 值为 37.34%，表明模型借助多粒度 AMR 信息融合机制以及图提示学习机制，依旧可捕捉中文文本里的复杂语义结构，展现出较好的泛化能力。与 Wiki-Events 和 RAMS 实验效果相比，span F1 指标和 head F1 均低于其在英文数据集下的表现。这主要是由于中文语言的句法结构及语义表达方式与英文存在较大差异，并且依存关系较为复杂，模型难以精准捕捉跨句子的论元边界，因此，span F1 偏低。

此外，CMNEE 数据集包含更多的事件类型，且事件论元分布较为分散，进一步增加了论元边界




图4 SeGPL模型在CMNEE中文数据集上效果

准确识别的难度，对 span F1 得分产生了负面影响。在未来可以通过提高中文语料的预训练、优化多粒度 AMR 表示以适配中文句法特性，进一步提高模型在中文数据集论元边界识别上的效果。

3.9 可视化分析

为验证模型对论元角色信息的建模效果，本文采用 *t*-SNE (*t*-distributed stochastic neighbor embedding) 技术将角色表示映射到二维空间，不同角色标记不同标签颜色，在此基础上进行可视化分析。从图 5 可以看出，相比于移除所有组件之后的模型，本文模型能够基于上下文将同一角色类型的论元聚类到一起，体现出更合理的角色关系内部和角色间的距离分配。这一结果证实了本文模型可以更好地学习不同事件中的语义信息。

3.10 讨论

针对 2.1 节提出的研究问题，本文设计了消融实验分别将 MGIF 和 GPL 组件移除，探究多粒度 AMR 信息融合机制和自适应的图提示特征是否能




图5 论元角色二维可视化(彩图请见 <https://qbx.istic.ac.cn>)

够有效提升事件抽取效果。实验结果表明, ①当移除 MGIF 组件后, 模型在论元识别任务和论元分类任务的效果显著下降, 模型可以通过多粒度 AMR 信息融合机制有效整合基础语义、时间时序关联、参与者关联以及事件目标关联等多粒度的 AMR 表示, 从而增强模型对长文本的语义理解能力, 提升模型效果; ②当移除 GPL 组件后, 模型在识别和分类任务中, head F1 分别下降了 1.38 和 1.99 个百分点, 这表明本文引入的自适应的图提示特征通过将 AMR 的语义结构信息显式地注入预训练模型中, 缩小通用语义表示与特定事件结构之间的鸿沟, 让模型可动态捕捉文档中不断演变的语义关系, 从而提升事件参数的识别与分类效果。此外, 在 3.9 节的可视化分析中, 采用 t -SNE 技术将角色表示映射到二维空间, 本文模型可以更好地区分不同事件角色的语义表示, 从而提升论元识别和角色分类的效果。

本文具有以下理论意义。首先, 提出的多粒度 AMR 信息融合机制通过整合基础语义关联、时间时序关联、参与者关联和事件目标关联等多粒度 AMR 表示, 增强了篇章级事件抽取的语义建模能力, 拓展了该领域的研究思路。其次, 设计的自适应图提示学习机制使模型能够直接利用 AMR 结构信息和语义依赖关系指导事件抽取, 更好地将 AMR 语义表示映射至下游事件结构, 丰富了图提示学习的理论创新。

本文具有以下实践意义。提出的 SeGPL 模型在多个基准数据集上均取得显著性能增益, 尤其在论元分布稀疏、触发词歧义、角色重叠及跨句长距离依赖等复杂场景下展现出较强的论元抽取能力, 为高效篇章级事件抽取系统的构建提供了一定的技术参考, 并有望为知识图谱构建、专利信息分析等下

游应用提供新的技术路径。

4 结 语

针对现有研究难以充分发挥 AMR 语义结构信息的问题, 本文提出一种基于语义图提示学习的篇章事件抽取框架, 通过引入多粒度 AMR 信息融合、自适应图提示特征等组件, 有效缓解了模型在复杂语境建模方面的不足。在英文数据集 WikiEvents、RAMS 以及中文数据集 CMNEE 上的实验结果表明, SeGPL 能够有效提升篇章级事件抽取的效果, 为篇章级事件抽取提供了新思路。

在下一步工作中, 我们将构建多语言平行事件抽取数据集, 将 SeGPL 框架扩展到法语、德语等语言环境中, 评估其跨语言泛化能力, 同时探索设计高效的模型蒸馏方案, 将大语言模型的语义理解能力迁移到轻量级模型中。

参 考 文 献

- [1] 喻雪寒, 何琳, 王献琪. 基于机器阅读理解的古文事件抽取研究[J]. 情报学报, 2023, 42(3): 316-326.
- [2] Han R J, Hsu I H, Sun J, et al. ESTER: a machine reading comprehension dataset for reasoning about event semantic relations [C]// Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2021: 7543-7559.
- [3] Li F Y, Peng W H, Chen Y G, et al. Event extraction as multi-turn question answering[C]// Findings of the Association for Computational Linguistics: EMNLP 2020. Stroudsburg: Association for Computational Linguistics, 2020: 829-838.
- [4] Lu D, Ran S H, Tetreault J, et al. Event extraction as question generation and answering[C]// Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics.

- Stroudsburg: Association for Computational Linguistics, 2023: 1666-1688.
- [5] 徐浩, 葛琳琳, 张焱, 等. 面向辅助决策的领域知识图谱构建及其场景式应用研究[J]. 科技情报研究, 2025, 7(4): 58-69.
- [6] Du X Y, Li S, Ji H. Dynamic global memory for document-level argument extraction[C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2022: 5264-5275.
- [7] 叶光辉, 谭启韬, 武川, 等. 融合对比学习的多阶段文献推荐双塔模型[J]. 情报学报, 2025, 44(7): 859-868.
- [8] Li Q, Ji H, Hong Y, et al. Constructing information networks using one single model[C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2014: 1846-1851.
- [9] Chen Y B, Xu L H, Liu K, et al. Event extraction via dynamic multi-pooling convolutional neural networks[C]// Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2015: 167-176.
- [10] 尹浩然, 曹金璇, 曹鲁喆, 等. 扩充语义维度的BiGRU-AM突发事件要素识别研究[J]. 数据分析与知识发现, 2020, 4(9): 91-99.
- [11] 郭嘉梁, 王巍, 剧京, 等. 融合混合提示与位置感知的突发事件抽取模型[J]. 计算机应用研究, 2025, 42(6): 1771-1777.
- [12] 陆伟, 冯子琨, 程齐凯, 等. 基于先验提示模板的冲突事件抽取方法研究[J]. 情报科学, 2024, 42(4): 1-8.
- [13] 斯彬洲, 孙海春, 吴越. 基于大语言模型和事件融合的电信诈骗事件风险分析[J]. 数据分析与知识发现, 2025, 9(7): 38-51.
- [14] Bhopale A P, Tiwari A. Transformer based contextual text representation framework for intelligent information retrieval[J]. Expert Systems with Applications, 2024, 238: 121629.
- [15] Liu W L, Zhou L, Zeng D Y, et al. Beyond single-event extraction: towards efficient document-level multi-event argument extraction[C]// Findings of the Association for Computational Linguistics: ACL 2024. Stroudsburg: Association for Computational Linguistics, 2024: 9470-9487.
- [16] Bao X Y, Wang Z Q, Gu J H, et al. Revisiting classical Chinese event extraction with ancient literature information[C]// Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2025: 8440-8451.
- [17] 曾金, 江长江, 李新来, 等. 突发事件抽取与演化关系研究——以“应急服务网”为例[J]. 情报学报, 2024, 43(11): 1334-1348.
- [18] Yang B S, Mitchell T M. Joint extraction of events and entities within a document context[C]// Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics, 2016: 289-299.
- [19] Yang H, Chen Y B, Liu K, et al. DCFEE: a document-level Chinese financial event extraction system based on automatically labeled training data[C]// Proceedings of ACL 2018, System Demonstrations. Stroudsburg: Association for Computational Linguistics, 2018: 50-55.
- [20] Xu R X, Liu T Y, Li L, et al. Document-level event extraction via heterogeneous graph-based interaction model with a tracker[C]// Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2021: 3533-3546.
- [21] Huang K H, Peng N Y. Document-level event extraction with efficient end-to-end learning of cross-event dependencies[C]// Proceedings of the Third Workshop on Narrative Understanding. Stroudsburg: Association for Computational Linguistics, 2021: 36-47.
- [22] Ma Y B, Wang Z H, Cao Y X, et al. Prompt for extraction? PAIE: prompting argument interaction for event argument extraction [C]// Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2022: 6759-6774.
- [23] Hu R J, Li J, Liu H Y, et al. Knowledge interaction graph guided prompting for event causality identification[J]. Applied Intelligence, 2025, 55(2): Article No.159.
- [24] Peng J R, Yang W Z, Wei F Y, et al. Prompt for extraction: multiple templates choice model for event extraction[J]. Knowledge-Based Systems, 2024, 289: 111544.
- [25] Xu R X, Wang P Y, Liu T Y, et al. A two-stream AMR-enhanced model for document-level event argument extraction[C]// Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics, 2022: 5025-5036.
- [26] Yang Y Q, Guo Q P, Hu X K, et al. An AMR-based link prediction approach for document-level event argument extraction[C]// Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2023: 12876-12889.
- [27] Hang T T, Liu S T, Feng J, et al. Few-shot relation extraction based on prompt learning: a taxonomy, survey, challenges and future directions[J]. ACM Computing Surveys, 2026, 58(2): Article No.40.
- [28] Petroni F, Rocktäschel T, Riedel S, et al. Language models as knowledge bases? [C]// Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2019: 2463-2473.

- [29] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners[C]// Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates, 2020: 1877-1901.
- [30] Gui J Y, Zhou Y H, Yu K, et al. PSC-BERT: a spam identification and classification algorithm via prompt learning and spell check[J]. Knowledge-Based Systems, 2024, 301: 112266.
- [31] Qiu Y N, Wang A D, Li C, et al. STEPS: sequential probability tensor estimation for text-to-image hard prompt search[C]// Proceedings of the 2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2025: 28640-28650.
- [32] Ghorbanpour F, Hangya V, Fraser A. Fine-grained transfer learning for harmful content detection through label-specific soft prompt tuning[C]// Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics, 2025: 11047-11061.
- [33] Mai C C, Chen Y, Gong Z Y, et al. PromptCNER: a segmentation-based method for few-shot Chinese NER with prompt-tuning[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2025, 24(9): Article No.95.
- [34] Xu J H, Yang C, Kang X J. LAAP: learning the argument of an entity with event prompts for document-level event extraction[J]. Neurocomputing, 2025, 613: 128584.
- [35] Chen L Y, Liu J, Duan Y T, et al. KG-prompt: interpretable knowledge graph prompt for pre-trained language models[J]. Knowledge-Based Systems, 2025, 311: 113118.
- [36] Le M, Luu T N, The A N, et al. Adaptive prompting for continual relation extraction: a within-task variance perspective[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(23): 24384-24392.
- [37] Sun X G, Cheng H, Li J, et al. All in one: multi-task prompting for graph neural networks[C]// Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM Press, 2023: 2120-2131.
- [38] Li S, Ji H, Han J W. Document-level event argument extraction by conditional generation[C]// Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics, 2021: 894-908.
- [39] Ebner S, Xia P, Culkin R, et al. Multi-sentence argument linking[C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2020: 8057-8077.
- [40] Shi P, Lin J. Simple BERT models for relation extraction and semantic role labeling[PP/OL]. V1. arXiv (2019-04-10). <https://arxiv.org/pdf/1904.05255>.
- [41] Lin Y, Ji H, Huang F, et al. A joint neural model for information extraction with global features[C]// Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2020: 7999-8009.
- [42] Zeng Q, Zhan Q S, Ji H. EA²E: improving consistency with event awareness for document-level argument extraction[C]// Findings of the Association for Computational Linguistics: NAACL 2022. Stroudsburg: Association for Computational Linguistics, 2022: 2649-2655.
- [43] Du X Y, Cardie C. Event extraction by answering (almost) natural questions[C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2020: 671-683.
- [44] Zhu M N, Xu Z J, Zeng K S, et al. CMNEE: a large-scale document-level event extraction dataset based on open-source Chinese military news[C]// Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation. Stroudsburg: Association for Computational Linguistics, 2024: 3367-3379.

(责任编辑 魏瑞斌)