

慢性病智能医疗问答系统构建与评价： 一种基于 GraphRAG 与 MoE 的混合建模方法

马鑫^{1,2,4}, 王芳^{1,2,3}, 张峰⁴, 李照川⁴

(1. 南开大学信息与传播学院信息资源管理系, 天津 300071; 2. 南开大学网络社会治理研究中心, 天津 300071;
3. 南开大学图书馆, 天津 300071; 4. 浪潮软件科技有限公司, 济南 250000)

摘要 随着慢性病成为全球公共卫生领域的核心挑战, 患者对高质量、个性化、可持续的健康信息服务需求日益增长。近年来, 尽管大语言模型在医疗问答任务中展现出显著优势, 但现有系统在面对慢性病管理这一长期性、情境化、语义复杂的场景时, 仍面临知识调度粒度粗、语义感知能力弱与模型响应一致性差等瓶颈。为此, 本研究遵循“结构化知识建模—混合驱动检索—大模型协同应答”三阶段流程, 提出一种融合图检索增强生成 (graph retrieval-augmented generation, GraphRAG) 与混合专家网络 (mixture of experts, MoE) 的慢性病问答系统。首先, 构建覆盖疾病演化、生活方式干预和长期管理要素的多源异构专有知识图谱, 通过结合关键词匹配、语义向量召回与多子图提示融合的三通道混合图谱检索机制, 实现对复杂信息需求的动态知识调度; 其次, 初筛用户查询合法性与规范性, 结合用户隐含意图与融合子图, 通过 MoE 动态门控智能体对 9 种开源大模型进行指令级协同, 实现语义深度与生成精度的双擎增强; 最后, 引入常识校验、内容完整性检查与格式化规则, 精细预生成文本, 确保输出结果的准确性、完整性与语言可读性。本研究自建覆盖 118 种慢性病与 3 类管理任务的测试集 CdMedQA, 综合采用客观指标评价和主观满意度对比两种方式验证系统性能。结果表明, 本研究构建系统在准确性、清晰度、个性化及情境适应性等方面显著优于多种通用与医疗垂直大模型基线。研究结果不仅为慢性病智能化管理提供了新路径, 也为多源知识驱动下人机交互优化与生成内容可信性提升提供了理论支持与技术方案。

关键词 慢性病支持; 医疗问答系统; 混合专家网络; 图检索增强生成; 大语言模型

Construction and Evaluation of Intelligent Medical Q&A System for Chronic Diseases: A Hybrid Modeling Approach Based on GraphRAG and MoE

Ma Xin^{1,2,4}, Wang Fang^{1,2,3}, Zhang Feng⁴ and Li Zhaochuan⁴

(1. Department of Information Resources Management, School of Information and Communication, Nankai University, Tianjin 300071; 2. Center for Network Society Governance, Nankai University, Tianjin 300071;
3. Nankai University Library, Tianjin 300071; 4. Inspur Software Technology Co., Ltd., Jinan 250000)

Abstract: With chronic diseases becoming a core challenge in global public health, there is a growing demand for high-

收稿日期: 2025-06-01; 修回日期: 2025-08-19

基金项目: 文化和旅游部部级社科研究项目“文化和旅游数据资源开发利用模式研究”(25DY09); 南开大学亚洲研究中心项目“数智赋能基层社会风险预警与治理研究”(AS2508)。

作者简介: 马鑫, 1995 年生, 博士, 主要研究方向为推荐系统、人机协同、大模型与健康信息学; 王芳, 通信作者, 1970 年生, 教授, 博士生导师, 主要研究方向为知识发现、情感挖掘、政府信息资源管理与电子政务, E-mail: wangfangnk@nankai.edu.cn; 张峰, 1975 年生, 正高级工程师, 主要研究方向为数据共享开放、一体化政务大数据体系、数字政府等; 李照川, 1984 年生, 正高级工程师, 主要研究方向为一体化政务大数据体系、知识图谱、隐私计算、社会治理等。

quality, personalized, and sustainable health information services for patients. Although large language models (LLMs) have demonstrated significant advantages in medical Q&A tasks recently, existing systems still face bottlenecks such as coarse knowledge scheduling granularity, weak semantic awareness, and poor model response consistency in chronic disease management, which is a long-term, contextualized, and semantically complex scenario. To this end, this study follows the three-stage process of “structured knowledge modeling–hybrid-driven retrieval–large model cooperative response” to propose a fusion approach of graph retrieval augmented generation (GraphRAG) and mixture of experts (MoE) for chronic disease Q&A system. First, a multi-source heterogeneous proprietary knowledge graph covering the elements of disease evolution, lifestyle intervention, and long-term management was constructed. Subsequently, keyword matching was combined with semantic vector recall, multi-model collaborative answering, and multi-subgraph cue fusion three-channel hybrid graph retrieval mechanism, to achieve dynamic knowledge scheduling for complex information requirements. Second, initial screening of user query legitimacy and normality was combined with the user’s implicit intent and fusion sub-graphs, through the MoE dynamic gating network on nine open source big models for command-level synergy, to achieve the semantic depth and generation precision of the dual engine enhancement. Finally, common sense and content integrity checking were introduced, along with formatting rules to refine the preliminary generated text and ensure the accuracy, integrity, and linguistic readability of the output results. The CdMedQA test set built for the experiment, covered 118 chronic diseases and three types of management tasks. The performance of the system was validated using a combination of objective index evaluation and subjective satisfaction comparisons. The results show that the proposed system significantly outperformed multiple generic and healthcare vertical large model baselines in terms of accuracy, clarity, personalization, and contextual adaptability. This provides not only a new path for the intelligent management of chronic disease but also theoretical support and technical solutions for the optimization of human-computer interaction and enhanced credibility for the generated content, driven by multi-source knowledge.

Keywords: chronic disease support; medical Q&A system; mixture of experts; graph retrieval-augmented generation; large language model

0 引言

在全球人口结构持续老龄化、城市化进程加速及生活方式长期不健康等多重因素作用下,慢性病(也称“慢病”)已成为 21 世纪全球范围内最严峻的公共卫生挑战之一^[1]。据世界卫生组织统计,慢性非传染性疾病(如高血压、糖尿病、冠心病、慢性阻塞性肺病等)每年导致超 4100 万人死亡,占全球死亡总人数的 74% 以上,严重影响人群生活质量、劳动生产力和健康公平性^[2]。中国作为世界上慢性病负担最重的国家之一,慢性病患者已突破 3 亿人次,给国家医疗体系和个人经济造成巨大负担^[3]。慢性病管理的复杂性不仅体现在疾病病程的长期性与干预的持续性,更在于其高度个体化的信息需求、行为干预与健康决策支持。传统医疗服务模式以临床就诊为中心,难以有效满足患者在日常生活场景中对医疗知识、行为指导和心理支持的持续性需求^[4-5]。因此,发展以患者为核心、覆盖全病程周期的数字化、智能化慢性病支持工具,已成为新一代健康技术体系构建的战略突破口。

伴随人工智能(artificial intelligence, AI)技术的迅猛演进,大语言模型(large language model, LLM)凭借其卓越的语言理解与生成能力,正深刻

重塑人机交互范式^[6]。以 GPT (generative pre-trained transformer)、DeepSeek 为代表的预训练语言模型已被广泛应用于医疗对话、问答推理与健康知识推荐等多个领域,显示出超越传统规则系统与浅层语义检索模型的强大泛化能力^[7-8]。在慢性病管理语境中,患者查询通常具有非结构化表达、症状与生活方式交织、信息需求动态演化等特点,显著提升了系统理解语境、判别意图与生成回应的技术门槛。基于 LLM 的医疗问答系统不仅能适配复杂自然语言输入,还可结合患者背景、上下文语义与知识约束生成具有人性化、结构化与连续性的答复,有效弥合医患之间的信息不对称与知识理解落差。

近年来,尽管医疗问答系统研究在疾病咨询、智能问诊与健康推荐等方面取得初步进展^[9-20],部分系统已引入知识图谱、上下文建模与语义理解模块,但其在服务慢性病管理这一高复杂度、低稳定性、强个体化的任务中仍存在 3 个方面突出短板。第一,多数系统依赖统一参数架构训练的单一通用大语言模型,难以在语义理解广度与个性推理深度之间取得有效平衡,尤其在处理情境丰富或多轮提问时,常出现泛化性回答、逻辑跳跃或专业表述不足等问题;即使一些研究在医疗场景下训练或微调了大语言模型,受数据和算力成本制约,应答表现

也不尽如人意。第二，多数系统依赖静态、通用型专业医学知识图谱，难以精准映射慢性病特有知识单元和常识知识单元，如药物使用副反应、阶段性干预策略、生活方式个性化调整建议等，缺乏高保真知识调度能力。第三，多数系统依赖静态语义匹配或浅层路径遍历的图检索策略，难以感知患者提问中隐含的健康状态变化、时间序列演化或潜在情绪信号，易导致回答在逻辑关联与行为指导上的失效或片面。因此，构建具备异构知识调度、大模型协同与情境感知生成能力的下一代慢性病问答系统，既是推动医疗人工智能从通用诊断走向深度健康管理的关键突破口，也是在多模态认知融合与用户体验共建方面的理论前沿与技术创新交汇点。

为应对上述问题，本研究提出一种融合图检索增强生成（graph retrieval-augmented generation, GraphRAG）与混合专家网络（mixture of experts, MoE）的慢性病问答系统，通过构建覆盖多源医学与通用知识的精细化异构知识图谱，结合语义解析驱动的图谱混合检索策略，实现对患者多样化信息需求的结构化响应；同时，引入多基座大语言模型构成的专家网络，基于问题特征进行动态协同推理，以提升系统在不同慢性病情境下的语言生成能力与知识适配精度。通过客观指标评分、主观偏好评估，本研究系统性验证了该方法在提升慢性病问答生成内容的准确性、相关性与人机交互质量方面的有效性。

1 相关工作

1.1 医疗问答系统

医疗问答系统的研究兴起于医疗信息需求的快速增长与医疗数据体量的日益膨胀，旨在通过自然语言处理和知识检索与推荐技术，为用户提供准确、及时的健康咨询与医疗信息服务。近年来，随着深度学习和预训练 LLM，如 BERT（bidirectional encoder representations from transformers）和 GPT 系列的技术迭代以及行业实践的不断深入，越来越多的医疗问答系统已被各大医疗机构和科技公司研发并应用于实际医疗服务场景以优化患者就医体验^[6]。例如，IBM 的 Watson Health 系统通过分析医学文献、病例、检查报告和患者数据，为医生提供决策支持，帮助其做出精准诊断^[7]；百度健康推出灵医慧智开放平台，通过融合知识图谱和大模型，赋能诊前、诊中、诊后全流程，助力患者服务

升级、医生工作提质增效、医疗行业能力升级^[8]。同时，行业领先的医疗平台，如 39 健康网和春雨医生，也在构建基于人工智能的智能问诊系统（“39AI 医生”和“春雨惠问”），以为用户提供 24 小时在线咨询服，减轻医务人员工作压力。此外，学术界也在医疗问答系统的研究中取得了诸多重要进展，如何提升系统智能化和个性化成为关键，研究内容涉及知识表示与多源数据融合^[9-11]、自然语言理解与语义建模^[12-15]、医疗查询应答与服务推荐^[16-18]以及系统评估与用户体验优化^[19-20]等多个核心主题。

1.2 混合专家网络

模型规模是提升模型性能的关键因素之一^[21]。混合专家网络（mixture of experts, MoE）起源于 1991 年 Jacobs 等^[22]提出的专家组合机制，其核心思想是在有限计算资源下，通过多个子模型协作提升综合预测精度和鲁棒性。MoE 通常由门控智能体（gating agent, GA）和专家集构成，前者根据输入特征稀疏激活并加权子模型组合，针对不同任务类型或数据子集选择最优推理路径，后者则聚焦输入特征特定区域或任务子集，形成“分而治之”的结构优势，已在自然语言处理、计算机视觉和推荐系统等高维、异质数据任务中得到广泛应用。近年来，随着深度学习技术的不断发展，MoE 门控智能体和专家调度策略得到了进一步优化，如软门控与动态门控^[23]、自适应专家选择^[24-25]、多模态建模^[26]以及分布式训练推理^[27]等，模型可扩展性和计算效率得到极大增强。尽管当前医疗问答系统在智能问诊等方面取得了一定进展，但在慢性病问答场景中仍面临诸多挑战，如患者提问高度个性化、语义复杂、病情演化多样，导致现有统一参数模型难以兼顾覆盖广度与语义深度，应答常出现泛化性差、上下文理解不足、专业性不强等问题，缺乏根据问题类型动态调整推理路径的能力。为应对这一问题，亟须引入一种具备高效计算与结构化建模优势的架构，从而实现更精准、专业、灵活的问答生成。因此，MoE 成为一种具有潜力的解决方案。

1.3 图检索增强生成

传统文本生成模型依赖海量语料训练，虽具备良好的语言生成能力，但易产生模型幻觉，即应答存在常识性错误或语义偏差^[28]，尤其在医疗、法律等高专业性领域潜在危害巨大。GraphRAG 应运而

生,其目标是在生成过程中动态检索知识图谱并引入权威、结构化的实体、关系与情境信息,融合客观知识与概率生成,提升应答文本的准确性、逻辑性与信息密度^[29],已被广泛应用于开放域问答、对话系统以及文本摘要等领域^[10]。既有关于 GraphRAG 的研究主要涉及优化图检索效率(如借助图神经网络抽取知识^[30])、提升知识融合深度(如借助多任务学习搭建知识融合机制^[31])以及图谱动态扩展(如基于文档的知识图谱扩展^[32])等方向,该范式在提高文本生成逻辑一致性与内容丰富度方面展现出重要价值。尽管 GraphRAG 在医疗问答中已有初步应用,如疾病诊断和症状分析,但在慢性病管理这一需长期支持与个性化干预的复杂场景中仍显不足,不仅多依赖通用医学知识图谱,缺乏对药物长期副作用、生活方式调整等专业知识或健康常识的精细支持,而且图检索策略难以捕捉患者查询中蕴含的隐性健康状态时序变化。因此,设计面向慢性病管理的精细化图谱实体、关系和属性,优化检索与融合机制,对于提升医疗问答系统在慢性病管理场景下的性能与实用性具有重要研究价值和应用前景。

2 基于混合专家网络与图检索增强生成的慢性病问答系统设计

针对上文所提慢性病管理场景中医疗问答系统存在的局限,即统一参数模型难以兼顾推理覆盖广度与语义深度、缺乏对慢性病特有知识的精细支持、图检索策略难以捕捉查询隐含的健康状态时序变化等,本研究提出一种基于混合专家网络和图检索增强生成的慢性病问答系统(GraphRAG and MoE based chronic disease Q&A system, GraphRAG-MoE-CDQ&A),旨在通过引入任务驱动的 LLM 专家模块实现不同病程阶段与问答类型的精准建模,结合多源异构知识图谱的动态检索与融合机制,增强系统对慢性病语义特征、演化规律及个体化需求的理解与响应,从而提升应答专业性、相关性。

2.1 系统整体框架

GraphRAG-MoE-CDQ&A 系统的整体框架及其各功能模块的处理流程如图1所示,涉及知识图谱构建、查询判断与解析、图谱混合检索、大模型协同以及多规则后处理5个模块。其中,知识图谱构建负责从多源数据中设计和抽取与慢性病管理相关的实体、关系与属性,通过语义规范化与结构化处

理,构建包含专业医学知识与通用健康常识的可扩展异构知识图谱,为后续任务提供结构化知识支撑;查询判断与解析负责对用户自然语言输入的合法性与规范性进行初步筛选,并基于命名实体识别与意图识别技术提取查询中涉及的慢性病实体、语义意图与具体信息需求,进而判断问题类型,为检索和生成提供语义先验;图谱混合检索负责综合采用关键词匹配、语义向量召回与多子图提示融合等策略,对已构建的专业医学知识图谱进行高效访问,从中获取与用户查询高度相关的医学知识与情境性建议,实现对慢性病复杂信息需求的精准响应;大模型协同负责基于 MoE 门控动态选择并激活多个预训练大语言模型所构成的专家网络,令系统能够兼顾推理广度与语义深度,生成更具专业性、针对性和个性化的问答内容;多规则后处理负责在生成模型输出基础上引入基于健康常识知识图谱的知识约束与内容验证机制,依据健康常识一致性、内容完整性与语言可读性等多维标准,对生成文本进行校验与优化,确保最终应答的准确性、相关性与实用价值。

2.2 知识图谱构建

知识图谱的构建是 GraphRAG-MoE-CDQ&A 系统的基础,直接影响系统对慢性病患者所提问题的理解和解答能力。知识图谱包括两个部分:专业医学知识图谱 DKG (domain-specific knowledge graph) 和健康常识知识图谱 NKG (nutrition/nursing knowledge graph)。两者相辅相成,共同支撑系统的智能问答功能。

2.2.1 专业医学知识图谱

DKG 主要构建自 39 健康网、99 健康网、好大夫在线等医疗领域专业平台的疾病知识、临床指南、药品说明和社区问答数据,以及国家卫生健康委和各省卫生健康委的规范性文件。不仅涵盖广泛的慢性病病种(医保规定可申报的 50 类普通慢性病和 34 类特殊慢性病^[33]),如糖尿病、高血压和慢性阻塞性肺病,而且包含疾病症状、治疗方案、药物副作用和病程管理建议等丰富的慢性病相关信息,数据的多样性和权威性确保了图谱的知识覆盖面和可靠性。

(1) 知识抽取与建模

考虑到源数据存在格式不统一、内容冗余、噪声信息等问题,本研究在构建知识图谱前,先对数据进行严格清洗与预处理,包括数据去重、分词




图1 GraphRAG-MoE-CDQ&A慢性病问答系统框架

(附加 49871 个词)、去除停用词 (附加 6595 个词)、标准化医学术语 (确保同一疾病或症状在不同数据源中使用一致表达), 以及过滤与慢性病管理无关的噪声数据; 特别地, 对于包括多个主题或多样化内容的大型医疗文档, 静态换行符划分后的文档段落主题是本研究判断其是否与慢性病管理相关的依据^[34]。然后, 结合文献调研和 DeepSeek-R1 提示, 利用 Brat 标注工具对从 20145 个源文本块随机抽取的 2000 个文本块中隐含的 8 类实体、8 类实体关系和 9 类实体属性进行背对背标注^[35] (标注一致性 $\kappa=0.82$), 并基于标注结果构建 BiLSTM-CRF (bidirectional long short-term memory - conditional random field) ($\text{hidden_dim}=256 \rightarrow 128$, $\text{dropout}=0.3$, $\text{CRF_l2_reg}=1e-4$, $\text{lr}=1e-3$, $\text{epoch}=40$, $\text{batch_size}=32$, 30% 测试集 $F1=0.916$)、PCNN (pulse coupled neural networks) (ReLU , $\text{filter}=3 \times 300$, $\text{position_embedding_dim}=5$, $\text{batch_size}=32$, $\text{lr}=1e-3$, $\text{maxlen}=120$, 30% 测试集 $F1=0.873$) 和 Canopy ($T1=0.7$, $T2=0.4$) 模型, 分别抽取实体、关系和属性。实

体、关系和属性定义及抽取结果如表 1 所示。

(2) 知识写入与存储

为确保数据的高效存储与快速查询, 本研究选择 Neo4j 作为知识图谱存储方案。Neo4j 以图的形式存储数据, 能够自然地反映实体间的关系结构, 有利于复杂查询的高效执行和知识的直观表达。知识写入过程中, 系统将抽取的实体节点及其关系边进行逐一存储, 并对其附加的属性进行关联保存。同时, Neo4j 还支持图谱的动态更新, 确保随着新知识的加入, 图谱能持续反映最新的医学发现和慢性病管理建议。DKG 的部分 Neo4j 网络如图 2 所示。

2.2.2 健康常识知识图谱

NKG 涉及的知识范围较广, 通常包括社会文化、日常生活、基本人体生理等方面的内容, 能够更好地结合现实世界的普遍认知, 对理解慢性病患者的日常健康需求和行为习惯、缓解模型幻觉至关重要。为更好地支持慢性病管理场景中的问答需

表 1 8类实体、8类实体关系和9类实体属性的定义及抽取结果

实体(4.4万+)			实体关系(58万+)			实体属性	
Brat 标识	描述	数量	Brat 标识	描述	数量	Brat 标识	描述
Disease	由医保目录定义的慢性非传染性疾病标准名称,如2型糖尿病	15210	Has_Ali	Disease 与 Alias 的同义映射关系,如2型糖尿病→消渴症	56194	Popular	发病人群(按《中国居民营养与慢性病状况报告(2024年)》分类为儿童、成人、老年和孕妇)
Alias	慢病在民间、临床或不同地区的常用非标准名称,如消渴症	9306	Has_Symp	Disease 与 Symptom 的因果关联,如冠心病→劳力性胸痛	132929	Infection	传染性(是/否)
Symptom	与特定慢病直接相关的、患者主观报告的异常生理或心理状态,如晨起头晕	5893	Has_Prt	Disease 与 Part 之间的定位关系,如慢性阻塞性肺病→肺泡	56692	Inspection	检查项目(按《临床技术操作规范》标准化名称)
Part	慢病病理改变的部位,如冠状动脉	86	Has_Dept	Disease 与 Department 之间的推荐关系,如抑郁症→精神科	71920	Treatment	治疗方法(药物/手术/物理/综合疗法)
Department	原卫生部《医疗机构诊疗科目名录》所列科室,如眼科	86	Has_Comp	Disease 与 Complication 之间的导致关系,如高血压→脑卒中	54181	Curecycle	治愈周期(慢病治愈所需花费的时间,如天/月/年等)
Complication	慢病直接引发的、需独立干预的继发性病理状态,如糖尿病足	3355	Has_Drg	Disease 与 Drug 之间的适应证关系,如类风湿性关节炎→甲氨蝶呤	76636	Curerate	治愈率(慢病治愈比例0%~100%)
Drug	用于该慢病治疗的化学/生物制剂(含中药提取物),如氨氯地平片	4856	Good_Fod	Disease 与 Food 之间的推荐摄入关系,如骨质疏松→牛奶(高钙)	65515	Treatcost	治疗费用(月平均治疗费用)
Food	与慢病相关的推荐/禁忌食品,如动物内脏(高嘌呤)	5567	Bad_Fod	Disease 与 Food 之间的禁忌关系,如痛风→海鲜(高嘌呤)	74941	Preventive	预防措施(预防慢病的医学手段/生活方式)
—	—	—	—	—	—	Lifestyle	生活建议(易于改善慢病的饮食/运动/心理/监测等建议)

注:知识图谱由 Neo4j 数据库存储;Cypher 查询语句——实体(MATCH (entity) RETURN COUNT(entity))/实体关系(MATCH ()-[rel]-() RETURN COUNT(*))。




图2 专业医学知识图谱的部分 Neo4j 网络

求,本研究选择以 CN-DBpedia 常识知识库为基础(<http://shuyantech.com/api/cndbpedia/avpair> q={待查询实体}),通过附加从科普中国网的 93 篇权威健康

科普咨询中人工抽取的 1142 条常识字典对其进行扩展和优化,以增强系统在回答慢性病相关问题时的可靠性和实用性。CN-DBpedia 是由复旦大学知识工

场实验室研发并维护的大规模通用领域结构化百科，也是国内最早推出的、目前最大规模的开放百科中文知识图谱，从百科领域延伸至法律、科技、教育、医疗等十多个垂直领域，涵盖数千万实体和数亿级的关系，相关知识服务 API（application programming interface）累计调用量达6亿次，已为各类行业近百家单位的智能化应用提供了支撑性知识服务，如华为、同花顺、中国移动和中国电信。CN-DBpedia 成为业界开放中文 NKG 的首选^[36]。

2.3 查询判断与解析

设 x_i 表示用户第 i 次的口语化查询文本。为便

于上下文学习，本研究先构建一个范例 PG，由 x_i 、8 类实体标记及描述和提示规则组成，作为门控智能体（GA）（GPT2-Large-Chinese）的提示，以对预处理后的查询文本进行价值判断，即判断该查询是否适合通过问答系统进行回答，是否包含足够的信息密度。若查询被判断为有价值且包含慢性病实体（T, T），则进行查询解析；若有价值但不包含慢性病实体（T, F），则直接交由通用大模型动态处理。相反地，若既无价值也无慢性病实体（F, F），GA 将根据用户查询的积极或消极态度直接从候选应答集中选择文本并向用户反馈。PG 提示规则和候选应答集如图 3 所示。




图3 PG 提示规则和候选应答集

对（T, T）条件的用户查询，进行实体和意图识别，提取 x_i 的关键实体集 E_i 和用户意图集 Intent_i ，为后续知识图谱检索和问答生成提供基础。其中， E_i 是由 TF-IDF（term frequency - inverse document frequency）算法和 Aho-Corasic 多模匹配算法（亦称

“AC 自动机”，构建自不同知识图谱实体类别的实体集）识别并由余弦相似度

$$S_1(b_{e_i}, b_{e_{\text{DKG},j}}) = \frac{b_{e_i} \cdot b_{e_{\text{DKG},j}}}{\|b_{e_i}\| \cdot \|b_{e_{\text{DKG},j}}\|} \quad (1)$$

1-编辑距离

$$S_2(p, q) = 1 - \left(\frac{\max(p, q), \min(p, q) = 0}{\min \begin{cases} S_2(p-1, q) + 1, \\ S_2(p, q-1) + 1, \\ S_2(p-1, q-1) + 1 \end{cases}} \right) / (\|e_i\| + \|e_{\text{DKG},j}\|) \quad (2)$$

和最小长度相似度

$$S_3(e_i, e_{\text{DKG},j}) = \frac{e_i \cap e_{\text{DKG},j}}{\min(\|e_i\|, \|e_{\text{DKG},j}\|)} \quad (3)$$

构成的混合相似度

$$\text{Sim}(e_i, e_{\text{DKG},j}) = \frac{1}{3} (S_1(b_{e_i}, b_{e_{\text{DKG},j}}) + S_2(p, q) + S_3(e_i, e_{\text{DKG},j})) \quad (4)$$

补充计算所得的实体集。其中， e_i 和 b_{e_i} 分别表示 x_i 提取的第 i 个实体和实体的 BERT 嵌入； $e_{\text{DKG},j}$ 和 $b_{e_{\text{DKG},j}}$ 分别表示 DKG 中的第 j 个实体和实体的 BERT 嵌入； p 和 q 分别表示 e_i 和 $e_{\text{DKG},j}$ 的下标。 Intent_i 是

由基于特征词的规则匹配和基于预训练朴素贝叶斯的意图分类模型共同预测的查询意图集合。其中，12 类查询意图的 3360 条用户查询文本被用于预训练和测试朴素贝叶斯模型（80% 数据用于训练，F1 指数为 0.733），查询意图分类、含义及数据量如表 2 所示。

2.4 图谱混合检索

为提取 DKG 深层次语义信息，满足慢性病患者复杂的、多层次的信息需求，本研究设计了一种包含关键词匹配、语义向量召回和多子图提示融合

表 2 12类用户查询意图的分类、实例及对应数据量

标识	查询意图	实例	标识	查询意图	实例
Q_Dis	查询慢病	最近总头晕是怎么回事	Q_Cyc	查询治愈周期	类风湿多久能治好
Q_Sym	查询症状	糖尿病早期症状有哪些	Q_Des	查询慢病描述	冠心病是一种什么病
Q_Tre	查询治疗方法	怎么治疗慢性支气管炎	Q_Bof	查询忌口食品	糖尿病患者不要吃什么
Q_Ins	查询检查项目	哪些检查能查出艾滋病	Q_Gof	查询建议食物	高胆固醇适合吃什么
Q_Dep	查询就诊科室	抑郁症要去哪个科室看	Q_Pre	查询预防措施	怎么预防高血压
Q_Rat	查询治愈率	高血压的治愈率有多高	Q_Lif	查询生活建议	艾滋病患者怎么护理

注：3360 条意图数据用于训练和测试朴素贝叶斯模型，每类意图包含 280 条问答文本，其中 28 条为 39 健康和 99 健康和好大夫问答社区采集的真实查询文本，252 条为 DeepSeek-R1 的扩增查询文本。

3 个部分的图谱混合检索方法。声明性的图查询语言 Cypher 被用于支持复杂的查询操作，通过直接对知识图谱中的节点和边进行精确检索，实现对特定信息的快速定位。设 $[e, r(s), h]$ 表示 DKG 三元组，

其中， e 表示慢性病实体， r 表示实体间关系， s 表示基础医疗文本来源， h 表示另一个慢性病实体； E_{DKG} 为 DKG 中的实体集合。DKG 中用户第 i 次查询 x_i 相关知识子图的检索流程如图 4 所示。




图 4 专业医学知识图谱中与用户查询相关子图的混合检索流程

(1) 关键词匹配

关键词匹配是对 DKG 中用户查询关键实体进行直接匹配的过程，即找到所有包含 E_i 中实体的知识图谱节点及其基础信息，提高简单查询响应速度。例如，给定查询“糖尿病患者的饮食建议”，系统将提取“糖尿病”和“饮食建议”作为关键实体集，并在 DKG 中匹配与这些关键词相关的实体。具体而言，对于每个实体 $e_i \in E_i$ 执行以下步骤：

Step1. 对 E_{DKG} 中各节点执行匹配，计算 e_i 与节点标签的匹配度，公式为

$$P_{\text{KEY}} = \bigcup_{e_i \in E_i} \{[e_i, \text{label}_{e_i}] \mid e_i \cap E_{\text{DKG}} \neq \emptyset\} \quad (5)$$

若匹配成功，则返回实体和对应实体标识 label 的集合 P_{KEY} ；否则，返回 NULL。

Step2. 设置 $E_i \leftarrow E_i - \{e_i\}$ 。

Step3. 迭代执行 Step1，直至 E_i 为空集。

(2) 语义向量召回

语义向量召回通过计算用户查询意图与实体关系（知识图谱边）的语义相似度来扩展检索范围和检索层次。设 DKG 中所有可能的关系集为 $R = \{r_1, r_2, \dots, r_m\}$

（ m 为 DKG 中实体关系数），每个关系 r_j 对应一个预定义的意图规则映射函数 $f_j: \text{Intent}_i \rightarrow \{0, 1\}$ ，表示该关系是否符合用户意图。基于关键词检索结果 P_{KEY} ，语义检索的结果及形式化表示为

$$P_{\text{REL}} = \{P_1, P_2, \dots, P_i, \dots, P_{\|E_{\text{KEY}}\|}\},$$

$$P_i = \{\dots, (h_{j-1}, r_{j-1}, e_i), (e_i, r_j, h_j), (h_j, r_{j+1}, h_{j+1}), \dots$$

$$|f_j(\text{Intent}_i) = 1, (e_i, r_j, h_j) \in \text{DKG} \wedge e_i \in P_{\text{KEY}}\} \quad (6)$$

其中， P_{REL} 表示 P_{KEY} 中不同实体对应子图的集合； P_i 表示 DKG 中 P_{KEY} 的实体 e_i 对应子图。

(3) 多子图提示融合

为获得与 x_i 相关且具有充分知识覆盖率的子图 SubDKG_i ，本研究采用一种 GA 提示工程方法。具体步骤如下：

Step1. 根据子图的知识覆盖度 KC 的公式

$$\text{KC}_i = \frac{\text{entity}(P_i)}{\|E_{\text{KEY}}\|} \quad (7)$$

对所有符合语义相似度的子图进行排序；式中， KC_i 表示子图 P_i 的知识覆盖度； $\text{entity}()$ 表示子图节点数统计函数； $\|E_{\text{KEY}}\|$ 表示 x_i 的关键实体数。

Step2. 按照覆盖度降序合并子图，形成更为完整的

知识图谱子图结构；

Step3. 构建提示规则（假定你是知识图谱方面的专家。给定用户查询 $[x_i]$ 、查询关键实体 $[E_i]$ 以及各实体对应子图集合 $[\{ (entity_0, relation_1, entity_1), \dots, [], \dots \}]$ 。你的任务是优先考虑具有最高知识覆盖率 $[formula]$ 的子图，并根据它们对用户查询意图的贡献对其排序，以在一个简洁的段落中有重点地描述所有子图路径，如果在你的描述中提到了特定的规律，尽可能多地解释，确保其提供与上下文一致的全面指导），用 GA 来优化实体及其关系的排序，确保 SubDKG_i 能够覆盖查询中的所有重要信息。

2.5 大模型协同

慢性病管理涉及问题复杂且多样，既有大模型在不同知识领域和场景下可能展现出不同优势。协同多个预训练 LLM（如 Spark Lite、Llama2 和 ChatGPT-3.5 Turbo），易于获得更全面、多样和准确的回答，满足用户的不同需求和偏好。具体协同步骤如下：

Step1. 将用户查询 x_i 和 2.4 节所得知识图谱子图 SubDKG_i 通过提示规则（假定你是慢性病管理方面的专家，给定用户查询 $[x_i]$ 和知识图谱检索结果 $[SubDKG_i]$ ，你的任务是结合这些信息生成一个你认为质量最高的回答，以帮助用户解决其健康问题）输入图 2 所示的 9 个既有大模型处理（5 个开源大模型和 4 个闭源大模型），生成候选应答集合 $\{y_{i,1}, y_{i,2}, \dots, y_{i,n}\}$ ，其中， $y_{i,j}$ 是第 j 个大模型在 x_i 和 SubDKG_i 提示下的生成文本， n 是大模型总数。

Step2. 基于智能问答领域文献调研和 DeepSeek-R1 提示预设评价指标体系（见 3.4 节），并综合考虑中文通用大模型综合性测评基准（super Chinese language understanding evaluation, SuperCLUE）排名^[37]，计算各 $y_{i,j}$ 的相对权重 $w_{i,j}$ ，公式为

$$w_{i,j} = \frac{\text{sum}_j}{\sum_{j=1}^n \text{sum}_j}, \text{sum}_j = \alpha s1_j + (1 - \alpha) \cdot s2_j, \\ s1_j = \frac{n - j + 1}{\sum_{j=1}^n (n - j + 1)}, s2_j = \frac{1}{80} \sum_{t=1}^8 d_{j,t} \quad (8)$$

其中， sum_j 表示 $y_{i,j}$ 在预设指标体系和 SuperCLUE 排名上的综合评分； $s1_j$ 表示 $y_{i,j}$ 在 SuperCLUE 排名中的相对权重； $s2_j$ 表示 $y_{i,j}$ 在 8 个评价指标中的平均得分； n 表示大模型数量； $d_{j,t}$ 表示 $y_{i,j}$ 第 t 个评价指标的得分（评分区间 $[1,10]$ ）； α 表示 $s1_j$ 在综合权重 $w_{i,j}$ 中的占比，取值为 0.4，该值通过 5 组对照实验（ $\alpha=0.2, 0.3, 0.4, 0.5, 0.6$ ）确定——当 $\alpha=0.4$ 时，系统在 CdMedQA 测试集的综合得分最高（客观均分提升 0.32）。

Step3. 利用 GPT2-Large-Chinese 预训练模型的 encoder 模块编码各大模型应答 $y_{i,j}$ ，按权重 $w_{i,j}$ 加权拼接编码最后隐藏层的状态矩阵 $I_{i,n}$ ，得到综合隐藏层状态矩阵 I'_i 。

Step4. 对 I'_i 进行解码，生成协同后的应答 y'_i 。

2.6 多规则后处理

为保障最终输出的质量，本研究采用多种规则对 y'_i 做进一步的优化和调整，包括常识校验、内容完整性检查和格式化规则。具体步骤如下：

Step1. 遍历 y'_i 中包含的所有实体集合 $E'_i = \{e'_1, e'_2, \dots, e'_z\}$ 和关系集合 $R'_i = \{r'_1, r'_2, \dots, r'_z\}$ ，匹配常识知识图谱 NKG，

$$\forall (e'_z, r'_z, e_0) \in (E'_i, R'_i): (e'_z, r'_z, e_0) \in \text{NKG} ? (\text{True}, \text{False}) \quad (9)$$

验证实体及关系合法性。针对 $(e'_z, r'_z, e_0) \notin \text{NKG}$ 的常识性错误，通过提示规则（给定以下内容 $[y'_i]$ ，在其中检测到常识错误 $[(e'_z, r'_z, e_0)]$ ，你的任务是用尽可能少的操作修正给定内容中的常识性错误）引导 GA 校正相关子信息。

Step2. 利用正则表达和字符串匹配对 y'_i 进行完整性检查，确保所有关键细节和信息均被呈现，如非专家意见声明。缺失信息由预定义的补全规则和模板进行插补。此外，对 y'_i 的逻辑结构进行分析，并在必要时借助 GA 对内容进行分段、分要点重组，使最终输出的 y_i 更符合患者逻辑和阅读习惯。

3 实验与分析

3.1 大模型基座

本研究共选取 5 种开源和 4 种闭源的通用预训练 LLM 作为专家集合，这些模型代表了当前领域的不同技术路线和性能水平，被用于协同完成慢性病问答任务，以提升 GraphRAG-MoE-CDQ&A 系统对复杂查询的理解和应对能力。各大模型概述如下。

(1) Spark Lite（原生预训练权重）^[38]：科大讯飞推出的一款轻量级开源 LLM，适用于低算力推理等定制场景，并且支持中、英等 37 种语言的自动判别，准确率和识别率显著优于传统语言识别方法。

(2) ChatGLM2-6B（原生预训练权重）^[39]：清华和智谱 AI 基于 ChatGLM-6B 开发的一款开源对话语言模型，拥有 62 亿参数，支持中英双语问答，可在最低 6 GB 显存的消费级显卡上本地部署，兼容长对话场景。

(3) ERNIE-Lite-8K（原生预训练权重）^[40]：百

度自研的一款闭源轻量级 LLM，支持 8 K 和 128 K 的上下文长度，适合在低算力 AI 加速卡上进行高效推理，旨在提供高效且经济的大语言模型服务。

(4) Llama2-7B (经千帆中文增强)^[41]: Meta AI 基于优化 Transformer 研发的一款开源 LLM，70 亿参数，并通过 2T token 数据预训练，在生成和语言理解等方面有显著的能力提升。

(5) Llama3-8B (经个人开发者中文增量预训练和指令精调)^[42]: Meta AI 研发的一款开源 LLM，拥有 80 亿参数，在数据规模、训练参数和优化算法上较前代均有所提升，能够更好地支持翻译和问答等自然语言处理任务。

(6) GPT-3.5 Turbo (原生预训练权重)^[43]: OpenAI 研发的一款闭源 LLM，200 亿参数，继承了 GPT 系列的优势，支持中英等数种语言，并在速度和效率上进行优化，可实现更加智能的文本生成和对话系统等。

(7) Moonshot (8K) (原生预训练权重)^[44]: Moonshot AI 推出的一款千亿参数的闭源语言模型，具备优秀的语义理解、指令遵循和文本生成能力。支持多种长度的上下文窗口，适合长文本的理解和内容生成场景。

(8) Gemma-7B (经千帆中文增强)^[45]: Google 推出的一款轻量级开源 LLM，基于 Gemini 相同技术构建，采用文本到文本、仅限解码器的架构，提供开放权重、预训练和指令调整变体。

(9) Hunyuan-Lite (原生预训练权重)^[46]: 腾讯自研的一款闭源轻量级 LLM，具备复杂语境下强大的中文创作能力、逻辑推理能力以及任务执行能力，最大输入为 250 K，最大输出为 6 K。

3.2 对照算法

除上述 9 种大模型基座外，3 种医疗垂直领域经典的开源中文大语言模型也被用于评估 GraphRAG-MoE-CDQ&A 系统在慢性病管理任务中的问答表现。

(1) DISC-MedLLM^[47]: 复旦大学数据智能与社会计算实验室专门针对医疗健康对话场景设计的一款开源 LLM，有效对齐了医疗场景下的人类偏好，弥合了通用语言模型输出与真实世界医疗对话之间的差距，以提供疾病问诊和治疗方案咨询等高质量的健康支持服务。

(2) DoctorGLM^[48]: 华南理工大学广东省数字孪生人重点实验室基于扁鹊健康大数据和 Chat-

GLM-6B 初始化模型、经过全量参数指令微调设计的一款开源中文主动健康 LLM，通过扩充药品说明书、医学百科知识和 ChatGPT 蒸馏指令等数据，强化了模型建议和知识查询能力。

(3) BenTsao^[49]: 哈尔滨工业大学社会计算与信息检索研究中心基于医学知识图谱和 GPT3.5 API 中文医学指令精调/微调的一款 Llama-7B 模型，提高了 Llama 在医疗领域的问答效果。

3.3 实验数据

本研究通过对慢性病管理领域的相关文献和来自健康管理平台、医疗咨询网站的患者提问与医生应答数据进行整理和分析，构建了一个涵盖慢性病类型、任务类型、用户查询和真实医生应答等多个维度的综合性慢性病问答测试集 CdMedQA，为后续算法测试提供不同情景下的丰富测试样本。

数据集构建流程如下：第一，利用后裔采集器获取[丁香医生→大家都在问]、[春雨医生→经典问答→只显示优质回答]和[有问必答→热门回答→已解决问题]共 3 个医疗网站问答社区的 32569 名慢性病患者的多轮问答数据，通过人工筛选和清洗明显脏数据，如重复提问、无效回答（如 AI 生成内容和“不清楚”）及未采纳应答，构建一对一问答对；第二，基于传染性、治疗类型和污名化程度 3 个特征，将问答对的对应慢性病合并标注为 2 类，一类为较低传染性、明确治疗方式、低污名化的疾病（如高血压和 2 型糖尿病），另一类为高传染性、治疗复杂、高污名化的疾病（如 AIDS 和肺结核），以更精确地评估模型在不同类型慢性病上的应答表现；第三，基于慢性病管理任务的侧重点，将问答对的任务类型标注为医疗管理、角色管理和情绪管理 3 类，标注规则如表 3 所示。最终，CdMedQA 数据集共收纳 1368 个问答对。其中，一类慢性病（68 种）对应 943 个问答对，二类慢性病（50 种）对应 425 个问答对，医疗管理任务类型对应 1060 个问答对，角色管理任务类型对应 167 个问答对，情绪管理任务类型对应 141 个问答对，有问必答源对应 536 个问答对，丁香医生源对应 380 个问答对，春雨医生源对应 452 个问答对；高血压（104 个）和糖尿病（98 个）对应问答对最多，包括肠易激综合征、骨质纤维化和腰间盘突出等在内的 44 种慢性病仅对应一个问答对。用户查询文本的字数范围为[7, 38]，医生回复文本的字数范围为[37, 166]。

表 3 问答对任务类型的分组与标注依据

标签	标注依据
医疗管理	明确提及患者对疾病进行医学管理与治疗的情境,例如,确诊、服药、饮食、运动锻炼、症状监测、遵循治疗计划、健康教育等
角色管理	明确提及患者当下及未来需承担的社会及家庭角色情境,例如,工作、学习、生活、参与社会活动和处理社会关系等
情绪管理	明确提及患者当下及未来需处理的情绪及心理挑战情境,例如,压力、焦虑、紧张、抑郁、恐惧、逆反和愤怒等负面情绪

3.4 评价指标

为全面评估本研究所提 GraphRAG-MoE-CDQ&A 系统在慢性病问答任务中的表现,实验在自建环境中运行 (MacBook Air-2024 13.6 M3, 8 核 CPU+10 核 GPU, 16G RAM, 512GB SSD),并设计了客观评价和主观评价两种互补评价方法:客观评价以实验数据中随机抽取的 150 组问答对的真实医生应答为比较基准,依据表 4 所列 8 项质量评价指标,通过提示 DeepSeek-R1 对各对照算法查询应答进行 5

轮独立评分 (满分 10 分),取平均值为最终得分,量化不同模型在内容质量上的差异;主观评价通过见数众包平台招募具备慢性病管理经验的 20 名患者,征集其最关切的慢性病问题,并由各模型生成应答,分别进行 78 次双盲两两比较 (C_{13}^2),以选择其主观感受最满意的应答 (A 和 B 比较, A 更满意为 1, B 更满意为 0),量化模型输出的用户接受度与实用性。这两类评价方法相辅相成,旨在确保对系统性能形成科学、系统且面向真实应用场景的综合判断。

表 4 慢性病问答生成内容的质量评价指标

评价指标	评价维度	DeepSeek-R1 提示	参考文献
准确性	(1)医疗信息准确(回答基于最新临床指南和科学证据,确保信息无误,避免误导患者); (2)医疗建议精准(考虑患者具体情况,提供针对患者需求的个性化回答)	√	[28,30-31,34,50-52]
清晰度	(1)语言简明易懂(回答应使用简单、直接的语言,避免专业术语或复杂医学表达);(2)结构化回答(采用分段或列表形式呈现复杂信息,内容更易阅读和理解)	√	[53]
完整性	(1)涵盖关键信息(回答包括患者问题相关的所有重要信息,如病因、症状、治疗方法、预防措施和生活方式建议);(2)补充背景信息(提供一些背景知识或额外的信息,帮助患者更好地理解其病情和管理方法)	√	×
同理心	(1)人性化表达(使用同情和支持性语言,关怀和理解患者,缓解其认知和行为负担);(2)鼓励和支持(回答中包含鼓励性语句,激励患者积极参与慢性病管理)	×	[54-55]
相关性	(1)紧扣患者问题(回答直接回应患者提出的问题,避免不相关信息干扰);(2)符合患者偏好(根据患者信息获取习惯和健康信念等偏好调整回答的内容和风格)	√	[31]
安全性	(1)避免过度诊断或治疗建议(回答避免引导患者进行不必要的医学检查或使用不当的药物和治疗方法);(2)隐私保护(不涉及患者隐私,符合数据保护法规)	×	[56-58]
可行性	(1)步骤明确(提出的行动建议包括明确的步骤和执行方法,使患者能够轻松理解和实施);(2)实际可操作(提供的建议具有现实可行性,考虑患者的具体生活环境、经济状况和可获得的资源)	√	[53]
连续性	(1)支持长期管理(回答提供持续的健康指导和管理建议,而非仅针对单一问题的解决方案);(2)促进自我管理(鼓励和教育患者进行有效的自我管理,增强其应对慢性病的能力)	√	×

注：提示——假设你是一个慢性病管理专家,你认为慢性病问答支持系统患者查询的文本回复应考察哪些重要的质量指标？

3.5 实验结果与分析

3.5.1 客观评价

DeepSeek-R1 对 GraphRAG-MoE-CDQ&A 与 12 种对照算法应答的客观评价如图 5 所示。结果表明,本研究提出的方法在 8 项质量指标上表现出色,综合均分达 9.2,在准确性 (9.3)、完整性

(9.5) 与连续性 (9.4) 等关键维度上均显著领先于对照模型,验证了多源知识图谱融合与混合专家机制在支持高复杂度慢性病管理问答任务中的有效性。相比之下,部分垂直领域模型如 BenTsao 与 DISC-MedLLM 在准确性 (均为 9.0) 与安全性 (9.0 与 8.9) 方面表现接近,但在可行性与连续性维度略显不足,表明其在应对多维任务和长期健康指导

方面仍有局限。通用大模型如 GPT-3.5 Turbo 与 Moonshot (8K)在清晰度 (8.8 与 8.5) 和相关性 (8.6 与 8.7) 上表现稳定, 凸显其语言生成优势, 但在同理心维度整体评分偏低 (7.9 与 7.8)。




图5 GraphRAG-MoE-CDQ&A 与 12 种对照算法的客观评价结果

值得注意的是, GraphRAG-MoE-CDQ&A 在同理心维度得分为 8.8, 虽高于所有对照模型, 但仍为其 8 项指标中的最低值。一个可能的原因是, DKG 和 NKG 的构建数据源 (如医疗指南和科普文章) 以传递客观医学信息和普适性建议为主, 语言风格天然偏向理性和中立, 虽包含 “生活建议” (Lifestyle 属性), 但建议通常侧重行为指导 (如饮食运动), 较少涉及细致入微的情感共鸣表达或针对特定心理状态 (如焦虑、抑郁) 的深度安抚策略; 加之用于训练/微调大模型基座的语料 (如开源模型的预训练数据、指令数据) 也未必在医疗情感支持方面进行充分强化。总体而言, 该系统在保障专业性与个性化的同时, 实现了语言表达、任务支持和安全性之间的较优平衡。

3.5.2 主观评价

实验招募的 20 名慢性病参与者的的人口统计特征如表 5 所示。参与者在性别、年龄、教育水平和疾病类型方面分布较为均衡, 涵盖了慢性病常见人群的核心构成, 尤其在 40~59 岁年龄段、患有高血压与糖尿病等高发性慢性病患者中集中度较高, 体现出现实慢性病管理场景中的典型特征, 有助于提升主观评价结果的外部效度与适用性。

表 5 主观评价中 20 名参与者的人口统计特征

特征类别	变量	人数 (n=20)	百分比/%
性别	男性	12	60.0
	女性	8	40.0
年龄/岁	30~39	4	20.0
	40~49	8	40.0
	50~59	6	30.0
	≥60	2	10.0
教育水平	高中及以下	5	25.0
	大专	3	15.0
	本科	7	35.0
	硕士及以上	5	25.0
慢性病类型	2 型糖尿病	4	20.0
	高血压	4	20.0
	冠心病	2	10.0
	哮喘	2	10.0
	其他 (如甲状腺病等)	8	40.0
病程年限	≤5	8	40.0
	6~10	8	40.0
	>10	4	20.0

慢性病问答系统主观应答满意度成对比较热力图与等高线如图 6 所示, 结果表明, GraphRAG-MoE-CDQ&A 在慢性病管理问答中展现显著主观优势, 其在绝大多数两两比较中均获得更高的用户满意度评分, 反映出该系统在语义理解、个性化建议生成以及医疗背景适配性方面具有更高的感知质量和用户认可度。热力图所示满意度分布进一步揭示了该模型在主观评价层面的整体领先地位, 其在与多数模型对比时均处于明显优势区域。然而, 从热力图中叠加的等高线结构来看, GraphRAG-MoE-CDQ&A 与 Hunyuan-Lite、DISC-MedLLM 及 DoctorGLM 等部分模型之间的满意度差异相对收敛, 局部呈现平缓梯度。一个可能的原因是, GraphRAG-MoE-CDQ&A 的核心优势在于处理复杂、需要整合深层语义和跨领域知识的查询 (如涉及药物副作用、生活方式调整与并发症关联的综合问题), 对于高血压、糖尿病等相对简单或标准化的常见病查询, 其混合架构带来的提升在用户主观感知上可能不如在复杂查询中那么显著, 两两比较中优势不突出, 存在系统优势的 “长尾效应”。

总体而言, 该结果验证了混合专家机制与知识图谱增强生成策略在提升用户感知体验方面的有效性, 同时揭示出高性能语言模型之间正在形成 “主观表现集聚带”, 即少数表现优异的模型在用户层面的差异被进一步压缩。这一趋势为后续模型设计




图6 慢性病问答系统主观应答满意度成对比较热力图与等高线

提供了新的研究导向, 即需聚焦于语用层面微观细节的优化, 包括情感调节、意图澄清与情境共识等因素, 以实现真正意义上的人机共情与专业赋能。

4 结论与展望

4.1 结论

本研究围绕慢性病管理中复杂医疗问答任务的核心挑战, 构建了融合图检索增强生成与混合专家网络的大语言模型问答系统——GraphRAG-MoE-CDQ&A, 并通过系统设计、数据构建与多维评估验证其在专业性、语义理解和用户感知质量方面的显著优势。

从理论层面看, 本研究回应了当前医疗问答系统中“统一参数模型难以兼顾覆盖广度与语义深度”的结构性瓶颈, 首次在慢性病问答场景下, 系统性地整合异构知识图谱结构表达与大语言模型专

家选择机制, 为任务驱动下的生成式医学问答建模提供了新的方法论框架, 拓展了现有 GraphRAG 与 MoE 理论在医疗信息服务中的应用边界; 同时, 本研究提出的图谱混合检索与多子图提示融合方法, 不仅为知识增强生成任务提供了更精细化、可解释的语义匹配路径, 也为自然语言生成与结构化知识对齐研究贡献了新思路。

从实践层面看, GraphRAG-MoE-CDQ&A 系统在面向患者个性化需求、动态健康状态与多层次意图的问答支持中, 展现出较强的场景适应性与信息融合能力; 特别是在主观评价实验中, 该系统获得真实慢性病患者的高度满意度, 验证了其在人机交互、语言可用性与认知支持等方面的多维实用价值。这一结果不仅为面向患者自助服务的智能健康助手提供了技术基础, 也为基层医疗服务、在线问诊平台等场景的人工智能系统部署与优化提供了现实路径。

综上,本研究不仅丰富了人工智能在慢性病健康管理中的理论构建与模型设计,也为推动医疗问答系统的个性化、结构化和语义增强发展提供了范式引导与工程参考。

4.2 局限与未来工作

尽管本研究提出的 GraphRAG-MoE-CDQ&A 系统在慢性病管理问答任务中的性能取得了显著提升,并在结构建模、知识整合与多模型协同方面实现了方法创新,但仍存在若干局限。第一,系统通过融合多源异构知识图谱与多专家模型,已显著提升了问答内容的准确性与个性化水平,但在应对高情绪负荷、强语境依赖的复杂场景(如心理干预类问答)中仍显不足,表现为同理心与情绪适应能力有限。未来研究将探索引入情感计算机制与社会语言模型,以增强系统对患者心理状态的感知与共情生成能力。第二,当前图检索增强机制虽在结构化实体与关系整合方面展现出较强能力,但对用户查询中隐含的长期行为模式、时间演化趋势与跨语境语义链尚缺乏有效建模。为进一步支持慢性病管理中时间序列决策与阶段性健康指导的需求,未来可探索引入时序知识图谱、多跳推理机制及跨任务语义融合策略。

参 考 文 献

- [1] Chioma Ebuonyi M, Schnoor K, Versluis A, et al. Short message services interventions for chronic disease management: a systematic review[J]. *Clinical EHealth*, 2021, 4: 24-29.
- [2] 世界卫生组织(WHO)发布《2023 世界卫生统计报告》[EB/OL]. (2023-05-23) [2025-05-28]. https://www.sohu.com/a/678189230_120103084.
- [3] 慢性病形势严峻,致死率占 80% 以上,要早做预防[EB/OL]. (2023-05-31) [2025-05-28]. https://www.sohu.com/a/680648695_121014369.
- [4] Yu G, Tabatabaei M, Mezei J, et al. Improving chronic disease management for children with knowledge graphs and artificial intelligence[J]. *Expert Systems with Applications*, 2022, 201: 117026.
- [5] 马费成,周利琴. 面向智慧健康的知识管理与服务[J]. *中国图书馆学报*, 2018, 44(5): 4-19.
- [6] Wang X, Sun Z C, Wang P P, et al. MedicalGLM: a pediatric medical question answering model with a quality evaluation mechanism[J]. *Journal of Biomedical Informatics*, 2025, 165: 104793.
- [7] 医疗大模型如雨后春笋,谁能在花园中挖出大大的花?[EB/OL]. (2023-07-20) [2025-05-28]. https://www.sohu.com/a/704494575_100150.
- [8] 百度健康发布灵医开放平台,马斯克要做“全球最强 AI”[EB/OL]. (2024-07-23) [2025-05-28]. https://news.qq.com/rain/a/20240723A09MEV00?suid=&media_id=.
- [9] Shen J, Pan T, Xu M, et al. A novel DL-based algorithm integrating medical knowledge graph and doctor modeling for Q&A pair matching in OHP[J]. *Information Processing & Management*, 2023, 60(3): 103322.
- [10] 席运江,李曼,邓雨珊,等. 中文在线医疗社区问答内容知识图谱构建研究[J]. *图书情报工作*, 2024, 68(4): 124-136.
- [11] 洪怡敏,张晗,白智瑛. 面向重大慢性疾病健康管理的知识图谱构建及应用[J]. *情报理论与实践*, 2024, 47(8): 180-189, 210.
- [12] 湛文佳,杨琳,李金林. 嵌入意图识别的医疗健康问答文本语义分类模型[J]. *数据分析与知识发现*, 2025, 9(2): 26-38.
- [13] Kim Y M, Lee T H, Na S O. Constructing novel datasets for intent detection and ner in a Korean healthcare advice system: guidelines and empirical results[J]. *Applied Intelligence*, 2023, 53(1): 941-961.
- [14] Tohti T, Abdurxit M, Hamdulla A. Medical QA oriented multi-task learning model for question intent classification and named entity recognition[J]. *Information*, 2022, 13(12): 581.
- [15] 廖开际,邹珂欣,席运江. 一种在线医疗社区问答文本实体识别方法——基于卷积神经网络和双向长短期记忆神经网络[J]. *科技管理研究*, 2021, 41(8): 173-179.
- [16] 彭佳儿,于菲菲,赵月华. 从患者生成健康数据到用药建议生成——基于图检索增强生成的患者用药信息问答模型[J]. *现代情报*, 2025, 45(12): 63-76.
- [17] Maharjan J, Garikipati A, Singh N P, et al. OpenMedLM: prompt engineering can out-perform fine-tuning in medical question-answering with open-source large language models[J]. *Scientific Reports*, 2024, 14: 14156.
- [18] Singhal K, Tu T, Gottweis J, et al. Toward expert-level medical question answering with large language models[J]. *Nature Medicine*, 2025, 31(3): 943-950.
- [19] 罗顺财,李庆印,魏福祿,等. 基于知识图谱的多源信息融合事故处理系统[J]. *山东理工大学学报(自然科学版)*, 2024, 38(3): 28-34.
- [20] Khurana K, Deshpande U. Video question-answering techniques, benchmark datasets and evaluation metrics leveraging video captioning: a comprehensive survey[J]. *IEEE Access*, 2021, 9: 43799-43823.
- [21] 混合专家模型(MoE)详解[EB/OL]. (2023-12-26) [2025-05-28]. <https://zhuanlan.zhihu.com/p/674698482>.
- [22] Jacobs R A, Jordan M I, Nowlan S J, et al. Adaptive mixtures of local experts[J]. *Neural Computation*, 1991, 3(1): 79-87.
- [23] Rambabu R, Vadakkepat P, Tan K C, et al. A mixture-of-experts prediction framework for evolutionary dynamic multiobjective optimization[J]. *IEEE Transactions on Cybernetics*, 2020, 50(12): 5099-5112.

- [24] He X H, Yan K Y, Li R, et al. Frequency-adaptive pan-sharpening with mixture of experts[C]// Proceedings of the 38th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2024: 2121-2129.
- [25] Zhou Q Y, Zhang K Y, Yao T P, et al. Adaptive mixture of experts learning for generalizable face anti-spoofing[C]// Proceedings of the 30th ACM International Conference on Multimedia. New York: ACM Press, 2022: 6009-6018.
- [26] Akbari H, Kondratyuk D, Cui Y, et al. Alternating gradient descent and mixture-of-experts for integrated multimodal perception [C]// Proceedings of the Conference on Advances in Neural Information Processing Systems. Red Hook: Curran Associates, 2023: 79142-79154.
- [27] Liu J C, Wang J H, Jiang Y M. Janus: a unified distributed training framework for sparse mixture-of-experts models[C]// Proceedings of the ACM SIGCOMM 2023 Conference. New York: ACM Press, 2023: 486-498.
- [28] 张金营, 王天堃, 么长英, 等. 基于大语言模型的电力知识库智能问答系统构建与评价[J]. 计算机科学, 2024, 51(12): 286-292.
- [29] Matsumoto N, Moran J, Choi H, et al. KRAGEN: a knowledge graph-enhanced RAG framework for biomedical problem solving using large language models[J]. Bioinformatics, 2024, 40(6): btac353.
- [30] Guo Q, Cao S, Yi Z. A medical question answering system using large language models and knowledge graphs[J]. International Journal of Intelligent Systems, 2022, 37(11): 8548-8564.
- [31] Sarmah B, Mehta D, Hall B, et al. HybridRAG: integrating knowledge graphs and vector retrieval augmented generation for efficient information extraction[C]// Proceedings of the 5th ACM International Conference on AI in Finance. New York: ACM Press, 2024: 608-616.
- [32] Andrus B R, Nasiri Y, Cui S L, et al. Enhanced story comprehension for large language models through dynamic document-based knowledge graphs[C]// Proceedings of the 36th AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2022: 10436-10444.
- [33] 慢性病病种有哪些? 准入标准是如何规定的?[EB/OL]. (2026-01-01) [2026-02-15]. <https://ybj.wuhu.gov.cn/ztzl/ybzsxl/mxbp/8364583.html>.
- [34] Wu J D, Zhu J Y, Qi Y L, et al. Medical graph RAG: towards safe medical large language model via graph retrieval-augmented generation[PP/OL]. V2. arXiv (2024-10-15). <https://arxiv.org/pdf/2408.04187>.
- [35] 马鑫, 王芳. 元宇宙的概念、技术、应用与影响——一项系统性文献综述[J]. 图书情报工作, 2023, 67(18): 113-128.
- [36] 科普中国. 常识知识库[EB/OL]. (2021-12-31) [2025-05-28]. https://www.kepuchina.cn/article/articleinfo?business_type=100&classify=0&ar_id=220010.
- [37] SuperCLUE 智能指数[EB/OL]. (2024-09-02) [2025-05-28]. <https://www.superclueai.com/homepage>.
- [38] 星火认知大模型 websocket 接口文档[EB/OL]. (2024-08-15) [2025-05-28]. <https://www.xfyun.cn/doc/spark/Web.html>.
- [39] 智谱清言[EB/OL]. [2025-05-28]. <https://chatglm.cn/>.
- [40] 百度千帆·大模型服务及 Agent 开发平台[EB/OL]. (2024-08-26) [2025-05-28]. <https://cloud.baidu.com/doc/WENXINWORKSHOP/s/dltgsna1o>.
- [41] Llama-2-7B[EB/OL]. (2023-08-31) [2025-05-28]. <https://huggingface.co/meta-llama/Llama-2-7b>.
- [42] 中文羊驼大模型三期项目(Chinese Llama-3 LLMs) developed from Meta Llama 3[EB/OL]. (2024-05-30) [2025-05-28]. <https://github.com/ymcui/Chinese-LLaMA-Alpaca-3>.
- [43] Singh M, Cambronero J, Gulwani S, et al. CodeFusion: a pre-trained diffusion model for code generation[C]// Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association of Computational Linguistics, 2023: 11697-11708.
- [44] 使用手册[EB/OL]. [2025-05-28]. <https://platform.moonshot.cn/docs/intro/#%E6%96%87%E6%9C%AC%E7%94%9F%E6%88%90%E6%A8%A1%E5%9E%8B>.
- [45] Gemma-7B[EB/OL]. (2024-07-26) [2025-05-25]. <https://www.modelscope.cn/models/AI-ModelScope/gemma-7b>.
- [46] API 概览[EB/OL]. [2025-05-25]. <https://cloud.tencent.com/document/product/1729/101848>.
- [47] Bao Z J, Chen W, Xiao S Z, et al. DISC-MedLLM: bridging general large language models and real-world medical consultation [PP/OL]. arXiv (2023-08-28). <https://arxiv.org/pdf/2308.14346>.
- [48] 中文医疗对话模型扁鹊(BianQue)[EB/OL]. (2023-06-06) [2025-05-25]. <https://github.com/scutecyr/BianQue>.
- [49] 本草(原名: 华驼)模型仓库, 基于中文医学知识的大语言模型指令微调[EB/OL]. (2023-06-11) [2025-05-25]. <https://github.com/SCIR-HI/Huatuo-Llama-Med-Chinese/tree/main>.
- [50] Luo R Q, Sun L A, Xia Y C, et al. BioGPT: generative pre-trained transformer for biomedical text generation and mining[J]. Briefings in Bioinformatics, 2022, 23(6): bbac409.
- [51] Dai D W, Zhang Y H, Xu L, et al. PA-LLaVA: a large language-vision assistant for human pathology image understanding[C]// Proceedings of the 2024 IEEE International Conference on Bioinformatics and Biomedicine. Piscataway: IEEE, 2024: 3138-3143.
- [52] Hager P, Jungmann F, Holland R, et al. Evaluation and mitigation of the limitations of large language models in clinical decision-making[J]. Nature Medicine, 2024, 30(9): 2613-2622.
- [53] Gajjar A A, Kumar R P, Paliwoda E D, et al. Usefulness and accuracy of artificial intelligence chatbot responses to patient questions for neurosurgical procedures[J]. Neurosurgery, 2024, 95(1): 171-178.
- [54] Ju J R, Meng Q G, Sun F F, et al. Citizen preferences and govern-

- ment chatbot social characteristics: evidence from a discrete choice experiment[J]. Government Information Quarterly, 2023, 40(3): 101785.
- [55] Chen Y Y, Yan S Z, Liu S J, et al. EmotionQueen: a benchmark for evaluating empathy of large language models[C]// Findings of the Association for Computational Linguistics: ACL 2024. Stroudsburg: Association for Computational Linguistics, 2024: 2149-2176.
- [56] Schmidgall S, Harris C, Essien I, et al. Addressing cognitive bias in medical language models[PP/OL]. V3. arXiv (2024-02-20). <https://arxiv.org/pdf/2402.08113>.
- [57] Colbert L, Hegazi I, Peters K, et al. Medical students' awareness of overdiagnosis and implications for preventing overdiagnosis [J]. BMC Medical Education, 2024, 24(1): Article No.256.
- [58] Lukas N, Salem A, Sim R, et al. Analyzing leakage of personally identifiable information in language models[C]// Proceedings of the 44th IEEE Symposium on Security and Privacy. Piscataway: IEEE, 2023: 346-363.

(责任编辑 魏瑞斌)